

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN



NAM CAN THO UNIVERSITY

NGUYỄN VĂN HỒ

**ỨNG DỤNG CÔNG NGHỆ RAG++ XÂY DỰNG CHATBOT
TRỢ GIÚP TRA CỨU THÔNG TIN PHÁP LÝ THÔNG
MINH VỀ LUẬT HÔN NHÂN VÀ GIA ĐÌNH**

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Kỹ Thuật Phần Mềm

Mã số ngành: 7480103

Tháng 6 năm 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN

NGUYỄN VĂN HỒ

MSSV: 222520

ỨNG DỤNG CÔNG NGHỆ RAG++ XÂY DỰNG
CHATBOT TRỢ GIÚP TRA CỨU THÔNG TIN PHÁP
LÝ THÔNG MINH VỀ LUẬT HÔN NHÂN VÀ GIA
ĐÌNH

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Kỹ Thuật Phần Mềm

Mã số ngành: 7480103

GIẢNG VIÊN HƯỚNG DẪN
NCS. TRẦN VĂN THIỆN

Tháng 6 năm 2026

CHẤP THUẬN HỘI ĐỒNG

Khóa luận “Ứng dụng công nghệ RAG++ xây dựng Chatbot trợ giúp tra cứu thông tin pháp lý thông minh về Luật Hôn nhân và Gia đình”, do sinh viên Nguyễn Văn Hồ thực hiện dưới sự hướng dẫn của Giảng viên Trần Văn Thiện. Khóa luận tốt nghiệp đã báo cáo và được Hội đồng chấm Khóa luận thông qua ngày
... tháng ... năm 2026.

Ủy viên
(Ký tên)

Thư ký
(Ký tên)

.....

.....

Phản biện 1
(Ký tên)

Phản biện 2
(Ký tên)

.....

.....

Cán bộ hướng dẫn
(Ký tên)

Chủ tịch Hội đồng
(Ký tên)

.....

.....

LỜI CẢM ƠN

Trước hết, em xin bày tỏ lòng biết ơn chân thành và sâu sắc đến trường Đại học Nam Cần Thơ – ngôi trường đã tạo điều kiện học tập, rèn luyện và cung cấp nền tảng kiến thức vững chắc để em hoàn thành chương trình học cũng như thực hiện luận văn tốt nghiệp này.

Em xin gửi lời cảm ơn trân trọng đến Quý thầy cô Khoa Công nghệ thông tin, những người đã tận tình giảng dạy, truyền đạt kiến thức và kinh nghiệm quý báu trong suốt thời gian em theo học tại trường. Những bài học và sự hướng dẫn tận tâm của quý thầy cô chính là hành trang quý giá giúp em có được kết quả như ngày hôm nay.

Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc đến Nghiên Cứu Sinh Trần Văn Thiện, người đã trực tiếp hướng dẫn, đồng hành cùng em trong suốt quá trình thực hiện luận văn. Thầy không chỉ tận tình định hướng, góp ý chuyên môn mà còn luôn động viên, khích lệ em vượt qua những khó khăn trong quá trình nghiên cứu. Sự tận tâm và nhiệt huyết của thầy là nguồn động lực to lớn giúp em hoàn thành tốt luận văn này.

Dù luận văn vẫn còn những hạn chế nhất định, nhưng em đã cố gắng thực hiện với tinh thần nghiêm túc và nỗ lực cao nhất. Em kính mong nhận được sự góp ý của quý thầy cô để có thể hoàn thiện hơn về kiến thức và kỹ năng trong tương lai.

Em xin chân thành cảm ơn!

Cần Thơ, ngày tháng 6 năm 2026

Người thực hiện

Nguyễn Văn Hồ

LỜI CAM ĐOAN

Em xin cam kết Khóa luận này được hoàn thành dựa trên kết quả nghiên cứu của em và các kết quả này chưa được dùng cho bất cứ khóa luận cùng cấp nào khác.

Cần Thơ, ngày tháng 6 năm 2026

Người thực hiện

Nguyễn Văn Hồ

MỤC LỤC

CHƯƠNG 1:	1
GIỚI THIỆU	1
1.1 ĐẶT VẤN ĐỀ NGHIÊN CỨU.....	1
1.2 LÝ DO CHỌN ĐỀ TÀI	1
1.3 MỤC TIÊU NGHIÊN CỨU.....	2
1.3.1 Mục tiêu chung.....	2
1.3.2 Mục tiêu cụ thể.....	2
1.4 PHẠM VI NGHIÊN CỨU	3
1.4.1 Không gian	3
1.4.2 Thời gian	3
1.4.3 Đối tượng nghiên cứu	4
1.5 BỐ CỤC CỦA LUẬN VĂN.....	4
1.6 Ý NGHĨA KHOA HỌC VÀ THỰC TIỄN CỦA ĐỀ TÀI	5
1.6.1. Ý nghĩa khoa học	5
1.6.2. Ý nghĩa thực tiễn.....	6
1.7 TỔNG KẾT CHƯƠNG.....	6
CHƯƠNG 2:	8
CƠ SỞ LÝ LUẬN VÀ TỔNG QUAN NGHIÊN CỨU	8
2.1. MÔ HÌNH NGÔN NGỮ LỚN (LARGE LANGUAGE MODELS – LLM) ..	8
2.1.1. Khái niệm và đặc điểm của Mô hình Ngôn ngữ Lớn.....	8
2.1.2. Hiện tượng Ảo giác thông tin (Hallucination) trong LLM	8
2.1.3. Tại sao LLM thuần túy không đủ cho tư vấn pháp lý – Phân tích khoảng trống kỹ thuật	9
2.2. KIẾN TRÚC SINH TĂNG CƯỜNG TRUY XUẤT (RETRIEVAL-AUGMENTED GENERATION – RAG).....	10
2.2.1. Khái niệm và Nguyên lý hoạt động của RAG	10
2.2.2. Các hạn chế của RAG thông thường trong miền Pháp luật Tiếng Việt..	10
2.3. CÁC KỸ THUẬT NỀN TẢNG CỦA KIẾN TRÚC RAG++	11

2.3.1. Tìm kiếm Ngữ nghĩa Dày đặc (Dense Semantic Retrieval) với FAISS	11
2.3.2. Tìm kiếm Từ khóa Thưa thớt (Sparse Keyword Retrieval) với BM25 và PyVi ViTokenizer	11
2.3.3. Tìm kiếm Lai (Hybrid Retrieval) và Reciprocal Rank Fusion (RRF)	12
2.3.4. Thuật toán Suy giảm Thời gian (Temporal Decay Penalty)	12
2.3.5. Mô hình Tái xếp hạng Cross-Encoder (Cross-Encoder Reranker)	13
2.3.6. Phân tích điểm yếu của từng kỹ thuật đơn lẻ – Lý luận cho kiến trúc kết hợp RAG++	13
2.4. XỬ LÝ NGÔN NGỮ TỰ NHIÊN TIẾNG VIỆT TRONG NGỮ CẢNH PHÁP LÝ	15
2.4.1. Đặc điểm Ngôn ngữ học Tiếng Việt và Thách thức Xử lý	15
2.4.2. PhoBERT và Mô hình Ngôn ngữ Tiếng Việt	15
2.5. ĐÁNH GIÁ HỆ THỐNG RAG VÀ LLM-AS-A-JUDGE	16
2.5.1. Các Phương pháp Đánh giá RAG Truyền thống	16
2.5.2. Khung Đánh giá RAGAS và LLM-as-a-Judge	16
2.5.3. Chuẩn đánh giá LexRAG cho Hệ thống Hỏi-Đáp Pháp lý	16
2.6. TỔNG QUAN CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN	17
2.6.1. Nghiên cứu về Hệ thống Hỏi-Đáp Pháp lý	17
2.6.2. Hệ thống Chatbot Kinh tế Tiếng Việt GVEC – Bài học Kinh nghiệm	17
2.6.3. Nghiên cứu về Chiến lược Truy xuất Nâng cao	18
2.6.4. Tổng hợp Khoảng trống Nghiên cứu	18
2.6.5. Bảng so sánh tổng hợp các công trình liên quan và vị trí của RAG++	18
2.7. CƠ SỞ PHÁP LÝ: LUẬT HÔN NHÂN VÀ GIA ĐÌNH VIỆT NAM	19
2.7.1. Tổng quan Hệ thống Văn bản Pháp luật	19
2.7.2. Nhu cầu Tiếp cận Thông tin Pháp luật Hôn nhân và Gia đình	19
2.8. TỔNG KẾT CHƯƠNG	20
CHƯƠNG 3	21
PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ HỆ THỐNG	21
3.1 GIỚI THIỆU CHUNG	21
3.2. TỔNG QUAN KIẾN TRÚC HỆ THỐNG RAG++	22
3.2.1 Phương pháp nghiên cứu	22

3.2.2 Kiến trúc tổng thể hệ thống RAG++	22
3.3. PIPELINE SỐ HÓA VÀ XÂY DỰNG KHO TRI THỨC PHÁP LÝ (OFFLINE KNOWLEDGE INGESTION PIPELINE)	24
3.3.1. Thu thập và Trích xuất Văn bản Pháp luật (Document Acquisition)	24
3.3.2. Phân đoạn Văn bản theo Ranh giới Điều luật (Article-Boundary Chunking).....	25
3.3.3. Sinh Embedding Đa ngôn ngữ và Lập chỉ mục Song song (Dual Indexing)	27
3.4. PIPELINE XỬ LÝ TRUY VẤN PHÁP LÝ THỜI GIAN THỰC (ONLINE LEGAL CONSULTATION PIPELINE)	28
3.4.1. Phân loại Truy vấn Ngoài Phạm vi (Out-of-Scope Detection)	29
3.4.2. Cải viết Truy vấn Pháp lý (Query Reformulation)	29
3.4.3. Tìm kiếm Lai Song song (Hybrid Retrieval): Dense FAISS và Sparse BM25.....	30
3.4.4. Hợp nhất Kết quả bằng Reciprocal Rank Fusion (RRF)	30
3.4.5. Thuật toán Suy giảm Thời gian Hiệu lực (Temporal Decay Penalty)	31
3.4.6. Tái xếp hạng bằng Cross-Encoder Reranker.....	32
3.4.7. Xây dựng Prompt và Sinh Câu trả lời bằng Mô hình Ngôn ngữ Lớn (Prompt Builder và LLM Generation)	32
3.4.8. Cơ chế Xoay vòng Khóa API Đảm bảo Tính Sẵn sàng Cao (High- Availability APIKeyRotator)	33
3.5. CÔNG CỤ, NGÔN NGỮ LẬP TRÌNH VÀ MÔI TRƯỜNG PHÁT TRIỂN	34
3.6 HỆ THỐNG ĐÁNH GIÁ CHẤT LƯỢNG TỰ ĐỘNG LEXRAG++.....	36
3.6.1 Kiến trúc hệ thống đánh giá bất đồng bộ	36
3.6.2 Quy trình đánh giá năm tiêu chí LexRAG++.....	36
3.6.3 Chỉ số Keyword Accuracy	37
3.6.4 Quy trình xây dựng bộ Benchmark 351 tình huống.....	37
3.7 THIẾT KẾ KIẾN TRÚC PHẦN MỀM TỔNG THỂ	38
3.7.1 Kiến trúc Backend FastAPI.....	38
3.7.2 Thiết kế cơ sở dữ liệu.....	38
3.7.3 Thiết kế hệ thống xác thực và phân quyền.....	42

3.7.4 Thiết kế giao diện Frontend	42
3.8 TỔNG KẾT CHƯƠNG.....	42
CHƯƠNG 4	44
TRIỂN KHAI VÀ KẾT QUẢ THỰC NGHIỆM.....	44
4.1. GIỚI THIỆU CHƯƠNG.....	44
4.2. KẾT QUẢ TRIỂN KHAI HỆ THỐNG PHẦN MỀM.....	44
4.2.1. Tổng quan Khai báo cấu trúc	44
4.2.2. Chatbot Chính giao diện (Chatweb).....	45
4.2.3 Giao diện Admin Tổng quan.....	47
4.2.4 Giao diện Quản lý hội thoại	49
4.2.5 Giao diện Thống Kê	52
4.2.6 Giao diện Cài Đặt Hệ thống.....	55
4.2.7. Minh họa Luồng Xử lý Thực tế	57
4.3. KẾT QUẢ THỰC NGHIỆM TỔNG THỂ TRÊN BỘ BENCHMARK 351 TÌNH HUỐNG.....	58
4.3.1. Thực nghiệm cài đặt.....	58
4.3.2. Kết quả LLM Judge Score theo Năm Tiêu chí LexRAG++	58
4.4. PHÂN TÍCH ĐÓNG GÓP TỪNG THÀNH PHẦN KIẾN TRÚC	59
4.4.1. So sánh cấu hình thiết kế.....	59
4.4.2. Kết quả nghiên cứu Ablation	60
4.5. PHÂN TÍCH SO SÁNH HIỆU NĂNG CÁC LLM BACKEND	62
4.5.1. So sánh thiết kế thực nghiệm LLM.....	62
4.5.2. Kết quả So sánh Hiệu ứng LLM	62
4.6. THẢO LUẬN VÀ PHÂN TÍCH TỔNG HỢP	64
4.6.1. Hiệu quả của kiến trúc RAG++ so với mô hình LLM thuần túy.....	64
4.6.2. Vai trò của Hybrid Retrieval trong hệ thống	64
4.6.3. Đóng góp của các thành phần nâng cao trong RAG++	65
4.6.4. Phân tích kết quả theo các tiêu chí LexRAG++.....	65
4.6.5. Khả năng thích ứng với nhiều mô hình ngôn ngữ	66
4.6.6. Hạn chế của nghiên cứu	66
4.6.7. Ý nghĩa thực tiễn của nghiên cứu	66

4.7. KẾT LUẬN CHƯƠNG 4.....	67
CHƯƠNG 5	68
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	68
5.1. GIỚI THIỆU CHƯƠNG	68
5.2. TỔNG KẾT KẾT QUẢ NGHIÊN CỨU	68
5.2.1. Đối chiếu Mục tiêu và Kết quả Đạt được	68
5.2.2. Tổng kết kết quả thực nghiệm cốt lõi	70
5.2.3. Xác nhận giải quyết các Thách thức Đặc thù.....	70
5.3. CÁC ĐÓNG GÓP CỦA LUẬN VĂN.....	71
5.3.1. Đóng góp Khoa học	71
5.3.2. Đóng góp Thực tiễn	73
5.4. HẠN CHẾ CỦA NGHIÊN CỨU.....	73
5.4.1. Hạn chế về Kho Tri thức Pháp lý.....	73
5.4.2. Hạn chế về Phương pháp Đánh giá.....	74
5.4.3. Hạn chế về Kiến trúc Kỹ thuật.....	74
5.4.4. Hạn chế về Phạm vi Triển khai.....	75
5.5. HƯỚNG PHÁT TRIỂN TIẾP THEO.....	75
5.5.1. Tích hợp GraphRAG – Truy xuất Tri thức Có Cấu trúc Đồ thị.....	75
5.5.2. Mở rộng Đa Lĩnh vực Pháp luật	76
5.5.3. Triển khai Mô hình Ngôn ngữ Cục bộ (On-Premise Local LLM)	76
5.5.4. Tích hợp Hội thoại Đa lượt và Quản lý Ký ức Hội thoại.....	77
5.5.5. Tích hợp Đầu vào Đa phương thức (Multimodal Input).....	77
5.6. KẾT LUẬN CHUNG.....	77
TÀI LIỆU THAM KHẢO.....	79

DANH SÁCH BẢNG

<i>Bảng 2. 1 Phân tích điểm mạnh, điểm yếu từng kỹ thuật và giải pháp tích hợp trong RAG++</i>	14
<i>Bảng 2. 2 So sánh RAG++ với các công trình liên quan theo sáu tiêu chí đặc thù của miền pháp luật tiếng Việt</i>	19
<i>Bảng 3. 1 Tương quan giữa các hạn chế của RAG thông thường và thành phần giải quyết trong RAG++</i>	24
<i>Bảng 3. 2 Hệ số Temporal Decay cho các văn bản pháp luật trong kho tri thức (năm 2026)</i>	32
<i>Bảng 3. 3 Danh mục công cụ, thư viện và công nghệ sử dụng trong hệ thống RAG++</i>	35
<i>Bảng 3. 4 Năm tiêu chí đánh giá LexRAG++ với thang điểm chi tiết</i>	37
<i>Bảng 3. 5 Từ điển dữ liệu của các thực thể</i>	39
<i>Bảng 4. 1 Ví dụ minh họa xử lý luồng thử nghiệm thực tế của hệ thống RAG++</i>	57
<i>Bảng 4. 2 Phân tích vấn đề giải pháp trong Bộ Benchmark 351 vấn đề</i>	58
<i>Bảng 4. 3 Kết quả LLM Judge Score trung bình của RAG++ trên Benchmark 351 vấn đề</i>	59
<i>Bảng 4. 4 Mô tả chi tiết cấu hình trong Ablation Study</i>	60
<i>Bảng 4. 5 Kết quả so sánh chi tiết cấu hình Ablation Study trên Benchmark 351 vấn đề</i>	60
<i>Bảng 4. 6 Đóng góp của RAG++</i>	61
<i>Bảng 4. 7 Các mô hình ngôn ngữ lớn được sử dụng trong nghiên cứu</i>	62
<i>Bảng 4. 8 So sánh hiệu năng của các LLM Backend trên Benchmark 351 tình huống</i>	63
<i>Bảng 5. 1 Đối chiếu các mục tiêu cụ thể với kết quả thực nghiệm tác đa phương thức, kế thừa trực tiếp nền tảng mà luận văn đặt ra</i>	69

DANH SÁCH HÌNH

<i>Hình 3. 1 Sơ đồ tổng quan kiến trúc hệ thống RAG++ – Pipeline số hóa kho tri thức (bên trái) và Pipeline xử lý truy vấn pháp lý thời gian thực (bên phải)</i>	<i>23</i>
<i>Hình 3. 2 Minh họa cơ chế phân đoạn văn bản theo ranh giới điều luật (Article-Boundary Chunking) bằng biểu thức chính quy lookahead.....</i>	<i>26</i>
<i>Hình 3. 3 Sơ đồ luồng xử lý chi tiết của Pipeline xử lý truy vấn pháp lý thời gian thực (Online Legal Consultation Pipeline).....</i>	<i>28</i>
<i>Hình 3. 4 Cơ sở dữ liệu</i>	<i>38</i>
<i>Hình 3. 5 Sơ đồ Thực thể ERD.....</i>	<i>41</i>
<i>Hình 4. 1 Giao diện Chatweb.....</i>	<i>45</i>
<i>Hình 4. 2 Giao diện Admin Tổng quan</i>	<i>47</i>
<i>Hình 4. 3 Giao diện Quản lý Hội thoại.....</i>	<i>49</i>
<i>Hình 4. 4 Giao diện Thống kê</i>	<i>52</i>
<i>Hình 4. 5 Giao diện Cài đặt Hệ thống</i>	<i>55</i>

DANH MỤC TỪ VIẾT TẮT

STT	Viết tắt	Tiếng Anh	Tiếng Việt
1	RAG	Retrieval-Augmented Generation	Sinh tăng cường truy xuất
2	RAG++	Retrieval-Augmented Generation Plus Plus	Sinh tăng cường truy xuất nâng cao
3	LLM	Large Language Model	Mô hình ngôn ngữ lớn
4	NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
5	FAISS	Facebook AI Similarity Search	Công cụ tìm kiếm tương đồng vector
6	BM25	Best Match 25	Thuật toán xếp hạng tài liệu BM25
7	RRF	Reciprocal Rank Fusion	Thuật toán hợp nhất xếp hạng đảo nghịch
8	OOS	Out-of-Scope	Phát hiện câu hỏi ngoài phạm vi
9	API	Application Programming Interface	Giao diện lập trình ứng dụng
10	JWT	JSON Web Token	Token xác thực dạng JSON
11	SSE	Server-Sent Events	Sự kiện gửi từ máy chủ
12	OCR	Optical Character Recognition	Nhận dạng ký tự quang học
13	RAGAS	Retrieval Augmented Generation Assessment	Khung đánh giá hệ thống RAG tự động
14	GraphRAG	Graph Retrieval-Augmented Generation	RAG có cấu trúc đồ thị tri thức
15	AI	Artificial Intelligence	Trí tuệ nhân tạo
16	NLU	Natural Language Understanding	Hiểu ngôn ngữ tự nhiên
17	QA	Question Answering	Hỏi – Đáp tự động
18	IR	Information Retrieval	Truy xuất thông tin
19	KG	Knowledge Graph	Đồ thị tri thức
20	LexRAG++	Legal RAG Evaluation Framework	Khung đánh giá RAG chuyên biệt pháp lý
21	BERT	Bidirectional Encoder Representations from Transformers	Mô hình ngôn ngữ hai chiều dựa trên Transformers
22	PhoBERT	Pho Bidirectional Encoder Representations from Transformers	Mô hình BERT tiếng Việt
23	E5	Text Embeddings by Weakly-Supervised Contrastive Pre-training	Mô hình nhúng văn bản đa ngôn ngữ
24	CPU	Central Processing Unit	Bộ xử lý trung tâm
25	GPU	Graphics Processing Unit	Bộ xử lý đồ họa
26	REST	Representational State Transfer	Kiến trúc truyền tải trạng thái đại diện

27	HTTP	Hypertext Transfer Protocol	Giao thức truyền tải siêu văn bản
28	UI	User Interface	Giao diện người dùng
29	UX	User Experience	Trải nghiệm người dùng
30	ORM	Object-Relational Mapping	Ảnh xạ quan hệ đối tượng
31	JSON	JavaScript Object Notation	Định dạng trao đổi dữ liệu JSON

TÓM TẮT

Luận văn này trình bày quá trình nghiên cứu, thiết kế và triển khai hệ thống Web Chatbot hỗ trợ tra cứu thông tin pháp lý thông minh chuyên sâu về Luật Hôn nhân và Gia đình Việt Nam, ứng dụng kiến trúc Sinh tăng cường truy xuất nâng cao (RAG++ – Retrieval-Augmented Generation Plus Plus). Đề tài được thực hiện trong bối cảnh người dân ngày càng có nhu cầu cao trong việc tiếp cận thông tin pháp luật hôn nhân – gia đình, trong khi các công cụ truyền thống chỉ dừng lại ở mức tra cứu văn bản thô, thiếu khả năng diễn giải và cá nhân hóa theo từng tình huống cụ thể.

Hệ thống đề xuất can thiệp sâu sắc vào cả ba giai đoạn của luồng xử lý dữ liệu, gồm: (1) Pipeline số hóa và tiền xử lý kho tri thức pháp lý với kỹ thuật phân đoạn theo ranh giới điều luật (Article-Boundary Chunking), sinh nhúng đa ngôn ngữ bằng mô hình multilingual-e5-base và lưu trữ song song lên FAISS Index và BM25 Index; (2) Pipeline xử lý truy vấn thời gian thực tích hợp Tác tử phân loại ý định (Query Intent Agent), cơ chế Tìm kiếm lai song song (Hybrid Search), thuật toán trộn điểm Reciprocal Rank Fusion (RRF), bộ lọc hiệu lực văn bản (Metadata Filtering), mô hình tái xếp hạng Cross-Encoder Reranker và thuật toán suy giảm thời gian (Temporal Decay Penalty); và (3) Hệ thống đánh giá chất lượng tự động đa chiều theo khung LexRAG++ và RAGAS thông qua phương pháp Giám khảo AI (LLM-as-a-Judge).

Kết quả thực nghiệm trên bộ dữ liệu Benchmark gồm 351 tình huống pháp lý phức tạp cho thấy hệ thống RAG++ đạt điểm LLM Judge Score trung bình 8,22/10 và Keyword Accuracy 0,93/1,0, vượt mức chuẩn đề ra ($\geq 7,50$) và đạt chất lượng đầu ra tương đương mức một Luật sư có chuyên môn. Phân tích loại trừ thành phần (Ablation Study) trên năm cấu hình kiến trúc cũng xác nhận rõ ràng đóng góp tích lũy của từng thành phần nâng cao trong kiến trúc RAG++ so với mô hình RAG cơ bản (điểm LLM Judge tăng từ 4,71 lên 8,22; Keyword Accuracy tăng từ 0,25 lên 0,93).

Luận văn đóng góp một quy trình toàn trình khép kín kiểm soát hoàn toàn hiện tượng ảo giác thông tin (hallucination) của mô hình ngôn ngữ lớn trong lĩnh vực pháp lý tiếng Việt, đồng thời xây dựng một khung đánh giá định lượng chuyên biệt cho bài toán Hỏi-Đáp pháp lý tại Việt Nam, có tiềm năng mở rộng sang các miền luật liên quan trong tương lai.

Từ khóa: RAG++, Sinh tăng cường truy xuất nâng cao, Chatbot pháp lý, Luật Hôn nhân và Gia đình, Tìm kiếm lai, BM25, FAISS, LLM-as-a-Judge, Xử lý ngôn ngữ tự nhiên tiếng Việt.

CHƯƠNG 1:

GIỚI THIỆU

1.1 ĐẶT VẤN ĐỀ NGHIÊN CỨU

Hệ thống pháp luật về hôn nhân và gia đình tại Việt Nam hiện nay tương đối đồ sộ và phức tạp, bao gồm Luật Hôn nhân và Gia đình năm 2014 (Luật số 52/2014/QH13) phối hợp cùng hàng loạt văn bản dưới luật như Nghị quyết 01/2024/NQ-HĐTP của Tòa án nhân dân tối cao, các Nghị định và Thông tư hướng dẫn thi hành. Sự đan xen phức tạp này tạo ra rào cản thông tin rất lớn đối với người dân khi có nhu cầu tra cứu, thấu hiểu và áp dụng các chế định pháp lý vào thực tiễn đời sống như thủ tục thuận tình hoặc đơn phương ly hôn, phân chia tài sản chung/riêng, tranh chấp quyền nuôi con hoặc nghĩa vụ cấp dưỡng.

Trong bối cảnh chuyển đổi số ngành tư pháp, nhu cầu tiếp cận thông tin pháp luật của người dân ngày càng tăng cao, đặc biệt ở các tỉnh Đồng bằng sông Cửu Long nơi khoảng cách địa lý và chi phí tư vấn luật sư chuyên nghiệp tạo ra rào cản tiếp cận dịch vụ pháp lý. Các công cụ tìm kiếm truyền thống hiện nay chỉ dừng lại ở mức so khớp từ khóa và trả về văn bản luật thô, hoàn toàn thiếu sự diễn giải ngữ cảnh và kết nối tình huống cá nhân hóa cho từng người dùng.

Sự xuất hiện của các Mô hình Ngôn ngữ Lớn (Large Language Models – LLM) mở ra tiềm năng xây dựng trợ lý AI có khả năng giao tiếp tự nhiên và diễn giải pháp luật. Tuy nhiên, việc ứng dụng trực tiếp LLM vào lĩnh vực pháp lý đối mặt với thách thức nghiêm trọng về hiện tượng ảo giác thông tin (hallucination) – mô hình có thể tự bịa đặt ra các số hiệu điều luật không tồn tại hoặc diễn giải sai lệch bản chất tư pháp, gây ra hậu quả pháp lý nguy hiểm cho người dùng. Kiến trúc Sinh tăng cường truy xuất (Retrieval-Augmented Generation – RAG) cung cấp giải pháp nền tảng bằng cách neo chặt đầu ra của LLM vào kho tri thức pháp lý đã được kiểm chứng; tuy nhiên, kiến trúc RAG thông thường vẫn bộc lộ bốn điểm yếu cốt lõi khi áp dụng cho lĩnh vực pháp luật tiếng Việt: (1) dễ bị tấn công bởi các truy vấn ngoài phạm vi chuyên ngành, (2) khoảng cách ngữ nghĩa giữa ngôn ngữ thông tục của người dân và thuật ngữ luật pháp chính thức, (3) vấn đề phân đoạn từ ghép tiếng Việt trong tìm kiếm từ khóa, và (4) phân cấp thời gian hiệu lực của các văn bản pháp luật.

Từ thực tiễn trên, nghiên cứu này đặt ra vấn đề cấp thiết là phải xây dựng một kiến trúc RAG nâng cao (Advanced RAG) chuyên biệt, can thiệp sâu sắc vào cả ba giai đoạn xử lý dữ liệu nhằm kiểm soát chặt chẽ kho tri thức nạp vào LLM, bảo đảm mọi câu trả lời sinh ra đều có căn cứ pháp lý chính xác, minh bạch và trích dẫn điều luật cụ thể.

1.2 LÝ DO CHỌN ĐỀ TÀI

Đề tài "Ứng dụng công nghệ RAG++ xây dựng Chatbot trợ giúp tra cứu thông tin pháp lý thông minh về Luật Hôn nhân và Gia đình" được lựa chọn xuất phát từ ba nhóm lý do khoa học và thực tiễn sau:

Thứ nhất, tính cấp thiết về mặt xã hội: Luật Hôn nhân và Gia đình là bộ luật ảnh hưởng trực tiếp đến đời sống của hàng triệu người dân Việt Nam. Nhu cầu tra cứu các quy định liên quan đến kết hôn, ly hôn, tài sản, con cái ngày càng tăng cao, trong khi chi phí thuê luật sư tư vấn vượt quá khả năng tài chính của nhiều gia đình, đặc biệt ở khu vực nông thôn và Đồng bằng sông Cửu Long – địa bàn nơi Trường Đại học Nam Cần Thơ tọa lạc.

Thứ hai, tính thách thức về mặt kỹ thuật: Miền pháp luật tiếng Việt đặt ra những bài toán kỹ thuật đặc thù chưa được giải quyết thỏa đáng trong các hệ thống RAG thông thường, bao gồm phân đoạn từ ghép tiếng Việt, xử lý khoảng cách ngữ nghĩa giữa ngôn ngữ thông tục và thuật ngữ pháp lý, và quản lý phân cấp hiệu lực thời gian của văn bản pháp luật. Đây là cơ hội nghiên cứu phát triển và đóng góp những giải pháp kỹ thuật mới có giá trị khoa học.

Thứ ba, tính khả thi và môi trường triển khai: Quá trình học tập tại Trường Đại học Nam Cần Thơ đã tạo điều kiện tiếp cận môi trường phát triển phần mềm thực tế, đồng thời sự phát triển của các API thương mại (OpenRouter, meta-llama/llama-3.3-70b-instruct) và các thư viện mã nguồn mở (FAISS, rank-bm25, multilingual-e5-base, FastAPI) giúp việc triển khai hệ thống trở nên khả thi về mặt nguồn lực kỹ thuật và tài chính trong khuôn khổ nghiên cứu sinh viên đại học.

1.3 MỤC TIÊU NGHIÊN CỨU

1.3.1 Mục tiêu chung

Mục tiêu chung của luận văn là nghiên cứu, thiết kế và phát triển thành công hệ thống Web Chatbot hỗ trợ tra cứu thông tin pháp lý thông minh chuyên sâu về Luật Hôn nhân và Gia đình Việt Nam, ứng dụng kiến trúc RAG++ (Retrieval-Augmented Generation Plus Plus) nâng cao. Hệ thống hướng tới mục tiêu cung cấp công cụ tham khảo pháp luật đáng tin cậy, chính xác về trích dẫn điều luật và dễ tiếp cận đối với mọi người dân, góp phần thúc đẩy quá trình chuyển đổi số trong lĩnh vực phổ biến giáo dục pháp luật tại Việt Nam.

1.3.2 Mục tiêu cụ thể

Để đạt được mục tiêu chung, luận văn xác định năm mục tiêu cụ thể sau:

(1) Xây dựng kho tri thức số hóa chuẩn mực: Thiết lập pipeline tiền xử lý tự động bóc tách, phân đoạn theo ranh giới điều luật (Article-Boundary Chunking) và nạp thành công 505 đoạn văn bản pháp lý từ hệ thống Luật Hôn nhân và Gia đình năm 2014 cùng các văn bản hướng dẫn dưới luật, kèm nhãn siêu dữ liệu (Metadata) pháp lý đầy đủ.

(2) Triển khai module tìm kiếm lai song song: Xây dựng thành công cơ chế Hybrid Retrieval kết hợp tìm kiếm ngữ nghĩa vector (Semantic Search với FAISS và mô hình multilingual-e5-base) và tìm kiếm từ khóa chính xác (Lexical Search với BM25 kết hợp PyVi ViTokenizer cho tiếng Việt).

(3) Tích hợp các thuật toán nâng cao: Triển khai thành công thuật toán trộn điểm RRF (Reciprocal Rank Fusion), mô hình Cross-Encoder Reranker, bộ lọc Metadata Filtering theo tình trạng hiệu lực văn bản và thuật toán Temporal Decay Penalty (hệ số suy giảm $\lambda=0,20$ mỗi năm) nhằm ưu tiên các văn bản pháp luật mới hơn.

(4) Xây dựng hệ thống Backend và Frontend hoàn chỉnh: Phát triển hệ thống mã nguồn Backend dịch vụ bằng framework FastAPI và thiết kế giao diện Frontend tương tác trực quan hỗ trợ cả khách vãng lai lẫn thành viên đăng ký, tích hợp các phân hệ xác thực, quản lý phiên hội thoại và đánh giá chất lượng bất đồng bộ.

(5) Đánh giá thực nghiệm đa chiều: Thực hiện kiểm định tự động hệ thống trên bộ Benchmark gồm 351 tình huống pháp lý phức tạp theo phương pháp Giám khảo AI (LLM-as-a-Judge), đạt điểm LLM Judge Score $\geq 7,50/10$ và Keyword Accuracy $\geq 0,70/1,0$, so sánh với năm cấu hình kiến trúc trong Ablation Study.

1.4 PHẠM VI NGHIÊN CỨU

1.4.1 Không gian

Về phạm vi không gian kỹ thuật, hệ thống được triển khai dưới dạng ứng dụng Web Chatbot hoàn chỉnh vận hành trên máy chủ FastAPI và Uvicorn. Kho tri thức giới hạn tính trong phạm vi các văn bản quy phạm pháp luật chuyên ngành tại thời điểm thực hiện nghiên cứu, bao gồm Luật Hôn nhân và Gia đình năm 2014 (Luật số 52/2014/QH13) và từ ba đến năm văn bản hướng dẫn dưới luật liên quan, đặc biệt là Nghị quyết 01/2024/NQ-HĐTP của Hội đồng Thẩm phán Tòa án nhân dân tối cao. Hệ thống không tích hợp tính năng tự động thu thập văn bản mới theo thời gian thực ngoài phạm vi dữ liệu tĩnh đã nạp.

Về phạm vi kỹ thuật và công nghệ, hệ thống giới hạn sử dụng ngôn ngữ Python (phiên bản 3.12 trở lên) cho backend, framework FastAPI, cơ sở dữ liệu SQLite/SQL Server với SQLAlchemy ORM, FAISS làm vector database, mô hình multilingual-e5-base sinh embedding và OpenRouter API (meta-llama/llama-3.3-70b-instruct) làm mô hình ngôn ngữ lớn. Giao tiếp người dùng giới hạn qua ký tự văn bản thuần (text-based), chưa hỗ trợ nhận diện giọng nói hoặc trích xuất ảnh tài liệu quét OCR.

Về phạm vi pháp lý, hệ thống đóng vai trò công cụ hỗ trợ tra cứu và giải thích pháp luật mang tính tham khảo học tập cho người dân. Hệ thống tuyệt đối không có chức năng cá nhân hóa hồ sơ tư pháp và không thực hiện các hoạt động tư vấn pháp lý chuyên nghiệp theo nghĩa của Luật Luật sư Việt Nam hiện hành.

1.4.2 Thời gian

Nghiên cứu được thực hiện trong khuôn khổ kỳ thực tập học kỳ III năm học 2025–2026 tại Trường Đại Học Năm Căn Thơ, từ tháng 3 năm 2026 đến tháng 6 năm 2026 (tổng cộng 12 tuần nghiên cứu). Kho tri thức pháp lý được số hóa phản ánh tình trạng hiệu lực văn bản tính đến tháng 6 năm 2026. Các kết quả thực

thực nghiệm và số liệu đánh giá được thu thập và tổng hợp trong giai đoạn triển khai hệ thống từ tháng 5 đến tháng 6 năm 2026.

1.4.3 Đối tượng nghiên cứu

Đối tượng nghiên cứu của luận văn bao gồm hai nhóm chính:

- Đối tượng kỹ thuật: Kiến trúc Sinh tăng cường truy xuất nâng cao (Advanced RAG Pipeline), bao gồm các kỹ thuật phân đoạn văn bản theo ranh giới điều luật, xử lý ngôn ngữ tự nhiên tiếng Việt, mô hình nhúng đa ngôn ngữ (multilingual-e5-base), thuật toán BM25 với PyVi ViTokenizer, thư viện FAISS, thuật toán RRF, mô hình Cross-Encoder Reranker, thuật toán Temporal Decay Penalty và phương pháp kiểm thử LLM-as-a-Judge.
- Đối tượng pháp lý: Hệ thống các văn bản quy phạm pháp luật hiện hành liên quan đến Luật Hôn nhân và Gia đình năm 2014 của nước Cộng hòa xã hội chủ nghĩa Việt Nam, bao gồm luật gốc và các Nghị định, Nghị quyết, Thông tư hướng dẫn thi hành có hiệu lực tại thời điểm nghiên cứu.
- Đối tượng người dùng hướng đến là người dân vắng lai hoặc thành viên đăng ký có nhu cầu tìm hiểu, tra cứu và cần diễn giải các quy định pháp luật về hôn nhân và gia đình trong các tình huống thực tế của đời sống, không yêu cầu người dùng có kiến thức pháp luật chuyên sâu.

1.5 BỐ CỤC CỦA LUẬN VĂN

Luận văn được tổ chức thành năm chương với nội dung chính như sau:

- Chương 1 – Giới thiệu: Trình bày bối cảnh, vấn đề nghiên cứu, lý do chọn đề tài, mục tiêu nghiên cứu tổng quát và cụ thể, phạm vi không gian–thời gian–đối tượng nghiên cứu, bố cục luận văn và ý nghĩa khoa học, thực tiễn của đề tài.
- Chương 2 – Cơ sở lý thuyết và tổng quan nghiên cứu: Trình bày các khái niệm nền tảng về Mô hình Ngôn ngữ Lớn (LLM), kiến trúc Retrieval-Augmented Generation (RAG) chuẩn và các hạn chế của nó, đồng thời tổng quan các công trình liên quan trong lĩnh vực Hỏi-Đáp pháp lý, tìm kiếm lai và đánh giá hệ thống RAG trong bối cảnh tiếng Việt và quốc tế.
- Chương 3 – Phương pháp nghiên cứu và thiết kế hệ thống: Trình bày chi tiết kiến trúc hệ thống RAG++, bao gồm Offline Knowledge Ingestion Pipeline (thu thập, phân đoạn Article-Boundary Chunking, nhúng và lập chỉ mục) và Online Legal Consultation Pipeline (OOS Detection, Query Reformulation, Hybrid Search, RRF, Temporal Decay, Cross-Encoder Reranking, LLM Generation và APIKeyRotator). Mô tả công cụ, ngôn ngữ lập trình và môi trường phát triển được sử dụng.
- Chương 4 – Triển khai và kết quả thực nghiệm: Trình bày kết quả triển khai thực tế hệ thống bao gồm thiết kế cơ sở dữ liệu lai (Hybrid Storage), các giao diện phần mềm (Chatweb, Admin, Thống kê), kết quả đánh giá thực nghiệm trên bộ Benchmark 351 tình huống theo năm tiêu chí LexRAG, Ablation Study so sánh năm cấu hình kiến trúc và so sánh hiệu năng các LLM backend khác nhau.
- Chương 5 – Kết luận và hướng phát triển: Tổng kết các đóng góp khoa học và thực tiễn của luận văn, phân tích các hạn chế hiện tại và đề xuất các hướng

nghiên cứu, phát triển tiếp theo bao gồm GraphRAG, mở rộng đa lĩnh vực pháp luật, triển khai thiết bị cục bộ và tương tác đa phương thức.

1.6 Ý NGHĨA KHOA HỌC VÀ THỰC TIỄN CỦA ĐỀ TÀI

1.6.1. Ý nghĩa khoa học

Về mặt khoa học, luận văn mang lại bốn đóng góp có giá trị tham chiếu cho cộng đồng nghiên cứu xử lý ngôn ngữ tự nhiên và trí tuệ nhân tạo pháp lý tại Việt Nam.

Đóng góp 1 – Kiến trúc RAG++ chuyên biệt cho miền pháp luật tiếng Việt: Luận văn đề xuất và hiện thực hóa đầy đủ kiến trúc RAG++ – một framework Sinh tăng cường truy xuất nâng cao (Advanced RAG) can thiệp toàn diện vào cả ba giai đoạn xử lý dữ liệu: tiền truy xuất (pre-retrieval), truy xuất (retrieval) và hậu truy xuất (post-retrieval). Đây là điểm khác biệt căn bản so với các nghiên cứu RAG thông thường trong tiếng Việt, vốn chỉ tối ưu hóa một thành phần đơn lẻ. Kiến trúc RAG++ tích hợp sáu tầng can thiệp kỹ thuật theo chuỗi: OOS Detection → Query Reformulation → Hybrid Retrieval (FAISS + BM25/PyVi) → RRF Fusion → Temporal Decay Penalty → Cross-Encoder Reranking, mỗi tầng được thiết kế để giải quyết trực tiếp một thách thức đặc thù của miền pháp luật tiếng Việt mà các hệ thống trước đây chưa giải quyết đồng thời và tích hợp.

Đóng góp 2 – Khung đánh giá LexRAG++ chuyên biệt cho Hỏi-Đáp pháp lý tiếng Việt: Luận văn xây dựng khung đánh giá định lượng đa chiều LexRAG++ gồm năm tiêu chí được thiết kế riêng cho bài toán tư vấn pháp lý tiếng Việt: Tính xác thực (Factuality), Tính đầy đủ (Completeness), Tính mạch lạc (Coherence), Tính rõ ràng (Clarity) và Mức độ liên quan (Relevance). Điểm chuẩn 7,50/10 được hiệu chỉnh tương đương năng lực một luật sư hành nghề có chuyên môn – cung cấp thang đo có ý nghĩa thực tế và có thể tái sử dụng cho các nghiên cứu LawTech tiếng Việt tiếp theo. Đây là khung đánh giá đầu tiên kết hợp đồng thời cả LLM-as-a-Judge đa tiêu chí và chỉ số Keyword Accuracy tự động (không cần LLM giám khảo) cho hệ thống tư vấn pháp lý tiếng Việt.

Đóng góp 3 – Bộ Benchmark 351 tình huống pháp lý tiếng Việt: Luận văn xây dựng bộ Benchmark gồm 351 tình huống pháp lý phức tạp về Luật Hôn nhân và Gia đình Việt Nam, bao phủ 15 chủ đề pháp lý lớn từ điều kiện kết hôn đến chia tài sản doanh nghiệp sau ly hôn. Đây là bộ dữ liệu đánh giá đầu tiên được xây dựng chuyên biệt cho bài toán Hỏi-Đáp về Luật Hôn nhân và Gia đình Việt Nam với quy trình chú thích ground truth có hệ thống và minh bạch, có tiềm năng trở thành tài nguyên dữ liệu mở phục vụ cộng đồng nghiên cứu AI pháp lý tiếng Việt trong tương lai.

Đóng góp 4 – Bảng chứng thực nghiệm định lượng về đóng góp từng thành phần (Ablation Study): Kết quả Ablation Study trên năm cấu hình kiến trúc (C1 đến C5) cung cấp bằng chứng thực nghiệm rõ ràng về đóng góp độc lập và tích lũy của từng thành phần kỹ thuật trong kiến trúc Advanced RAG khi áp dụng vào miền pháp luật tiếng Việt. Chuỗi kết quả tăng dần từ 4,71 (LLM thuần túy) đến 8,22 (RAG++ hoàn chỉnh) với các bước trung gian được kiểm soát chặt chẽ là đóng góp

có giá trị tham chiếu cho các nhà nghiên cứu muốn xây dựng hệ thống Advanced RAG trong các miền chuyên biệt khác của tiếng Việt.

1.6.2. Ý nghĩa thực tiễn

Bên cạnh giá trị khoa học, đề tài mang lại ba đóng góp thiết thực có thể triển khai ngay trong bối cảnh chuyển đổi số tư pháp tại Việt Nam.

Đóng góp thực tiễn 1 – Công cụ tra cứu pháp lý tiếp cận 24/7 cho người dân: Hệ thống RAG++ cung cấp một Web Chatbot hoạt động 24/7, cho phép người dân tra cứu và nhận diện giải các quy định Luật Hôn nhân và Gia đình mà không cần kiến thức pháp luật chuyên sâu và không tốn chi phí thuê luật sư tư vấn. Điều này mang ý nghĩa xã hội đặc biệt với cộng đồng dân cư tại khu vực Đồng bằng sông Cửu Long – nơi khoảng cách địa lý và chi phí tư vấn pháp lý tạo ra rào cản tiếp cận thông tin pháp luật đáng kể. Kết quả thực nghiệm với điểm LLM Judge Score đạt 8,22/10 và Keyword Accuracy đạt 0,93/1,0 xác nhận chất lượng tư vấn đạt mức tương đương luật sư có chuyên môn trong lĩnh vực Hôn nhân và Gia đình, đủ tin cậy để người dân sử dụng làm công cụ tham khảo pháp luật trong các tình huống thực tế.

Đóng góp thực tiễn 2 – Nền tảng kỹ thuật có khả năng mở rộng sang các lĩnh vực pháp luật khác: Kiến trúc RAG++ được thiết kế theo nguyên tắc LLM-Agnostic (độc lập với mô hình ngôn ngữ) và Domain-Agnostic (dễ mở rộng sang các miền pháp luật khác bằng cách thay thế kho tri thức mà không cần thiết kế lại toàn bộ kiến trúc). Thực nghiệm với bốn LLM Backend – Llama 3.3-70B, GPT-4o-mini, Gemini Flash và Gemma 4-26B – đều vượt ngưỡng 7,50 xác nhận tính linh hoạt này. Đây là nền tảng trực tiếp để mở rộng sang Luật Đất đai 2024, Bộ luật Dân sự 2015 và Luật Tố tụng Dân sự 2015 trong các nghiên cứu tiếp theo.

Đóng góp thực tiễn 3 – Kho tri thức pháp lý số hóa chuẩn mực và bộ công cụ đánh giá tái sử dụng: Kho tri thức 505 phân đoạn pháp lý với siêu dữ liệu đầy đủ (article_id, tên văn bản, năm ban hành, trạng thái hiệu lực) cùng bộ Benchmark 351 tình huống có chú thích ground truth là các tài nguyên dữ liệu chất lượng cao có thể tái sử dụng cho các ứng dụng AI pháp lý khác, hỗ trợ đào tạo và kiểm định các mô hình tư vấn pháp lý tiếng Việt thế hệ tiếp theo. Về ứng dụng trực tiếp, hệ thống có tiềm năng triển khai trong các cổng thông tin pháp luật, hệ thống hỗ trợ tư vấn của Sở Tư pháp, Trung tâm Trợ giúp pháp lý và các nền tảng chuyển đổi số trong lĩnh vực tư pháp tại Việt Nam.

1.7 TỔNG KẾT CHƯƠNG

Chương 1 đã trình bày bức tranh toàn cảnh của vấn đề nghiên cứu: sự cấp thiết của việc xây dựng công cụ hỗ trợ tra cứu pháp luật hôn nhân và gia đình thông minh trong bối cảnh chuyển đổi số tư pháp Việt Nam, những hạn chế của các giải pháp hiện tại (công cụ truyền thống và RAG thông thường), và tầm nhìn giải quyết của kiến trúc RAG++ được đề xuất trong luận văn.

Mục tiêu chung hướng đến xây dựng hệ thống Chatbot pháp lý chuyên sâu có chất lượng đầu ra tương đương Luật sư có chuyên môn, với năm mục tiêu cụ thể

bao phủ toàn bộ vòng đời của hệ thống từ số hóa tri thức, thiết kế pipeline truy xuất nâng cao, triển khai phần mềm đến đánh giá thực nghiệm định lượng. Phạm vi nghiên cứu được giới hạn rõ ràng trong hệ thống Luật Hôn nhân và Gia đình năm 2014 và các văn bản liên quan, triển khai trong khuôn khổ học kỳ 3 tại Trường Đại học Nam Cần Thơ, năm 2026.

Những nội dung lý thuyết nền tảng về LLM, RAG và các kỹ thuật xử lý ngôn ngữ tự nhiên tiếng Việt sẽ được trình bày chi tiết trong Chương 2, làm tiền đề cho việc thiết kế kiến trúc RAG++ ở Chương 3.

CHƯƠNG 2:

CƠ SỞ LÝ LUẬN VÀ TỔNG QUAN NGHIÊN CỨU

2.1. MÔ HÌNH NGÔN NGỮ LỚN (LARGE LANGUAGE MODELS – LLM)

2.1.1. Khái niệm và đặc điểm của Mô hình Ngôn ngữ Lớn

Mô hình Ngôn ngữ Lớn (Large Language Models – LLM) là các mô hình học sâu được huấn luyện trên tập dữ liệu văn bản khổng lồ, có khả năng hiểu và sinh ngôn ngữ tự nhiên ở mức độ tiệm cận con người. Các mô hình tiêu biểu như Llama 3.3, Gemini và GPT-4 đã chứng minh năng lực ấn tượng trong các tác vụ đa dạng: trả lời câu hỏi, tóm tắt văn bản, dịch thuật, lập trình và phân tích ngữ nghĩa phức tạp.

Kiến trúc nền tảng của LLM hiện đại là cơ chế Transformer với cơ chế chú ý đa đầu (multi-head attention), cho phép mô hình nắm bắt các phụ thuộc ngữ nghĩa tầm xa trong văn bản. Quá trình huấn luyện thường diễn ra theo hai giai đoạn: (1) tiền huấn luyện trên kho ngữ liệu quy mô lớn theo mục tiêu mô hình hóa ngôn ngữ nhân quả, và (2) tinh chỉnh có giám sát kết hợp Học tăng cường từ phản hồi con người (RLHF) để căn chỉnh hành vi với yêu cầu thực tế.

2.1.2. Hiện tượng Ảo giác thông tin (Hallucination) trong LLM

Mặc dù sở hữu năng lực ngôn ngữ vượt trội, LLM đôi mắt với hạn chế nghiêm trọng trong các ứng dụng đòi hỏi tính chính xác cao: hiện tượng ảo giác thông tin (hallucination). Đây là hiện tượng mô hình tự sinh ra các nội dung nghe có vẻ hợp lý nhưng thực chất sai lệch về mặt thực tế – bao gồm trích dẫn sai số hiệu điều luật, bịa đặt các quy định không tồn tại, hoặc diễn giải sai lệch nội dung pháp lý [4].

Nguyên nhân cốt lõi của hiện tượng này nằm ở bản chất xác suất của quá trình sinh văn bản: mô hình dự đoán token tiếp theo dựa trên phân phối xác suất học được từ dữ liệu huấn luyện, không có cơ chế tra cứu thực tế (grounding) để kiểm chứng tính chính xác của thông tin được sinh ra. Trong lĩnh vực pháp lý, một trích dẫn điều luật sai lệch duy nhất có thể gây ra hậu quả nghiêm trọng cho người dùng đang dựa vào hệ thống để đưa ra quyết định pháp lý quan trọng.

Kiến trúc Sinh tăng cường truy xuất (RAG) được đề xuất như giải pháp căn bản để kiểm soát hiện tượng ảo giác thông tin, bằng cách neo chặt đầu ra của LLM vào kho tri thức đã kiểm chứng thay vì phụ thuộc vào bộ nhớ tham số của mô hình [4].

2.1.3. Tại sao LLM thuần túy không đủ cho tư vấn pháp lý – Phân tích khoảng trống kỹ thuật

Mặc dù các LLM hiện đại sở hữu năng lực ngôn ngữ ấn tượng, kết quả thực nghiệm của nghiên cứu này (Ablation Study, Bảng 4.5) cho thấy mô hình LLM thuần túy không tích hợp cơ chế truy xuất (cấu hình C1) chỉ đạt điểm LLM Judge trung bình 4,71/10 – thấp hơn đáng kể so với ngưỡng chấp nhận được 7,50. Kết quả định lượng này phản ánh ba nhóm hạn chế kỹ thuật cơ bản của LLM trong lĩnh vực pháp luật, làm nền tảng lý luận cho việc áp dụng kiến trúc RAG:

Hạn chế 1 – Tri thức tham số bị đóng băng và có thể lỗi thời: Toàn bộ tri thức của LLM được mã hóa vào các tham số mô hình trong quá trình huấn luyện (parametric knowledge). Đối với lĩnh vực pháp luật – nơi các văn bản quy phạm pháp luật liên tục được cập nhật, bổ sung và thay thế – tri thức tham số nhanh chóng trở nên lỗi thời sau thời điểm khóa dữ liệu huấn luyện (training data cutoff). Một mô hình có thể không nhận biết rằng Nghị quyết 01/2024/NQ-HĐTP đã thay thế các hướng dẫn cũ, dẫn đến việc tư vấn dựa trên quy định không còn hiệu lực [4].

Hạn chế 2 – Không thể trích dẫn căn cứ pháp lý cụ thể và kiểm chứng được: Trong lĩnh vực pháp luật, một câu trả lời đúng về nội dung nhưng thiếu số hiệu điều luật cụ thể (ví dụ "theo Điều 55 Luật Hôn nhân và Gia đình 2014") không đáp ứng yêu cầu thực tiễn, vì người dùng cần căn cứ pháp lý để thực hiện quyền lợi hoặc giải trình trước cơ quan có thẩm quyền. LLM thuần túy sinh ra căn cứ pháp lý dựa trên phân phối xác suất học được từ dữ liệu huấn luyện, không có cơ chế tra cứu thực tế (grounding mechanism) để kiểm chứng tính chính xác, dẫn đến nguy cơ bịa đặt số hiệu điều luật – điều đặc biệt nguy hiểm trong bối cảnh tư vấn pháp lý [4].

Hạn chế 3 – Hiệu suất giảm mạnh với văn bản pháp luật tiếng Việt ít xuất hiện trong dữ liệu huấn luyện: Phần lớn các LLM lớn được huấn luyện chủ yếu trên dữ liệu tiếng Anh, với tiếng Việt chiếm tỷ lệ nhỏ hơn đáng kể. Văn bản pháp luật tiếng Việt – đặc biệt là các văn bản quy phạm pháp luật chuyên biệt như Luật Hôn nhân và Gia đình – càng ít xuất hiện hơn. Kết hợp với đặc điểm ngôn ngữ học đặc thù của tiếng Việt (đơn âm tiết, thanh điệu, từ ghép pháp lý), điều này dẫn đến chất lượng tư vấn pháp lý tiếng Việt của các LLM tổng quát thấp hơn đáng kể so với các tác vụ tiếng Anh cùng độ phức tạp [12].

Ba hạn chế trên cộng với hiện tượng ảo giác thông tin (Hallucination, mục 2.1.2) tạo thành luận cứ kỹ thuật vững chắc cho việc áp dụng kiến trúc RAG: bằng cách neo chặt đầu ra của LLM vào kho tri thức pháp lý đã kiểm chứng, RAG trực tiếp giải quyết cả ba hạn chế này – cung cấp tri thức cập nhật, cho phép trích dẫn căn cứ pháp lý cụ thể và đảm bảo tính chính xác với văn bản pháp luật tiếng Việt [3], [4].

2.2. KIẾN TRÚC SINH TĂNG CƯỜNG TRUY XUẤT (RETRIEVAL-AUGMENTED GENERATION – RAG)

2.2.1. Khái niệm và Nguyên lý hoạt động của RAG

Retrieval-Augmented Generation (RAG) là kiến trúc kết hợp module truy xuất thông tin (Retrieval) với module sinh ngôn ngữ (Generation), được Lewis và cộng sự giới thiệu lần đầu vào năm 2020 [4]. Khác với LLM thuần túy chỉ dựa vào kiến thức tham số, RAG bổ sung một bộ nhớ ngoài (non-parametric memory) dưới dạng kho văn bản được lập chỉ mục, cho phép mô hình truy xuất các đoạn văn bản liên quan theo thời gian thực và sử dụng chúng làm ngữ cảnh cho quá trình sinh câu trả lời.

Nguyên lý hoạt động cơ bản của RAG diễn ra theo ba bước tuần tự: (1) Encode – truy vấn của người dùng được mã hóa thành vector biểu diễn ngữ nghĩa; (2) Retrieve – hệ thống tìm kiếm trong kho văn bản các đoạn có độ tương đồng ngữ nghĩa cao nhất với vector truy vấn; và (3) Generate – LLM nhận đồng thời truy vấn gốc và các đoạn văn bản truy xuất được, từ đó sinh câu trả lời dựa trên ngữ cảnh thực tế.

Công trình REALM [3] của Guu và cộng sự đã đặt nền tảng lý thuyết quan trọng cho kiến trúc này bằng cách chứng minh rằng tích hợp truy xuất vào quá trình tiền huấn luyện giúp mô hình học cách sử dụng ngữ cảnh bên ngoài một cách hiệu quả. Kết quả thực nghiệm của RAG trong công bố gốc [4] cho thấy sự cải thiện đáng kể về tính thực tế và giảm thiểu hiện tượng ảo giác thông tin so với LLM thuần túy trong các tác vụ đòi hỏi kiến thức chuyên sâu.

2.2.2. Các hạn chế của RAG thông thường trong miền Pháp luật Tiếng Việt

Mặc dù RAG cơ bản cung cấp giải pháp nền tảng quan trọng, việc áp dụng trực tiếp vào lĩnh vực pháp luật tiếng Việt bộc lộ bốn nhóm hạn chế nghiêm trọng mà nghiên cứu này tập trung giải quyết:

- 1) Dễ bị tổn thương bởi truy vấn ngoài phạm vi (Out-of-Scope Vulnerability): Người dùng thường xuyên gửi câu hỏi không thuộc phạm vi chuyên môn của hệ thống (ví dụ: luật thuế, lập trình, nấu ăn). Hệ thống RAG thông thường vẫn tiến hành truy xuất tài liệu hôn nhân và gia đình, sau đó sinh ra câu trả lời nhầm lẫn, bịa đặt hoặc hoàn toàn không liên quan đến câu hỏi thực sự.
- 2) Khoảng cách Ngữ nghĩa giữa Ngôn ngữ Thông tục và Thuật ngữ Pháp lý (Colloquial Query-Corpus Mismatch): Người dân thường đặt câu hỏi bằng ngôn ngữ đời thường, giản dị (ví dụ: "ly hôn cần giấy tờ gì"), trong khi kho pháp lý sử dụng ngôn ngữ chính thức, thuật ngữ pháp luật chuyên biệt. Khoảng cách ngữ nghĩa này làm giảm đáng kể độ chính xác của cả hai phương pháp tìm kiếm ngữ nghĩa lẫn từ khóa [4].
- 3) Vấn đề Phân đoạn Từ ghép Tiếng Việt (Vietnamese Compound Word Segmentation): Tiếng Việt có đặc điểm ngôn ngữ học đặc thù: các từ ghép có nghĩa pháp lý quan trọng như "hôn nhân", "ly hôn", "cấp dưỡng" về mặt chữ

viết trông giống như tổ hợp các âm tiết đơn không có khoảng trắng phân cách (hôn, nhân). Các tokenizer tiếng Anh tiêu chuẩn như BM25 nếu không tích hợp bộ phân đoạn từ tiếng Việt sẽ xử lý sai các từ ghép này, dẫn đến kết quả tìm kiếm từ khóa không chính xác [12].

- 4) Phân cấp Thời gian Hiệu lực của Văn bản Pháp luật (Temporal Legal Hierarchy): Hệ thống pháp luật Việt Nam liên tục được cập nhật, bổ sung và thay thế. Các nghị quyết mới (ví dụ: Nghị quyết 01/2024/NQ-HĐTP) có thể vô hiệu hóa hoặc điều chỉnh các quy định trong luật gốc (Luật Hôn nhân và Gia đình 2014). RAG thông thường xử lý tất cả tài liệu như nhau về mặt thời gian, dẫn đến nguy cơ trả về các quy định đã hết hiệu lực [1].

2.3. CÁC KỸ THUẬT NỀN TẢNG CỦA KIẾN TRÚC RAG++

2.3.1. Tìm kiếm Ngữ nghĩa Dày đặc (Dense Semantic Retrieval) với FAISS

Tìm kiếm ngữ nghĩa dày đặc dựa trên việc mã hóa cả truy vấn lẫn tài liệu thành các vector biểu diễn dày đặc (dense vectors) trong không gian ngữ nghĩa chiều cao, sau đó tính toán độ tương đồng giữa các vector này. Phương pháp này cho phép tìm kiếm theo nghĩa thay vì chỉ theo từ khóa, khắc phục được nhược điểm của tìm kiếm thưa thớt khi người dùng diễn đạt cùng một ý nghĩa bằng các từ ngữ khác nhau.

Trong hệ thống RAG++, module này sử dụng mô hình intfloat/multilingual-e5-base [6] – một mô hình Sentence Transformer được huấn luyện theo phương pháp đối lập yếu giám sát (weakly-supervised contrastive learning) trên 1 tỷ cặp văn bản đa ngôn ngữ. Mô hình này mã hóa mỗi đoạn văn bản pháp lý thành vector 768 chiều, đạt hiệu suất tốt trên các ngôn ngữ châu Á trong đó có tiếng Việt [12].

Để hỗ trợ tìm kiếm tương đồng vector quy mô lớn với tốc độ cao, hệ thống sử dụng thư viện FAISS (Facebook AI Similarity Search) [5] của Johnson và cộng sự. FAISS cung cấp chỉ mục phẳng L2 (Flat L2 Index) cho phép tìm kiếm chính xác theo khoảng cách Euclidean, đảm bảo không bỏ sót bất kỳ tài liệu liên quan nào trong kho tri thức pháp lý có quy mô hợp lý. Với kho dữ liệu 505 đoạn văn bản, FAISS trả về Top-20 ứng viên dày đặc trong thời gian milisecond, đáp ứng yêu cầu tương tác thời gian thực [5].

2.3.2. Tìm kiếm Từ khóa Thưa thớt (Sparse Keyword Retrieval) với BM25 và PyVi ViTokenizer

Tìm kiếm thưa thớt (Sparse Retrieval) dựa trên sự khớp chính xác của các từ khóa giữa truy vấn và tài liệu. Thuật toán BM25 (Best Match 25) [2] của Robertson và Zaragoza là phương pháp tìm kiếm thưa thớt tiêu chuẩn trong thực tế, mở rộng mô hình TF-IDF cổ điển bằng cách tính đến độ bão hòa tần số từ và chuẩn hóa độ dài tài liệu. BM25 đặc biệt hiệu quả với các thuật ngữ pháp lý chuyên biệt – những từ có tần số xuất hiện cao trong bộ luật nhưng không thể nắm bắt chỉ bằng biểu diễn ngữ nghĩa.

Tuy nhiên, để BM25 hoạt động đúng với tiếng Việt, cần tích hợp bộ phân đoạn từ (word segmentation) chuyên biệt. PyVi ViTokenizer là thư viện phân đoạn từ tiếng Việt mã nguồn mở, sử dụng mô hình CRF (Conditional Random Field) được huấn luyện trên kho ngữ liệu tiếng Việt, có khả năng nhận diện và phân đoạn đúng các từ ghép pháp lý như "hôn_nhân", "ly_hôn", "cấp_dưỡng", "nuôi_con". Sau khi phân đoạn, BM25Okapi có thể khớp chính xác các cụm từ pháp lý quan trọng này với tài liệu trong kho, thay vì phân tách nhầm thành các âm tiết đơn lẻ không có nghĩa pháp lý [2].

2.3.3. Tìm kiếm Lai (Hybrid Retrieval) và Reciprocal Rank Fusion (RRF)

Tìm kiếm lai (Hybrid Retrieval) kết hợp đồng thời tìm kiếm ngữ nghĩa dày đặc và tìm kiếm từ khóa thưa thớt, tận dụng ưu điểm bổ trợ của cả hai phương pháp. Tìm kiếm dày đặc bắt được các trường hợp diễn đạt cùng ý nghĩa bằng từ ngữ khác nhau (paraphrase), trong khi tìm kiếm thưa thớt bảo đảm không bỏ sót tài liệu chứa đúng thuật ngữ pháp lý cần thiết. Các nghiên cứu thực nghiệm cho thấy tìm kiếm lai nhất quán vượt trội so với từng phương pháp đơn lẻ trong các tác vụ truy xuất thông tin pháp lý [2], [4].

Sau khi có hai danh sách ứng viên từ hai luồng tìm kiếm, thuật toán Reciprocal Rank Fusion (RRF) được sử dụng để hợp nhất kết quả. Điểm RRF của tài liệu d được tính như sau:

$$RRF_{Score(d \in D)} = \sum_{m \in M} \frac{1}{(k + r_{m(d)})}$$

trong đó $r_m(d)$ là vị trí xếp hạng của tài liệu d trong retriever m ; $k_0 = 60$ là hằng số làm trơn giúp giảm ảnh hưởng của các tài liệu xếp hạng quá cao; và $w_m = 1,5$ là trọng số ưu tiên cho từng retriever. Ưu điểm của RRF nằm ở chỗ nó dựa trên thứ hạng thay vì điểm số tuyệt đối, nên không bị ảnh hưởng bởi sự chênh lệch về thang điểm giữa tìm kiếm dày đặc (cosine similarity 0–1) và BM25 (điểm số không giới hạn trên)[18].

2.3.4. Thuật toán Suy giảm Thời gian (Temporal Decay Penalty)

Để giải quyết vấn đề phân cấp hiệu lực thời gian của văn bản pháp luật, hệ thống RAG++ tích hợp thuật toán Temporal Decay Penalty – một cơ chế điều chỉnh điểm truy xuất dựa trên độ mới của tài liệu. Điểm số cuối cùng của tài liệu được tính theo công thức:

$$Score_{final}(d) = Score_{RRF}(d) \times \max(0,01, 1,0 - (Y_{hiện tại} - Y_{tài liệu}) \times \lambda)$$

trong đó Y là năm ban hành văn bản và $\lambda = 0,20$ là hệ số suy giảm hàng năm. Với giá trị này, một văn bản ban hành năm 2024 (Nghị quyết 01/2024/NQ-HĐTP) nhận hệ số nhân 1,0; trong khi Luật Hôn nhân và Gia đình 2014 – được ban hành cách đây 10 năm – nhận hệ số nhân $\max(0,01; 1,0 - 10 \times 0,20) = 0,01$ [19]. Cơ chế này

đảm bảo rằng các nghị quyết, nghị định mới hơn luôn được ưu tiên trong các tình huống có quy định chồng chéo giữa văn bản mới và cũ [1].

2.3.5. Mô hình Tái xếp hạng Cross-Encoder (Cross-Encoder Reranker)

Sau giai đoạn Hybrid Retrieval và Temporal Decay, Top-15 tài liệu được đưa qua mô hình tái xếp hạng Cross-Encoder. Khác với mô hình Bi-Encoder (được dùng trong giai đoạn truy xuất ban đầu) xử lý truy vấn và tài liệu độc lập, Cross-Encoder nhận đồng thời cặp (truy vấn, tài liệu) và tính toán điểm liên quan thông qua cơ chế self-attention đầy đủ giữa hai văn bản.

Kiến trúc hai tầng (Bi-Encoder retrieval → Cross-Encoder reranking) là giải pháp thực tế tối ưu cho bài toán truy xuất pháp lý [4], [8]: giai đoạn đầu sử dụng Bi-Encoder nhanh để lọc từ hàng trăm tài liệu xuống còn Top-15, giai đoạn sau sử dụng Cross-Encoder chính xác hơn nhưng tốn tài nguyên hơn để chọn ra Top-5 tài liệu tốt nhất làm ngữ cảnh cho LLM. Cách tiếp cận này đảm bảo cả tốc độ phản hồi tương tác lẫn chất lượng ngữ cảnh cuối cùng.

2.3.6. Phân tích điểm yếu của từng kỹ thuật đơn lẻ – Lý luận cho kiến trúc kết hợp RAG++

Mục 2.3.1 đến 2.3.5 đã trình bày các kỹ thuật nền tảng theo hướng tích cực. Tuy nhiên, để dẫn dắt logic đến kiến trúc RAG++, cần phân tích rõ điểm yếu cố hữu của từng kỹ thuật khi hoạt động độc lập, làm căn cứ cho quyết định kết hợp trong mục 3.2. Bảng 2.1 dưới đây tổng hợp điểm mạnh và điểm yếu của từng kỹ thuật, đối chiếu với kết quả Ablation Study ở Chương 4.

Kỹ thuật	Ưu điểm chính	Điểm yếu cố hữu	Hệ quả trong miền pháp lý	Giải pháp trong RAG++
Dense Retrieval (FAISS + multilingual-e5)	Nắm bắt ngữ nghĩa tổng thể, xử lý tốt paraphrase, không bị ảnh hưởng bởi sai từ khóa	Bỏ sót các điều luật chứa thuật ngữ pháp lý chính xác nhưng không đồng nghĩa với truy vấn; Keyword Accuracy chỉ đạt 0,71 (C2)	Câu hỏi về "Điều 81" có thể bỏ sót tài liệu chứa đúng cụm "Điều 81" nếu vector ngữ nghĩa không đủ gần	Kết hợp với BM25 Sparse Retrieval qua RRF để bổ trợ
Sparse Retrieval (BM25 + PyVi)	Khớp chính xác thuật ngữ pháp lý và số hiệu điều luật;	Không nắm bắt được ngữ nghĩa: câu hỏi đòi thường	Tư vấn cho người dân sử dụng ngôn	Kết hợp với Dense Retrieval; bổ sung Query

ViTokenizer)	Keyword Accuracy đạt 0,76 (C3)	'muốn ly hôn thì làm gì' không khớp được với 'thủ tục chấm dứt hôn nhân'; điểm LLM Judge chỉ 6,64 (C3)	ngữ thông tục kém hiệu quả	Reformulation
Hybrid Retrieval (FAISS + BM25 + RRF)	Kết hợp ưu điểm cả hai; điểm LLM Judge 7,91 (C4), vượt ngưỡng 7,50	Vẫn không phân biệt được văn bản mới/cũ về thời gian hiệu lực; chưa lọc truy vấn ngoài phạm vi; chưa tinh chỉnh ngữ cảnh cấp câu	Có thể trả về quy định đã bị thay thế bởi nghị quyết mới; dễ bị tấn công bởi câu hỏi lạc chủ đề	Bổ sung OOS Detection, Temporal Decay và Cross-Encoder Reranking
Cross-Encoder Reranker	Đánh giá mức độ liên quan chính xác nhất; tương tác đầy đủ giữa query và document	Chi phí tính toán cao $O(n)$; không thể áp dụng trực tiếp lên toàn bộ kho dữ liệu	Không thể thay thế bước truy xuất ban đầu – chỉ phù hợp làm bước tinh chỉnh	Áp dụng ở bước cuối, sau khi đã lọc xuống Top-15 bằng Hybrid Retrieval
Temporal Decay Penalty	Ưu tiên văn bản mới hơn theo thời gian; phản ánh nguyên tắc 'luật mới thay luật cũ'	Tham số λ cần hiệu chỉnh thực nghiệm; có thể hạ thấp không hợp lý một số văn bản gốc vẫn còn hiệu lực	Nếu λ quá cao, một số điều luật gốc năm 2014 vẫn còn giá trị sẽ bị loại bỏ	Áp dụng hàm min sàn 0,01 để đảm bảo văn bản cũ vẫn có thể được truy xuất khi cần

Bảng 2. 1 Phân tích điểm mạnh, điểm yếu từng kỹ thuật và giải pháp tích hợp trong RAG++

Bảng 2.1 cho thấy rõ không có kỹ thuật đơn lẻ nào đủ để giải quyết toàn bộ thách thức của bài toán tư vấn pháp lý tiếng Việt. Dense Retrieval mạnh về ngữ nghĩa nhưng yếu về khớp thuật ngữ; BM25 mạnh về thuật ngữ nhưng yếu về ngữ nghĩa; Cross-Encoder chính xác nhưng không thể mở rộng; Temporal Decay giải quyết phân cấp thời gian nhưng cần tham số hiệu chỉnh cẩn thận. Kiến trúc RAG++ được đề xuất chính là giải pháp tích hợp có hệ thống của các kỹ thuật này, với mỗi

thành phần giải quyết điểm yếu của thành phần khác, tạo thành một pipeline xử lý hoàn chỉnh và bổ trợ lẫn nhau. Bảng chứng định lượng cho nhận định này được cung cấp bởi Ablation Study trong Chương 4: điểm LLM Judge tăng tích lũy từ 4,71 (C1 – không có RAG) lên 7,91 (C4 – Hybrid Retrieval) và đạt đỉnh 8,22 (C5 – RAG++ hoàn chỉnh với tất cả sáu tầng can thiệp).

2.4. XỬ LÝ NGÔN NGỮ TỰ NHIÊN TIẾNG VIỆT TRONG NGỮ CẢNH PHÁP LÝ

2.4.1. Đặc điểm Ngôn ngữ học Tiếng Việt và Thách thức Xử lý

Tiếng Việt là ngôn ngữ đơn âm tiết có thanh điệu, trong đó mỗi âm tiết được viết như một đơn vị độc lập không có khoảng trắng phân cách với các âm tiết cùng từ ghép. Đặc điểm này tạo ra thách thức đặc thù trong xử lý ngôn ngữ tự nhiên: để biết một chuỗi âm tiết tạo thành một từ hay nhiều từ, cần có ngữ cảnh và từ điển từ ghép chuyên biệt. Trong lĩnh vực pháp luật, nhầm lẫn trong phân đoạn từ trực tiếp ảnh hưởng đến độ chính xác của tìm kiếm và phân tích văn bản.

Ví dụ minh họa điển hình: chuỗi "hôn nhân" (marriage) nếu không phân đoạn đúng sẽ bị xử lý như hai âm tiết riêng biệt "hôn" và "nhân" – vốn là các từ đơn có nghĩa khác nhau hoàn toàn. Tương tự, "ly hôn" (divorce), "cấp dưỡng" (alimony), "nuôi con" (child custody) đều là các từ ghép pháp lý quan trọng cần được xử lý đúng. PyVi ViTokenizer được lựa chọn trong hệ thống RAG++ chính vì khả năng nhận diện chính xác các từ ghép này, đặc biệt trong ngữ cảnh văn bản pháp luật [12].

2.4.2. PhoBERT và Mô hình Ngôn ngữ Tiếng Việt

Bước ngoặt quan trọng trong xử lý ngôn ngữ tự nhiên tiếng Việt là sự ra đời của PhoBERT [12] – mô hình BERT tiền huấn luyện chuyên biệt cho tiếng Việt, được Nguyen và cộng sự giới thiệu vào năm 2020. PhoBERT được huấn luyện trên kho ngữ liệu tiếng Việt quy mô lớn gồm 20GB văn bản từ Wikipedia và tin tức, sử dụng kiến trúc RoBERTa với bộ từ vựng theo đơn vị phân đoạn từ phụ (sub-word tokenization).

Tuy nhiên, trong hệ thống RAG++, chúng tôi sử dụng mô hình intfloat/multilingual-e5-base [6] thay vì PhoBERT do yêu cầu đặc thù của bài toán: cần một mô hình sinh vector biểu diễn câu (sentence embedding) có khả năng so sánh ngữ nghĩa giữa câu hỏi tiếng Việt của người dùng và đoạn văn bản pháp lý, trong không gian embedding thông nhất. Multilingual-e5-base được tối ưu hóa chính xác cho tác vụ này thông qua huấn luyện đối lập trên 1 tỷ cặp câu đa ngôn ngữ [6], phù hợp với thực tế người dùng có thể đặt câu hỏi bằng cả tiếng Việt phổ thông lẫn tiếng Việt có xen tiếng Anh chuyên ngành.

2.5. ĐÁNH GIÁ HỆ THỐNG RAG VÀ LLM-AS-A-JUDGE

2.5.1. Các Phương pháp Đánh giá RAG Truyền thống

Việc đánh giá chất lượng hệ thống RAG trong lĩnh vực pháp lý đặt ra những thách thức phương pháp luận quan trọng. Các chỉ số đánh giá truyền thống như BLEU và ROUGE, vốn được thiết kế cho tác vụ dịch thuật và tóm tắt, không phù hợp cho đánh giá pháp lý vì: (1) câu trả lời pháp lý đúng có thể được diễn đạt theo nhiều cách khác nhau mà BLEU/ROUGE đều đánh giá thấp; (2) BLEU/ROUGE không phân biệt được câu trả lời sai về điều luật nhưng đúng về từ ngữ [9].

Chỉ số Keyword Accuracy – đo tỷ lệ từ khóa pháp lý chuẩn có mặt trong câu trả lời – là một phương pháp định lượng đơn giản nhưng hiệu quả để đánh giá mức độ bao phủ khái niệm pháp lý. Chỉ số này được tính theo công thức:

$$\text{Keyword_Accuracy} = \frac{|\{kw \in \text{"Keywords_GT"} \mid kw \in \text{"Answer"}\}|}{|\text{"Keywords_GT"}|}$$

trong đó Keywords_GT là tập từ khóa pháp lý chuẩn (ground truth) được chú thích cho từng tình huống đánh giá, và Answer là câu trả lời được sinh ra bởi hệ thống[9].

2.5.2. Khung Đánh giá RAGAS và LLM-as-a-Judge

Paradigm LLM-as-a-Judge sử dụng chính các LLM mạnh như một giám khảo tự động để đánh giá chất lượng câu trả lời, thay thế cho việc đánh giá thủ công bởi chuyên gia con người. Phương pháp này cho thấy tương quan cao với đánh giá chuyên gia trong nhiều lĩnh vực chuyên môn, đặc biệt khi được thiết kế với tiêu chí đánh giá rõ ràng và chi tiết.

Khung RAGAS [7] của Es và cộng sự áp dụng nguyên lý LLM-as-a-Judge vào đánh giá RAG thông qua bốn chiều đánh giá tự động: Faithfulness (tính trung thực với ngữ cảnh truy xuất), Answer Relevance (mức độ liên quan của câu trả lời), Context Precision (độ chính xác của ngữ cảnh) và Context Recall (độ bao phủ của ngữ cảnh). Self-RAG [8] tiến xa hơn bằng cách tích hợp cơ chế tự đánh giá vào chính quá trình sinh câu trả lời của mô hình.

Hệ thống RAG++ áp dụng và mở rộng khung LLM-as-a-Judge với năm tiêu chí đánh giá được thiết kế riêng cho bài toán pháp lý tiếng Việt: (1) Tính thực tế – Factuality, (2) Tính đầy đủ – Completeness, (3) Tính mạch lạc logic – Logical Coherence, (4) Tính rõ ràng dễ hiểu – Clarity, và (5) Mức độ liên quan câu trả lời – Answer Relevance. Mỗi tiêu chí được chấm điểm từ 1 đến 10, với điểm chuẩn 7.5 được hiệu chỉnh tương đương năng lực của một luật sư hành nghề có chuyên môn.

2.5.3. Chuẩn đánh giá LexRAG cho Hệ thống Hỏi-Đáp Pháp lý

Chuẩn đánh giá LexRAG [9] của Li và cộng sự đề xuất một khung đánh giá chuyên biệt cho hệ thống Hỏi-Đáp pháp lý đa lượt hội thoại, nhấn mạnh tầm quan trọng của độ chính xác trích dẫn điều luật và khả năng xử lý các câu hỏi pháp lý

phức tạp liên quan đến nhiều điều khoản. LexRAG thừa nhận rằng trong lĩnh vực pháp lý, một câu trả lời đúng về nội dung nhưng sai về số điều luật vẫn được coi là câu trả lời không chấp nhận được, vì người dùng cần căn cứ pháp lý chính xác để thực hiện quyền lợi của mình.

Nghiên cứu này kế thừa tinh thần của LexRAG [9] nhưng điều chỉnh phù hợp với đặc thù tiếng Việt và bài toán tư vấn pháp lý hôn nhân gia đình: thay vì chỉ kiểm tra trích dẫn điều luật thuần túy, khung đánh giá LexRAG++ mở rộng sang đánh giá toàn diện chất lượng lập luận pháp lý, tính thiết thực của hướng dẫn hành động và sự rõ ràng trong diễn đạt cho đối tượng phi chuyên.

2.6. TỔNG QUAN CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN

2.6.1. Nghiên cứu về Hệ thống Hỏi-Đáp Pháp lý

Hỏi-Đáp pháp lý (Legal Question Answering – Legal QA) là lĩnh vực nghiên cứu AI ứng dụng có lịch sử phát triển lâu dài, từ các hệ thống lập luận dựa trên logic hình thức và bản thể học (ontological reasoning), đến các hệ thống truy xuất thần kinh (neural retrievers) hiện đại. Các thách thức đặc thù của lĩnh vực bao gồm: tính chính xác cao của trích dẫn nguồn pháp lý, khả năng lập luận đa bước với nhiều điều khoản liên quan, và yêu cầu giải thích ngôn ngữ pháp luật cho người dùng phổ thông.

Trong bối cảnh tiếng Việt, đến nay chưa có công trình nào xây dựng hệ thống Legal QA toàn diện cho Luật Hôn nhân và Gia đình với các thành phần nâng cao như: tự động lọc truy vấn ngoài phạm vi, cải viết truy vấn sang ngôn ngữ pháp lý, tìm kiếm lai với phân đoạn từ tiếng Việt, và thuật toán ưu tiên văn bản theo thời gian hiệu lực.

2.6.2. Hệ thống Chatbot Kinh tế Tiếng Việt GVEC – Bài học Kinh nghiệm

Nhóm nghiên cứu của Ngo-Ho và cộng sự [14], [15], [16] đã phát triển hệ thống GVEC (Generative Vietnamese Economy Chatbot) – chatbot tư vấn kinh tế tiếng Việt ứng dụng kiến trúc RAG kết hợp cơ sở dữ liệu thông tin kinh tế VEID từ cộng đồng Vneconomy. Bộ benchmark VNEIQAD [15] và chỉ số đánh giá EMINI (Exact Match with Numeric Information) [17] được phát triển để đánh giá chất lượng các câu hỏi-đáp chứa thông tin số liệu kinh tế.

Các công trình GVEC cung cấp nền tảng phương pháp luận quan trọng cho nghiên cứu này, đặc biệt về: xây dựng bộ benchmark tổng hợp cho tiếng Việt, phương pháp đánh giá LLM đa tiêu chí trong miền chuyên biệt tiếng Việt, và thiết kế pipeline RAG theo đặc thù dữ liệu tiếng Việt. Tuy nhiên, miền pháp luật đặt ra những thách thức kỹ thuật khác biệt so với miền kinh tế: yêu cầu trích dẫn điều luật chính xác, xử lý tính phân cấp thời gian hiệu lực văn bản, và cơ chế phòng chống ảo giác thông tin trong môi trường có rủi ro pháp lý cao [16].

2.6.3. Nghiên cứu về Chiến lược Truy xuất Nâng cao

Công trình của Akarsu và cộng sự [13] cung cấp một benchmark toàn diện so sánh các chiến lược truy xuất từ BM25 thuần túy đến Corrective RAG trên tập dữ liệu chứa cả văn bản và bảng biểu. Nghiên cứu này xác nhận rằng các chiến lược truy xuất thích nghi (adaptive retrieval) vượt trội so với phương pháp truy xuất cố định, đặc biệt với dữ liệu có cấu trúc phức tạp – điều này phù hợp với kho dữ liệu pháp lý vốn chứa nhiều bảng biểu quy định và danh sách điều khoản.

Kết quả của Akarsu và cộng sự [13] củng cố quyết định thiết kế của hệ thống RAG++ trong việc kết hợp Hybrid Search (dense + sparse) với Cross-Encoder Reranking và Temporal Decay Penalty, thay vì chỉ đơn giản áp dụng một chiến lược truy xuất cố định.

2.6.4. Tổng hợp Khoảng trống Nghiên cứu

Qua phân tích tổng quan tài liệu, có thể xác định rõ khoảng trống nghiên cứu mà RAG++ hướng đến lấp đầy. Không có nghiên cứu nào trước đây trong lĩnh vực pháp luật tiếng Việt đồng thời giải quyết được cả bốn thách thức: lọc truy vấn ngoài phạm vi (Out-of-Scope Classification), cải viết truy vấn thông tục sang ngôn ngữ pháp lý (Query Reformulation), tìm kiếm lai với phân đoạn từ tiếng Việt (Hybrid Search + PyVi), và ưu tiên văn bản theo thời gian hiệu lực (Temporal Decay Penalty). Hơn nữa, chưa có công trình nào xây dựng bộ benchmark đánh giá chuyên biệt cho Luật Hôn nhân và Gia đình tiếng Việt với phương pháp LLM-as-a-Judge đa tiêu chí.

2.6.5. Bảng so sánh tổng hợp các công trình liên quan và vị trí của RAG++

Để làm rõ hơn khoảng trống nghiên cứu mà RAG++ lấp đầy, Bảng 2.2 dưới đây đặt hệ thống đề xuất trong tương quan trực tiếp với các công trình tiêu biểu trong và ngoài nước theo sáu tiêu chí kỹ thuật đặc thù của miền pháp luật tiếng Việt.

Nghiên cứu / Hệ thống	Lọc OOS	Cải viết truy vấn	Hybrid Retrieval	Temporal Decay	Tiếng Việt pháp lý	Đánh giá đa tiêu chí
RAG gốc – Lewis et al. [4] (2020)	Không	Không	Không	Không	Không	Không
Self-RAG – Asai et al. [8] (2023)	Không	Không	Không	Không	Không	Một phần
LexRAG – Li et al. [9] (2024)	Không	Một phần	Không	Không	Không (tiếng Anh)	Có

RAG++ – Luận văn này (2026)	Có	Có	Có	Có	Có	Có
-----------------------------------	----	----	----	----	----	----

Bảng 2. 2 So sánh RAG++ với các công trình liên quan theo sáu tiêu chí đặc thù của miền pháp luật tiếng Việt

Bảng 2.2 cho thấy RAG++ là hệ thống duy nhất đồng thời đáp ứng cả sáu tiêu chí kỹ thuật đặc thù của miền pháp luật tiếng Việt. Trong khi các nghiên cứu quốc tế như Self-RAG [8] và LexRAG [9] giải quyết tốt bài toán pháp lý nhưng không được thiết kế cho tiếng Việt và không tích hợp cơ chế lọc OOS hay phân cấp thời gian hiệu lực văn bản, thì kiến trúc RAG++ được đề xuất trong luận văn lấp đầy khoảng trống này bằng một framework tích hợp toàn diện, được kiểm chứng định lượng qua Ablation Study có kiểm soát chặt chẽ.

2.7. CƠ SỞ PHÁP LÝ: LUẬT HÔN NHÂN VÀ GIA ĐÌNH VIỆT NAM

2.7.1. Tổng quan Hệ thống Văn bản Pháp luật

Kho tri thức pháp lý của hệ thống RAG++ được xây dựng dựa trên hai văn bản quy phạm pháp luật cốt lõi có hiệu lực tại thời điểm nghiên cứu:

Luật Hôn nhân và Gia đình năm 2014 (Luật số 52/2014/QH13) [1]: Được Quốc hội nước Cộng hòa xã hội chủ nghĩa Việt Nam thông qua ngày 19 tháng 6 năm 2014, có hiệu lực từ ngày 01 tháng 01 năm 2015. Đây là văn bản pháp luật nền tảng điều chỉnh toàn diện các quan hệ hôn nhân và gia đình tại Việt Nam, bao gồm: điều kiện kết hôn và thủ tục đăng ký kết hôn (Chương II), quyền và nghĩa vụ giữa vợ và chồng (Chương III), chế độ tài sản vợ chồng (Chương IV), thủ tục và điều kiện ly hôn (Chương V), quyền nuôi con và nghĩa vụ cấp dưỡng sau ly hôn (Chương VII).

Nghị quyết 01/2024/NQ-HĐTP của Hội đồng Thẩm phán Tòa án nhân dân tối cao: Văn bản hướng dẫn thi hành các quy định của Luật số 52/2014/QH13, cập nhật các hướng dẫn xét xử mới nhất về phân chia tài sản chung, xác định tài sản riêng và thủ tục giải quyết tranh chấp. Văn bản này có hiệu lực từ năm 2024, thay thế một số hướng dẫn cũ và bổ sung các quy định phù hợp với thực tiễn xét xử hiện đại.

2.7.2. Nhu cầu Tiếp cận Thông tin Pháp luật Hôn nhân và Gia đình

Theo đặc điểm địa bàn nghiên cứu, người dân tại khu vực Đồng bằng sông Cửu Long – trong đó có địa bàn tỉnh Cần Thơ nơi Trường Đại học Nam Cần Thơ tọa lạc – đối mặt với khoảng cách lớn trong tiếp cận dịch vụ tư vấn pháp lý chuyên nghiệp về hôn nhân và gia đình. Chi phí tư vấn luật sư thường vượt quá khả năng tài chính của nhiều hộ gia đình, trong khi các thủ tục pháp lý về ly hôn, phân chia tài sản hay quyền nuôi con đòi hỏi hiểu biết pháp luật chính xác để bảo vệ quyền lợi hợp pháp.

Nguồn thông tin pháp lý trực tuyến chính thức như Thuvienphapluat.vn [11] cung cấp toàn bộ văn bản pháp luật dưới dạng số, nhưng chỉ dừng lại ở tra cứu văn bản thô mà không cung cấp diễn giải ngữ cảnh, phân tích tình huống cụ thể hay hướng dẫn hành động thực tiễn. Đây chính là khoảng trống thiết yếu mà hệ thống RAG++ hướng đến giải quyết: cung cấp công cụ tra cứu pháp lý thông minh, có khả năng diễn giải điều luật và đưa ra hướng dẫn hành động cụ thể cho từng tình huống của người dùng, dựa trên căn cứ pháp lý được trích dẫn minh bạch [1], [11].

2.8. TỔNG KẾT CHƯƠNG

Chương 2 đã trình bày hệ thống cơ sở lý luận và tổng quan nghiên cứu đầy đủ làm nền tảng cho kiến trúc RAG++ được đề xuất trong luận văn. Các nội dung lý thuyết cốt lõi được trình bày bao gồm:

- (1) Mô hình Ngôn ngữ Lớn (LLM): khái niệm, kiến trúc Transformer và vấn đề ảo giác thông tin – nguyên nhân căn bản dẫn đến sự cần thiết của kiến trúc RAG trong ứng dụng pháp lý [4].
- (2) Kiến trúc RAG cơ bản [3], [4]: nguyên lý hoạt động ba bước Encode–Retrieve–Generate và bốn hạn chế cốt lõi khi áp dụng trực tiếp vào lĩnh vực pháp luật tiếng Việt.
- (3) Các kỹ thuật nền tảng của RAG++: tìm kiếm ngữ nghĩa dày đặc với FAISS [5] và multilingual-e5-base [6]; tìm kiếm từ khóa thưa thớt với BM25 [2] và PyVi ViTokenizer; hợp nhất kết quả bằng RRF; ưu tiên văn bản bằng Temporal Decay Penalty [19]; và tái xếp hạng với Cross-Encoder.
- (4) Xử lý ngôn ngữ tự nhiên tiếng Việt [12]: đặc điểm đơn âm tiết, thách thức phân đoạn từ ghép pháp lý và các mô hình ngôn ngữ tiền huấn luyện tiếng Việt.
- (5) Khung đánh giá hệ thống RAG: RAGAS [7], Self-RAG [8], LexRAG [9] và phương pháp LLM-as-a-Judge, làm cơ sở cho khung đánh giá LexRAG++ được phát triển trong nghiên cứu này.
- (6) Tổng quan các công trình liên quan [13], [14], [15], [16], [17]: xác định rõ khoảng trống nghiên cứu và đóng góp kỹ thuật của RAG++ so với các giải pháp hiện có.

CHƯƠNG 3

PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ HỆ THỐNG

3.1 GIỚI THIỆU CHUNG

Chương 3 là chương trung tâm của luận văn, trình bày toàn bộ phương pháp nghiên cứu và thiết kế chi tiết hệ thống RAG++. Nội dung chương được tổ chức logic theo luồng nghiên cứu và triển khai thực tế của hệ thống, bao gồm các nội dung cốt lõi sau:

- Mục 3.2 – Tổng quan kiến trúc hệ thống RAG++: Giới thiệu về phương pháp nghiên cứu thiết kế – phát triển hệ thống (DDR) kết hợp thực nghiệm định lượng, cùng sơ đồ kiến trúc tổng thể của giải pháp RAG++.
- Mục 3.3 – Pipeline số hóa và xây dựng kho tri thức pháp lý (Offline Knowledge Ingestion Pipeline): Đi sâu vào quy trình xử lý theo lô bao gồm bóc tách văn bản quy phạm pháp luật, kỹ thuật phân đoạn theo ranh giới điều luật tự nhiên (Article-Boundary Chunking) và cơ chế lập chỉ mục song song (FAISS Dense Index và BM25 Sparse Index).
- Mục 3.4 – Pipeline xử lý truy vấn pháp lý thời gian thực (Online Legal Consultation Pipeline): Mô tả chi tiết luồng xử lý trực tuyến qua 8 thành phần kỹ thuật nâng cao từ bộ lọc ngoài phạm vi (OOS Classifier), cải viết câu hỏi (Query Reformulation) đến tìm kiếm lai và tái xếp hạng.
- Mục 3.5 – Công cụ, ngôn ngữ lập trình và môi trường phát triển: Tổng hợp hệ sinh thái công nghệ, thư viện (FastAPI, FAISS, PyVi, OpenRouter API...) phục vụ hiện thực hóa hệ thống.
- Mục 3.6 – Hệ thống đánh giá chất lượng tự động LexRAG++: Trình bày kiến trúc đánh giá bất đồng bộ, quy trình chấm điểm 5 tiêu chí dựa trên Giám khảo AI (LLM-as-a-Judge) và phương pháp xây dựng bộ dữ liệu Benchmark 351 tình huống pháp lý.
- Mục 3.7 – Thiết kế kiến trúc phần mềm tổng thể: Chi tiết hóa thiết kế phân tầng của Backend FastAPI, cấu trúc cơ sở dữ liệu lai (Hybrid Storage), hệ thống xác thực phân quyền JWT và các màn hình giao diện Frontend (Chatweb, Admin Dashboard).
- Mục 3.8 – Tổng kết chương: Tóm lược lại các đóng góp thiết kế cốt lõi của Chương 3 làm tiền đề cho việc triển khai và đánh giá thực nghiệm ở chương tiếp theo.

3.2. TỔNG QUAN KIẾN TRÚC HỆ THỐNG RAG++

3.2.1 Phương pháp nghiên cứu

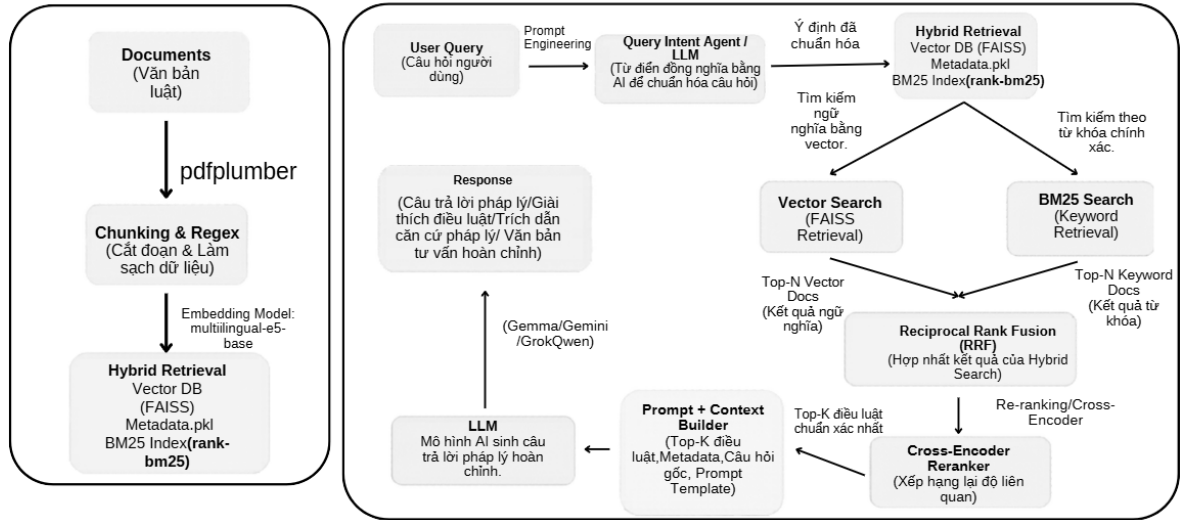
Luận văn áp dụng phương pháp nghiên cứu thiết kế và phát triển hệ thống (Design and Development Research – DDR) kết hợp với phương pháp thực nghiệm định lượng (Quantitative Experimental Method). Cụ thể, quy trình nghiên cứu được thực hiện theo vòng lặp năm bước:

- (1) Phân tích yêu cầu: Xác định bốn thách thức kỹ thuật đặc thù của miền pháp luật tiếng Việt (OOS Vulnerability, Colloquial-Legal Mismatch, Compound Word Segmentation, Temporal Hierarchy) từ phân tích tài liệu học thuật và khảo sát thực tế nhu cầu người dùng tại khu vực Đồng bằng sông Cửu Long.
- (2) Thiết kế kiến trúc: Thiết kế kiến trúc RAG++ với các thành phần nâng cao nhằm giải quyết từng thách thức đã xác định, trình bày chi tiết trong Mục 3.3 và 3.4.
- (3) Triển khai: Lập trình và triển khai hệ thống bằng Python 3.12, FastAPI và các thư viện mã nguồn mở chuyên biệt cho NLP và vector search.
- (4) Đánh giá thực nghiệm: Kiểm định hệ thống trên bộ Benchmark 351 tình huống pháp lý phức tạp theo khung LexRAG++ và Ablation Study năm cấu hình kiến trúc.
- (5) Phân tích và rút ra kết luận: Phân tích kết quả thực nghiệm, xác định đóng góp của từng thành phần và đề xuất hướng phát triển tiếp theo.

3.2.2 Kiến trúc tổng thể hệ thống RAG++

Trên cơ sở khung lý thuyết về Mô hình Ngôn ngữ Lớn, kiến trúc Sinh tăng cường truy xuất (RAG) cơ bản và bốn nhóm hạn chế cốt lõi khi áp dụng trực tiếp vào miền pháp luật tiếng Việt đã được phân tích ở Chương 2, Chương 3 trình bày chi tiết phương pháp nghiên cứu và thiết kế kiến trúc hệ thống RAG++ (Retrieval-Augmented Generation Plus Plus) – giải pháp kỹ thuật trung tâm của luận văn. Nguyên tắc thiết kế xuyên suốt của RAG++ là can thiệp toàn diện vào cả ba giai đoạn xử lý dữ liệu của một hệ thống RAG: giai đoạn tiền truy xuất (pre-retrieval), giai đoạn truy xuất (retrieval) và giai đoạn hậu truy xuất (post-retrieval), thay vì chỉ tối ưu hóa một thành phần đơn lẻ như các nghiên cứu RAG thông thường [4].

Về mặt tổ chức, kiến trúc RAG++ được phân tách thành hai pipeline độc lập về thời điểm thực thi nhưng liên kết chặt chẽ với nhau qua một kho tri thức dùng chung (shared knowledge base): (1) Pipeline số hóa và xây dựng kho tri thức pháp lý (Offline Knowledge Ingestion Pipeline) – thực thi theo lô (batch) một lần khi khởi tạo hoặc cập nhật hệ thống, có nhiệm vụ chuyển đổi các văn bản quy phạm pháp luật dạng PDF thô thành kho dữ liệu có cấu trúc, được lập chỉ mục song song trên hai cơ sở dữ liệu vector và từ khóa; và (2) Pipeline xử lý truy vấn pháp lý thời gian thực (Online Legal Consultation Pipeline) – thực thi theo từng yêu cầu (request) của người dùng, có nhiệm vụ tiếp nhận câu hỏi, phân loại, cải viết, truy xuất, hợp nhất, tái xếp hạng và sinh câu trả lời tư vấn pháp lý có căn cứ trích dẫn minh bạch.



Hình 3. 1 Sơ đồ tổng quan kiến trúc hệ thống RAG++ – Pipeline số hóa kho tri thức (bên trái) và Pipeline xử lý truy vấn pháp lý thời gian thực (bên phải)

Hình 3.1 minh họa toàn cảnh kiến trúc hệ thống. Ở nhánh bên trái (giai đoạn Offline), các văn bản pháp luật gốc được trích xuất bằng pdfplumber [10], phân đoạn theo ranh giới điều luật bằng kỹ thuật Article-Boundary Chunking, sau đó mỗi đoạn được mã hóa thành vector ngữ nghĩa 768 chiều bằng mô hình multilingual-e5-base [6] và đồng thời được phân đoạn từ bằng PyVi ViTokenizer để nạp vào chỉ mục BM25Okapi [2]. Kết quả của giai đoạn này là cặp chỉ mục lai (FAISS Index + BM25 Index) cùng kho siêu dữ liệu (metadata) mô tả trạng thái hiệu lực của từng điều luật. Ở nhánh bên phải (giai đoạn Online), mỗi truy vấn của người dùng được xử lý tuần tự qua tám bước: phân loại phạm vi, cải viết truy vấn, tìm kiếm lai song song, hợp nhất RRF, suy giảm thời gian, tái xếp hạng Cross-Encoder, xây dựng prompt và sinh câu trả lời bằng LLM, có hỗ trợ cơ chế xoay vòng khóa API để đảm bảo vận hành liên tục.

Thiết kế của RAG++ tuân theo nguyên tắc mỗi thành phần kỹ thuật được bổ sung nhằm giải quyết trực tiếp một hoặc nhiều hạn chế đã được xác định của kiến trúc RAG thông thường trong miền pháp luật tiếng Việt. Bảng 3.1 tổng hợp mối tương quan giữa bốn nhóm hạn chế nền tảng (đã trình bày tại mục 2.2.2) và các thành phần kỹ thuật tương ứng được tích hợp trong kiến trúc RAG++, qua đó thể hiện tính hệ thống và mục đích thiết kế rõ ràng của từng module.

Hạn chế của RAG thông thường (Chương 2)	Thành phần kỹ thuật giải quyết trong RAG++ (Chương 3)
Dễ bị tổn thương bởi truy vấn ngoài phạm vi (Out-of-Scope Vulnerability)	Bộ phân loại truy vấn ngoài phạm vi (Out-of-Scope Classifier) – mục 3.3.1
Khoảng cách ngữ nghĩa	Mô-đun cải viết truy vấn pháp lý (Query Reformulation

giữa ngôn ngữ thông tục và thuật ngữ pháp lý (Colloquial Query-Corpus Mismatch)	Module) – mục 3.3.2
Vấn đề phân đoạn từ ghép tiếng Việt (Vietnamese Compound Word Segmentation)	PyVi ViTokenizer kết hợp BM25Okapi trong tìm kiếm thừa thớt – mục 3.2.3 và 3.3.3
Phân cấp thời gian hiệu lực của văn bản pháp luật (Temporal Legal Hierarchy)	Thuật toán suy giảm thời gian (Temporal Decay Penalty) kết hợp Metadata Filtering – mục 3.3.5

Bảng 3. 1 Tương quan giữa các hạn chế của RAG thông thường và thành phần giải quyết trong RAG++

Phần còn lại của chương được tổ chức như sau: mục 3.2 trình bày chi tiết Pipeline số hóa và xây dựng kho tri thức pháp lý; mục 3.3 trình bày chi tiết Pipeline xử lý truy vấn pháp lý thời gian thực với tám thành phần kỹ thuật cấu thành; mục 3.4 mô tả công cụ, ngôn ngữ lập trình và môi trường phát triển được sử dụng để hiện thực hóa toàn bộ kiến trúc

3.3. PIPELINE SỐ HÓA VÀ XÂY DỰNG KHO TRI THỨC PHÁP LÝ (OFFLINE KNOWLEDGE INGESTION PIPELINE)

Pipeline số hóa và xây dựng kho tri thức pháp lý là giai đoạn nền tảng, được thực thi theo phương thức xử lý theo lô (batch processing) một lần trước khi hệ thống được đưa vào vận hành, hoặc được thực thi lại mỗi khi kho văn bản pháp luật gốc được cập nhật, bổ sung văn bản hướng dẫn mới. Mục tiêu cốt lõi của pipeline là chuyển đổi các văn bản quy phạm pháp luật dạng PDF phi cấu trúc thành một kho tri thức có cấu trúc, được lập chỉ mục song song trên hai cơ sở dữ liệu hỗ trợ cho nhau: cơ sở dữ liệu vector ngữ nghĩa (FAISS) và cơ sở dữ liệu từ khóa (BM25). Pipeline gồm ba giai đoạn xử lý tuần tự: (1) Thu thập và trích xuất văn bản pháp luật, (2) Phân đoạn văn bản theo ranh giới điều luật (Article-Boundary Chunking), và (3) Sinh embedding đa ngôn ngữ và lập chỉ mục song song.

3.3.1. Thu thập và Trích xuất Văn bản Pháp luật (Document Acquisition)

Kho tri thức pháp lý của hệ thống RAG++ được xây dựng dựa trên hai văn bản quy phạm pháp luật cốt lõi có hiệu lực tại thời điểm thực hiện nghiên cứu: Luật Hôn nhân và Gia đình năm 2014 (Luật số 52/2014/QH13) [1] – văn bản pháp luật nền tảng điều chỉnh toàn diện các quan hệ hôn nhân và gia đình tại Việt Nam, và Nghị quyết 01/2024/NQ-HĐTP của Hội đồng Thẩm phán Tòa án nhân dân tối cao – văn bản hướng dẫn thi hành cập nhật các quy định mới nhất về phân chia tài sản, xác định tài sản riêng và thủ tục giải quyết tranh chấp. Ngoài hai văn bản gốc này, kho tri thức còn được bổ sung tham chiếu đối chiếu từ cổng thông tin Thuvienphapluat.vn [11] – hệ thống văn bản pháp luật trực tuyến chính thống của

Việt Nam, nhằm bảo đảm tính cập nhật và chính xác về trạng thái hiệu lực của từng điều khoản.

Quá trình trích xuất văn bản thô được thực hiện bằng thư viện pdfplumber [10] – một thư viện mã nguồn mở Python chuyên dụng cho việc phân tích cấu trúc tài liệu PDF ở mức trang (page-level) và mức ký tự (character-level). pdfplumber được lựa chọn thay cho các thư viện trích xuất PDF thông dụng khác vì khả năng bảo toàn chính xác các dấu thanh và dấu phụ của tiếng Việt (dấu sắc, huyền, hỏi, ngã, nặng), cũng như khả năng giữ nguyên cấu trúc xuống dòng của từng điều, khoản, điểm trong văn bản luật – yếu tố quan trọng để bước phân đoạn theo ranh giới điều luật ở mục 3.2.2 có thể hoạt động chính xác.

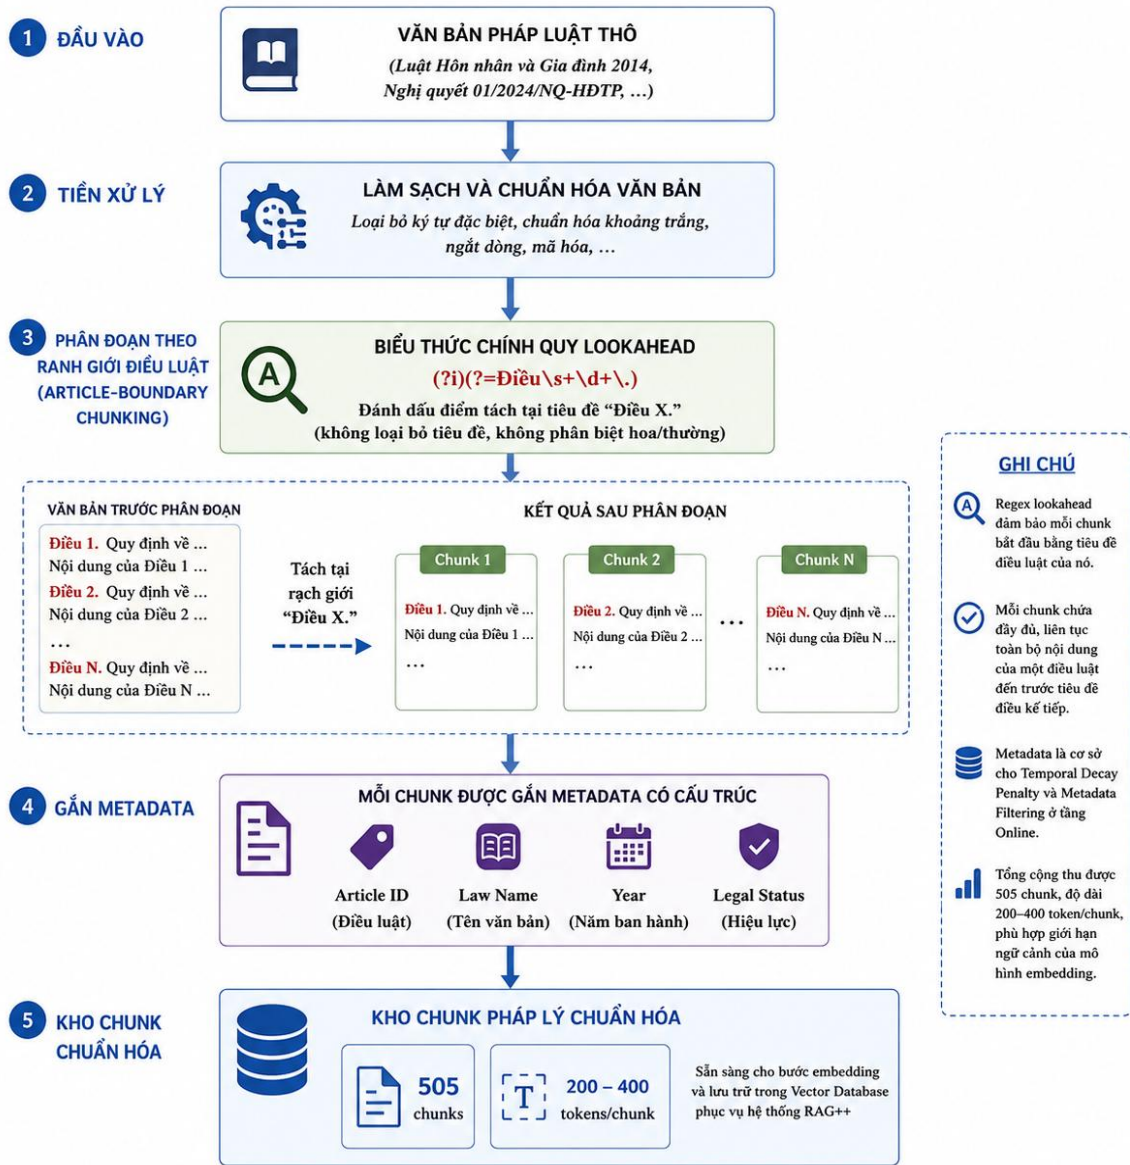
Sau khi trích xuất, văn bản thô được đưa qua một bước tiền xử lý làm sạch (cleaning) gồm: loại bỏ các thành phần nhiễu không mang nội dung pháp lý như số trang, tiêu đề lặp lại ở đầu/cuối mỗi trang PDF (header/footer), chuẩn hóa các ký tự khoảng trắng và xuống dòng dư thừa do quá trình ngắt trang tự động của PDF gây ra, đồng thời nối liền các đoạn văn bản của một điều luật bị PDF tách thành nhiều trang khác nhau. Kết quả của bước này là một chuỗi văn bản liên tục, sạch, giữ nguyên trình tự logic của toàn bộ văn bản luật gốc, sẵn sàng cho bước phân đoạn theo ranh giới điều luật.

3.3.2. Phân đoạn Văn bản theo Ranh giới Điều luật (Article-Boundary Chunking)

Các kỹ thuật phân đoạn văn bản (chunking) tiêu chuẩn thường được sử dụng trong các hệ thống RAG thông thường dựa trên độ dài cố định (fixed-length splitting), ví dụ chia văn bản thành các đoạn 256 hoặc 512 token với một phần chồng lấp (overlap) cố định. Tuy nhiên, cách tiếp cận này về cơ bản không phù hợp với văn bản pháp luật, bởi mỗi điều luật (Điều) trong văn bản quy phạm pháp luật Việt Nam tạo thành một đơn vị pháp lý nguyên tử (atomic legal provision) – mang một ý nghĩa pháp lý hoàn chỉnh, độc lập và thường được người dùng tham chiếu trực tiếp theo số hiệu điều (ví dụ "Điều 51", "Điều 81"). Việc cắt một điều luật làm đôi bởi ranh giới token cố định sẽ phá vỡ tính liên kết logic giữa các khoản, điểm trong cùng một điều, làm suy giảm nghiêm trọng chất lượng truy xuất và độ chính xác trích dẫn.

Để giải quyết vấn đề này, hệ thống RAG++ triển khai kỹ thuật phân đoạn theo ranh giới điều luật (Article-Boundary Chunking), sử dụng biểu thức chính quy (regular expression) dạng nhìn trước không tiêu thụ (zero-width positive lookahead): `r"(?i)(?=Điều\s+\d+\.)"`. Cơ chế hoạt động của biểu thức này như sau: công cụ phân đoạn quét tuần tự toàn bộ văn bản đã làm sạch, mỗi khi gặp một vị trí mà ngay sau đó là cụm từ khóa "Điều" theo sau bởi một hoặc nhiều khoảng trắng, một số thứ tự (`\d+`) và dấu chấm – ví dụ "Điều 1.", "Điều 58.", "Điều 81." – biểu thức sẽ đánh dấu đây là một điểm tách (split point), nhưng không loại bỏ chính cụm từ "Điều X." khỏi đoạn văn bản theo sau (đặc tính "zero-width" và "lookahead"). Cờ `(?i)` đảm bảo việc khớp mẫu không phân biệt chữ hoa/chữ thường. Kết quả là mỗi đoạn (chunk) sinh ra luôn bắt đầu chính xác bằng tiêu đề điều luật của nó và chứa

đầy đủ, liên tục toàn bộ nội dung của điều luật đó cho đến trước tiêu đề điều luật kế tiếp.



Hình 3. 2 Minh họa cơ chế phân đoạn văn bản theo ranh giới điều luật (Article-Boundary Chunking) bằng biểu thức chính quy lookahead

Mỗi đoạn (chunk) sau khi phân tách được gắn kèm một tập siêu dữ liệu (metadata) có cấu trúc, bao gồm: định danh điều luật (article identifier, ví dụ "Điều 51"), tên văn bản luật gốc (ví dụ "Luật Hôn nhân và Gia đình số 52/2014/QH13"), năm ban hành văn bản (year of enactment, ví dụ 2014 hoặc 2024) và trạng thái hiệu lực (hieu_luc – còn hiệu lực hoặc đã bị thay thế/hết hiệu lực). Tập siêu dữ liệu này đóng vai trò then chốt cho các thành phần xử lý ở tầng Online, đặc biệt là thuật toán suy giảm thời gian (Temporal Decay Penalty, mục 3.3.5) và bộ lọc Metadata Filtering. Áp dụng quy trình phân đoạn này lên toàn bộ kho văn bản (Luật Hôn nhân và Gia đình 2014 và Nghị quyết 01/2024/NQ-HĐTP), hệ thống thu được tổng cộng

505 đoạn văn bản pháp lý chuẩn mực, với độ dài mỗi đoạn dao động trong khoảng từ 200 đến 400 token, phù hợp với giới hạn ngữ cảnh hiệu quả của mô hình embedding được sử dụng ở bước tiếp theo.

3.3.3. Sinh Embedding Đa ngôn ngữ và Lập chỉ mục Song song (Dual Indexing)

Sau khi có 505 đoạn văn bản pháp lý chuẩn mực kèm siêu dữ liệu, hệ thống thực hiện đồng thời hai luồng xử lý để xây dựng hai chỉ mục hỗ trợ cho nhau, tạo thành nền tảng cho cơ chế Tìm kiếm lai (Hybrid Retrieval) ở giai đoạn Online. Luồng thứ nhất xây dựng chỉ mục ngữ nghĩa dày đặc (Dense Index); luồng thứ hai xây dựng chỉ mục từ khóa thưa thớt (Sparse Index).

Đối với luồng Dense, mỗi đoạn văn bản pháp lý được mã hóa thành một vector biểu diễn dày đặc 768 chiều bằng mô hình intfloat/multilingual-e5-base [6] – một mô hình Sentence Transformer được huấn luyện theo phương pháp đối lập yếu giám sát (weakly-supervised contrastive learning) trên một tỷ cặp văn bản đa ngôn ngữ, đạt hiệu suất tốt trên các ngôn ngữ châu Á trong đó có tiếng Việt [12]. Tuân theo quy ước huấn luyện của họ mô hình E5, mỗi đoạn văn bản được thêm tiền tố "passage: " trước khi đưa vào mô hình mã hóa, giúp mô hình phân biệt vai trò của văn bản đang được mã hóa là tài liệu (passage) thay vì truy vấn (query) – sự phân biệt này có vai trò đối xứng quan trọng với tiền tố "query: " được sử dụng ở giai đoạn truy xuất (mục 3.3.3). Toàn bộ 505 vector 768 chiều thu được sau đó được nạp vào một chỉ mục FAISS Flat L2 (Facebook AI Similarity Search) [5] – cấu trúc chỉ mục thực hiện tìm kiếm chính xác (exact search) theo khoảng cách Euclidean (L2), không sử dụng các kỹ thuật xấp xỉ (approximate nearest neighbor) như IVF hay HNSW. Lựa chọn chỉ mục Flat L2 là phù hợp và tối ưu cho quy mô kho dữ liệu 505 phân đoạn của hệ thống, vì ở quy mô này chỉ mục phẳng vẫn đảm bảo tốc độ tìm kiếm trong khoảng milisecond đồng thời đảm bảo không bỏ sót bất kỳ tài liệu liên quan nào – một yêu cầu đặc biệt quan trọng trong miền pháp lý, nơi việc bỏ sót một điều luật liên quan có thể dẫn đến câu trả lời thiếu căn cứ pháp lý.

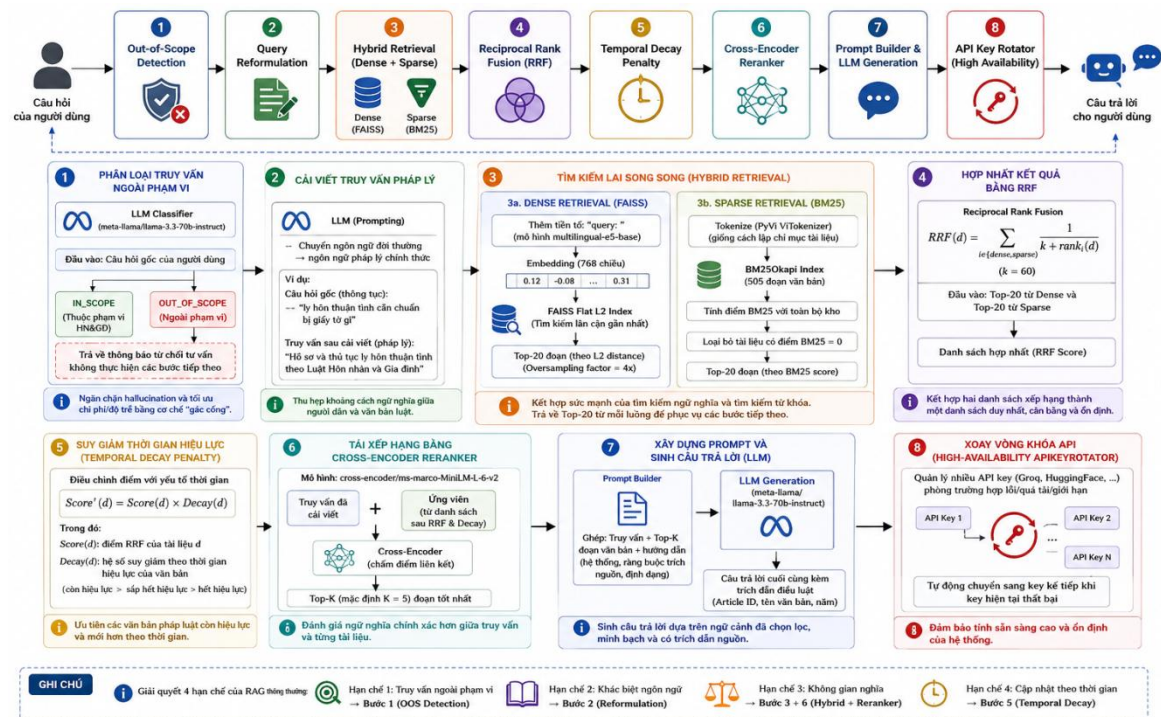
Đối với luồng Sparse, song song với quá trình sinh embedding, mỗi đoạn văn bản pháp lý (505 đoạn) được đưa qua bộ phân đoạn từ tiếng Việt PyVi ViTokenizer – thư viện phân đoạn từ mã nguồn mở dựa trên mô hình CRF (Conditional Random Field) được huấn luyện trên kho ngữ liệu tiếng Việt, có khả năng nhận diện chính xác các từ ghép pháp lý quan trọng như "hôn_nhân", "ly_hôn", "cấp_dưỡng", "nuôi_con" thành các token ghép duy nhất thay vì các âm tiết rời rạc không mang nghĩa pháp lý. Tập token đã phân đoạn của toàn bộ 505 đoạn văn bản được nạp vào chỉ mục BM25Okapi [2] – một biến thể tiêu chuẩn của thuật toán BM25 (Best Match 25), mở rộng mô hình TF-IDF cổ điển bằng cách tính đến độ bão hòa tần số từ (term frequency saturation) và chuẩn hóa độ dài tài liệu (document length normalization), đặc biệt hiệu quả với các thuật ngữ pháp lý chuyên biệt có tần số xuất hiện cao trong văn bản luật.

Kết quả cuối cùng của Pipeline số hóa là một kiến trúc lưu trữ song song (dual-index architecture) gồm: (1) chỉ mục vector FAISS Flat L2 chứa 505 vector 768 chiều phục vụ tìm kiếm ngữ nghĩa; (2) chỉ mục BM25Okapi trên 505 đoạn văn

bản đã được PyVi ViTokenizer phân đoạn, phục vụ tìm kiếm từ khóa chính xác; và (3) kho siêu dữ liệu (metadata store) ánh xạ mỗi đoạn văn bản tới định danh điều luật, tên văn bản, năm ban hành và trạng thái hiệu lực tương ứng. Cả hai chỉ mục và kho siêu dữ liệu được lưu trữ bền vững (persist) trên đĩa và được nạp (load) một lần vào bộ nhớ khi máy chủ FastAPI khởi động, từ đó phục vụ toàn bộ các yêu cầu truy xuất của Pipeline xử lý truy vấn thời gian thực ở mục 3.3 mà không cần tính toán lại embedding hay chỉ mục cho mỗi truy vấn, đảm bảo độ trễ phản hồi ở mức tương tác thời gian thực.

3.4. PIPELINE XỬ LÝ TRUY VẤN PHÁP LÝ THỜI GIAN THỰC (ONLINE LEGAL CONSULTATION PIPELINE)

Pipeline xử lý truy vấn pháp lý thời gian thực là thành phần lõi của hệ thống RAG++, được thực thi cho mỗi câu hỏi mà người dùng gửi đến hệ thống thông qua giao diện Chatweb. Khác với Pipeline số hóa chỉ thực thi một lần, pipeline này hoạt động theo cơ chế bất đồng bộ (asynchronous) trên nền FastAPI và Uvicorn, xử lý tuần tự câu truy vấn qua tám thành phần kỹ thuật được thiết kế để giải quyết triệt để bốn hạn chế của RAG thông thường đã trình bày tại Bảng 3.1. Tám thành phần này, theo đúng trình tự xử lý của một luồng (request flow), bao gồm: (1) Phân loại truy vấn ngoài phạm vi (Out-of-Scope Detection); (2) Cải viết truy vấn pháp lý (Query Reformulation); (3) Tìm kiếm lai song song (Hybrid Retrieval) gồm Dense FAISS và Sparse BM25; (4) Hợp nhất kết quả bằng Reciprocal Rank Fusion (RRF); (5) Thuật toán suy giảm thời gian hiệu lực (Temporal Decay Penalty); (6) Tái xếp hạng bằng Cross-Encoder Reranker; (7) Xây dựng Prompt và sinh câu trả lời bằng LLM (Prompt Builder và LLM Generation); và (8) Cơ chế xoay vòng khóa API đảm bảo tính sẵn sàng cao (High-Availability APIKeyRotator).



Hình 3. 3 Sơ đồ luồng xử lý chi tiết của Pipeline xử lý truy vấn pháp lý thời gian thực (Online Legal Consultation Pipeline)

3.4.1. Phân loại Truy vấn Ngoài Phạm vi (Out-of-Scope Detection)

Ngay khi nhận được câu hỏi từ người dùng và trước khi thực hiện bất kỳ hoạt động truy xuất nào, hệ thống kích hoạt thành phần đầu tiên là Bộ phân loại truy vấn ngoài phạm vi (Out-of-Scope – OOS Classifier). Thành phần này gửi câu hỏi gốc của người dùng kèm theo một prompt chỉ dẫn (instruction prompt) đến mô hình meta-llama/llama-3.3-70b-instruct, yêu cầu mô hình trả về duy nhất một trong hai nhãn: IN_SCOPE (thuộc phạm vi pháp luật Hôn nhân và Gia đình) hoặc OUT_OF_SCOPE (ngoài phạm vi chuyên môn của hệ thống, ví dụ các câu hỏi về luật thuế, lập trình, công thức nấu ăn, hoặc các chủ đề giải trí không liên quan đến pháp luật).

Nếu kết quả phân loại là OUT_OF_SCOPE, hệ thống ngay lập tức trả về một thông báo từ chối tư vấn (refusal message) lịch sự, hướng dẫn người dùng đặt câu hỏi trong phạm vi Luật Hôn nhân và Gia đình, mà không kích hoạt bất kỳ thành phần truy xuất hay sinh văn bản tốn kém tài nguyên nào ở các bước tiếp theo. Cơ chế "gác cổng" (gatekeeping) này mang lại hai lợi ích cốt lõi: thứ nhất, ngăn chặn triệt để hiện tượng hệ thống RAG thông thường vẫn truy xuất các điều luật hôn nhân – gia đình không liên quan rồi sinh ra câu trả lời lạc đề hoặc bịa đặt (hallucination) khi đối mặt với câu hỏi ngoài phạm vi; thứ hai, tối ưu hóa chi phí tính toán và độ trễ phản hồi, vì các bước tìm kiếm lai, hợp nhất RRF, tái xếp hạng Cross-Encoder và sinh câu trả lời đầy đủ chỉ được thực thi khi câu hỏi thực sự thuộc phạm vi chuyên môn của hệ thống.

3.4.2. Cải viết Truy vấn Pháp lý (Query Reformulation)

Đối với các truy vấn được phân loại IN_SCOPE, hệ thống chuyển tiếp câu hỏi đến Mô-đun cải viết truy vấn (Query Reformulation Module). Mô-đun này sử dụng kỹ thuật prompting trên mô hình ngôn ngữ lớn để chuyển đổi câu hỏi đầu vào – thường được người dùng diễn đạt bằng ngôn ngữ thông tục, đời thường, đôi khi viết tắt hoặc thiếu dấu – thành một truy vấn tìm kiếm tương đương được diễn đạt bằng ngôn ngữ pháp lý chính thức, sát với thuật ngữ và cấu trúc câu trong văn bản quy phạm pháp luật.

Ví dụ minh họa cho cơ chế cải viết: câu hỏi thông tục "ly hôn thuận tình cần chuẩn bị giấy tờ gì" được Mô-đun cải viết chuyển đổi thành truy vấn tìm kiếm chính thức "Hồ sơ và thủ tục ly hôn thuận tình theo Luật Hôn nhân và Gia đình". Phép biến đổi này thu hẹp đáng kể khoảng cách ngữ nghĩa giữa cách diễn đạt của người dân (citizen register) và ngôn ngữ của văn bản luật (statutory register) – một trong bốn hạn chế cốt lõi đã phân tích tại mục 2.2.2. Truy vấn đã được cải viết sau đó được sử dụng làm đầu vào thống nhất cho cả hai luồng tìm kiếm song song ở mục 3.3.3, giúp cải thiện đồng thời độ chính xác của cả tìm kiếm ngữ nghĩa dày đặc (do vector truy vấn nằm gần hơn trong không gian embedding với vector các điều luật) và tìm kiếm từ khóa thưa thớt (do truy vấn chứa các thuật ngữ pháp lý chính xác có khả năng khớp trực tiếp với từ khóa trong kho BM25).

3.4.3. Tìm kiếm Lai Song song (Hybrid Retrieval): Dense FAISS và Sparse BM25

Truy vấn đã được cải viết tại mục 3.3.2 được xử lý đồng thời theo hai luồng tìm kiếm song song, tận dụng tính hỗ trợ giữa tìm kiếm ngữ nghĩa và tìm kiếm từ khóa đã trình bày tại mục 2.3.3.

Luồng thứ nhất – Tìm kiếm Ngữ nghĩa Dày đặc (Dense Semantic Retrieval với FAISS): truy vấn được thêm tiền tố "query: " theo đúng quy ước huấn luyện của mô hình multilingual-e5-base [6] (đối xứng với tiền tố "passage: " được áp dụng cho tài liệu ở mục 3.2.3), sau đó được mã hóa thành một vector 768 chiều bằng cùng mô hình embedding. Vector truy vấn này được đưa vào chỉ mục FAISS Flat L2 để thực hiện tìm kiếm lân cận gần nhất theo khoảng cách Euclidean (L2 approximate nearest-neighbor search), trả về danh sách Top-20 đoạn văn bản pháp lý có vector gần nhất với vector truy vấn. Việc lựa chọn Top-20 (thay vì chỉ Top-5 cần dùng cho sinh câu trả lời cuối cùng) tương ứng với hệ số mở rộng lấy mẫu (oversampling factor) bằng 4 lần so với số lượng tài liệu cuối cùng cần cho LLM, nhằm cung cấp đủ ứng viên chất lượng cao cho các bước hợp nhất và tái xếp hạng phía sau.

Luồng thứ hai – Tìm kiếm Từ khóa Thưa thớt (Sparse Keyword Retrieval với BM25): truy vấn đã cải viết được phân đoạn từ bằng PyVi ViTokenizer theo cùng cơ chế đã áp dụng cho tài liệu ở mục 3.2.3, đảm bảo các từ ghép pháp lý trong truy vấn (ví dụ "lý_hôn", "thuận_tình") được phân đoạn nhất quán với cách các từ ghép tương ứng đã được phân đoạn và lập chỉ mục trong kho BM25Okapi [2]. Truy vấn đã phân đoạn được tính điểm tương quan với toàn bộ 505 đoạn văn bản trong chỉ mục BM25. Các tài liệu nhận điểm BM25 bằng 0 (zero score) – nghĩa là không chứa bất kỳ token chung nào với truy vấn – bị loại bỏ ngay khỏi danh sách ứng viên, nhằm tránh việc các tài liệu hoàn toàn không liên quan về từ khóa vẫn được đưa vào bước hợp nhất RRF ở mục 3.3.4 chỉ vì có điểm BM25 bằng 0 nhưng vẫn được xếp hạng

3.4.4. Hợp nhất Kết quả bằng Reciprocal Rank Fusion (RRF)

Hai danh sách ứng viên thu được từ luồng Dense (FAISS, Top-20) và luồng Sparse (BM25, các tài liệu có điểm khác 0) được hợp nhất thành một danh sách thống nhất bằng thuật toán Reciprocal Rank Fusion (RRF) [18]. Điểm RRF của một tài liệu d được tính theo công thức sau:

$$RRFScore(d) = \sum (m \in M) [w_m / (k_o + r_m(d))]$$

trong đó $M = \{FAISS, BM25\}$ là tập hai retriever tham gia hợp nhất; $r_m(d)$ là vị trí xếp hạng (rank) của tài liệu d trong danh sách kết quả của retriever m (nếu d không xuất hiện trong danh sách của retriever m , hạng $r_m(d)$ được coi là vô hạn và số hạng tương ứng bằng 0); $k_o = 60$ là hằng số làm trơn (smoothing constant) có vai trò giảm ảnh hưởng quá lớn của các tài liệu được xếp ở vị trí top-1, top-2; và $w_m = 1,5$ là trọng số ưu tiên áp dụng đồng nhất cho cả hai retriever, được lựa chọn để cân bằng đóng góp của tìm kiếm ngữ nghĩa và tìm kiếm từ khóa vào điểm hợp nhất cuối cùng.

Ưu điểm cốt lõi của RRF nằm ở việc thuật toán này dựa hoàn toàn trên thứ hạng (rank-based) của tài liệu trong từng danh sách riêng lẻ, thay vì dựa trên giá trị điểm số tuyệt đối (score-based). Điều này giúp RRF tránh được vấn đề chênh lệch thang điểm (score scale mismatch) giữa hai retriever có bản chất hoàn toàn khác nhau: điểm tương đồng cosine của FAISS nằm trong khoảng giới hạn [0, 1], trong khi điểm BM25 là một giá trị không có giới hạn trên và phụ thuộc vào độ dài tài liệu, tần số từ khóa. Nếu áp dụng các phương pháp chuẩn hóa điểm số tuyến tính (linear score normalization) thông thường, kết quả hợp nhất sẽ rất nhạy cảm với phân phối điểm số cụ thể của từng truy vấn; trong khi đó, cơ chế dựa trên thứ hạng của RRF [18] mang lại sự ổn định và bền vững (robustness) cao hơn, đã được khẳng định qua các thực nghiệm trên nhiều miền dữ liệu truy xuất khác nhau. Công trình REALM [3] cũng cung cấp nền tảng lý thuyết quan trọng cho việc tích hợp các tín hiệu truy xuất đa dạng vào quá trình sinh văn bản của mô hình ngôn ngữ.

3.4.5. Thuật toán Suy giảm Thời gian Hiệu lực (Temporal Decay Penalty)

Danh sách tài liệu sau khi được hợp nhất bằng RRF được tiếp tục xử lý qua thuật toán suy giảm thời gian (Temporal Decay Penalty) – thành phần kỹ thuật được thiết kế chuyên biệt để giải quyết hạn chế về phân cấp thời gian hiệu lực của văn bản pháp luật (Temporal Legal Hierarchy) đã trình bày tại mục 2.2.2 và 2.3.4. Điểm số cuối cùng (final score) của mỗi tài liệu d được tính bằng tích của điểm RRF với một hệ số suy giảm theo độ mới (recency multiplier), theo công thức:

$$Score_final(d) = RRF_Score(d) \times \max(0,01 ; 1,0 - (Y_hiện_tại - Y_d) \times \lambda)$$

Trong đó $Y_hiện_tại$ là năm hiện tại, Y_d là năm ban hành của văn bản chứa tài liệu d (được trích xuất từ trường siêu dữ liệu đã gắn trong bước Article-Boundary Chunking, mục 3.2.2), và $\lambda = 0,20$ là hệ số suy giảm hàng năm (annual decay rate), tương đương mức suy giảm 20% mỗi năm tuổi của văn bản. Hàm $\max(0,01; \dots)$ đảm bảo hệ số nhân không bao giờ giảm về 0 tuyệt đối, giữ lại một trọng số sàn (floor weight) tối thiểu 0,01 cho các văn bản rất cũ, để các văn bản này vẫn có thể được truy xuất trong trường hợp không có văn bản mới nào đề cập đến nội dung tương ứng.

Áp dụng công thức trên với mốc thời gian nghiên cứu (năm 2026): Nghị quyết 01/2024/NQ-HĐTP, được ban hành năm 2024 ($Y_d = 2024$), nhận hệ số nhân $\max(0,01; 1,0 - 2 \times 0,20) = \max(0,01; 0,6) = 0,6$; trong khi Luật Hôn nhân và Gia đình 2014 ($Y_d = 2014$), được ban hành cách đây 12 năm, nhận hệ số nhân $\max(0,01; 1,0 - 12 \times 0,20) = \max(0,01; -1,4) = 0,01$. Cơ chế này đảm bảo rằng, trong các tình huống có quy định chồng chéo giữa văn bản luật gốc 2014 và nghị quyết hướng dẫn 2024, các điều khoản của nghị quyết mới hơn luôn được ưu tiên xếp hạng cao hơn một cách có hệ thống [1], phản ánh đúng nguyên tắc "văn bản pháp luật mới thay thế văn bản cũ" trong thực tiễn áp dụng pháp luật. Sau khi áp dụng Temporal Decay Penalty, danh sách được sắp xếp lại theo $Score_final$ giảm dần, và Top-15 tài liệu có điểm cao nhất được chuyển tiếp sang bước tái xếp hạng Cross-Encoder ở mục 3.3.6.

Văn bản pháp luật	Năm ban hành	Khoảng cách (năm)	Hệ số suy giảm	Ý nghĩa
Nghị quyết 01/2024/NQ-HĐTP	2024	2	$\max(0.01; 1.0 - 0.20 \times 2) = 0.60$	Ưu tiên cao – văn bản mới nhất
Nghị định hướng dẫn 2021	2021	5	$\max(0.01; 1.0 - 0.20 \times 5) = 0.00 \rightarrow 0.01$	Ưu tiên thấp
Luật HN&GD số 52/2014/QH13	2014	12	$\max(0.01; 1.0 - 0.20 \times 12) = 0.01$	Tối thiểu – luật gốc vẫn được xét

Bảng 3. 2 Hệ số Temporal Decay cho các văn bản pháp luật trong kho tri thức (năm 2026)

3.4.6. Tái xếp hạng bằng Cross-Encoder Reranker

Top-15 tài liệu thu được sau bước Temporal Decay Penalty được đưa qua mô hình tái xếp hạng Cross-Encoder. Về bản chất kỹ thuật, các mô hình được sử dụng ở hai luồng tìm kiếm trong mục 3.3.3 (multilingual-e5-base cho FAISS) thuộc kiến trúc Bi-Encoder – mã hóa truy vấn và tài liệu thành hai vector độc lập rồi so sánh bằng độ tương đồng cosine hoặc khoảng cách Euclidean, cho phép tính toán nhanh nhưng không nắm bắt được tương tác chi tiết giữa từng cặp từ trong truy vấn và tài liệu. Ngược lại, mô hình Cross-Encoder nhận đồng thời cặp (truy vấn, tài liệu) làm đầu vào của một mô hình Transformer duy nhất, áp dụng cơ chế self-attention đầy đủ trên toàn bộ chuỗi ghép nối, từ đó tính ra một điểm số tương quan (relevance score) phản ánh chính xác hơn mức độ liên quan ngữ nghĩa sâu giữa câu hỏi tình huống của người dùng và nội dung cụ thể của từng điều luật.

Kiến trúc truy xuất hai tầng (two-stage retrieval) – Bi-Encoder ở giai đoạn lọc thô (mục 3.3.3 và 3.3.4) kết hợp Cross-Encoder ở giai đoạn tinh chỉnh (mục 3.3.6) – là giải pháp thực tiễn tối ưu cho cân bằng giữa độ trễ phản hồi và độ chính xác ngữ cảnh trong các tác vụ truy xuất văn bản pháp lý [4], [8]. Giai đoạn đầu sử dụng Bi-Encoder có chi phí tính toán thấp để thu hẹp không gian tìm kiếm từ 505 đoạn văn bản trong toàn bộ kho tri thức xuống còn Top-15 ứng viên có khả năng liên quan cao nhất; giai đoạn sau áp dụng Cross-Encoder có chi phí tính toán cao hơn nhưng chỉ cần thực thi trên 15 cặp (truy vấn, tài liệu), do đó vẫn đảm bảo độ trễ phù hợp cho tương tác thời gian thực. Kết quả của bước này là Top-5 tài liệu có điểm Cross-Encoder cao nhất, được lựa chọn làm ngữ cảnh (context) đầu vào cuối cùng cho mô hình sinh câu trả lời ở mục 3.3.7.

3.4.7. Xây dựng Prompt và Sinh Câu trả lời bằng Mô hình Ngôn ngữ Lớn (Prompt Builder và LLM Generation)

Top-5 đoạn văn bản pháp lý được lựa chọn sau bước tái xếp hạng được tập hợp lại bởi thành phần Prompt Builder, kết hợp cùng câu hỏi gốc của người dùng và một mẫu prompt hệ thống (system prompt template) được thiết kế chuyên biệt cho bài toán tư vấn pháp lý, để tạo thành một prompt có cấu trúc hoàn chỉnh gửi đến mô

hình ngôn ngữ lớn meta-llama/llama-3.3-70b-instruct thông qua cổng điều phối API của OpenRouter (sử dụng OpenAI Python SDK). Prompt hệ thống yêu cầu mô hình sinh câu trả lời theo một cấu trúc cố định gồm bốn phân mục lớn, đảm bảo tính nhất quán và dễ theo dõi cho người dùng phổ thông:

- PHẦN I – Ghi nhận vấn đề (Issue Acknowledgement): tóm tắt lại tình huống pháp lý mà người dùng đang gặp phải, thể hiện sự thấu hiểu đúng bản chất câu hỏi.
- PHẦN II – Căn cứ pháp lý áp dụng (Applicable Statutory Provisions): liệt kê các điều luật, khoản, điểm cụ thể được trích xuất từ Top-5 ngữ cảnh, kèm số hiệu điều và tên văn bản tương ứng.
- PHẦN III – Phân tích pháp lý chi tiết (Detailed Legal Analysis): diễn giải nội dung các điều luật đã trích dẫn trong mối liên hệ trực tiếp với tình huống cụ thể của người dùng, bằng ngôn ngữ dễ hiểu cho người không có chuyên môn luật.
- PHẦN IV – Hướng dẫn hành động cụ thể (Concrete Advice and Action Steps): đề xuất các bước hành động thực tế, hồ sơ, thủ tục cần thực hiện để người dùng có thể áp dụng vào tình huống của mình.

Một ràng buộc quan trọng được áp đặt trong prompt hệ thống là mô hình chỉ được phép trích dẫn các điều luật có mặt trong Top-5 ngữ cảnh được cung cấp ("chỉ trích dẫn các điều luật có trong ngữ cảnh được cung cấp"), tuyệt đối không được tự suy diễn hoặc bịa đặt thêm số hiệu điều luật ngoài phạm vi ngữ cảnh. Ràng buộc này là tuyến phòng vệ cuối cùng và quan trọng nhất chống lại hiện tượng ảo giác thông tin (hallucination) đã phân tích tại mục 2.1.2 – ngay cả khi mô hình có "kiến thức tham số" về các điều luật khác ngoài Top-5, prompt hệ thống vẫn buộc mô hình neo chặt đầu ra vào đúng các căn cứ pháp lý đã được kiểm chứng và truy xuất thực tế từ kho tri thức [4].

Về mặt linh hoạt triển khai, kiến trúc Prompt Builder và LLM Generation của RAG++ được thiết kế độc lập với một mô hình sinh cụ thể (model-agnostic), cho phép thay thế mô hình sinh văn bản chính (meta-llama/llama-3.3-70b-instruct) bằng các mô hình thay thế khác như Gemma, Gemini hoặc GPT-4o-mini mà không cần thay đổi các thành phần truy xuất, hợp nhất, suy giảm thời gian và tái xếp hạng phía trước. Tính linh hoạt này được tận dụng trực tiếp trong thực nghiệm so sánh hiệu năng các LLM backend khác nhau, được trình bày chi tiết tại Chương 4 (Bảng IV).

3.4.8. Cơ chế Xoay vòng Khóa API Đảm bảo Tính Sẵn sàng Cao (High-Availability APIKeyRotator)

Để đảm bảo hệ thống có thể vận hành liên tục 24/7 phục vụ truy vấn của người dân mà không bị gián đoạn bởi giới hạn hạn ngạch (quota limit) của các nhà cung cấp API thương mại, hệ thống RAG++ triển khai một lớp (class) chuyên trách có tên APIKeyRotator. Thành phần này duy trì một bể (pool) chứa tối đa 50 khóa truy cập API (API credentials) hợp lệ, được cấu hình trong tệp môi trường .env.

Mỗi khi một lệnh gọi đến mô hình ngôn ngữ lớn qua OpenRouter trả về một trong các mã lỗi HTTP báo hiệu hết hạn mức hoặc khóa không hợp lệ (401 Unauthorized, 402 Payment Required, hoặc 429 Too Many Requests),

APIKeyRotator tự động chuyển sang sử dụng khóa API kế tiếp còn khả dụng trong bể, đồng thời đánh dấu khóa vừa gặp lỗi bằng cách tự động "comment out" (vô hiệu hóa tạm thời bằng ký tự chú thích) dòng tương ứng trong tệp cấu hình .env, ngăn không cho khóa đã hết hạn mức được sử dụng lại trong các lượt xoay vòng tiếp theo. Cơ chế xoay vòng và tự vô hiệu hóa này cho phép hệ thống tiếp tục phục vụ các yêu cầu tư vấn pháp lý của người dùng một cách liên tục, không cần can thiệp thủ công của quản trị viên để thay khóa API – một yêu cầu vận hành thiết yếu đối với một dịch vụ công ích hướng đến người dân.

3.5. CÔNG CỤ, NGÔN NGỮ LẬP TRÌNH VÀ MÔI TRƯỜNG PHÁT TRIỂN

Để hiện thực hóa toàn bộ kiến trúc RAG++ đã trình bày tại mục 3.2 và 3.3 – từ giai đoạn số hóa kho tri thức, vận hành Pipeline truy xuất nâng cao, đến giai đoạn kiểm định thực nghiệm khoa học theo phương pháp LLM-as-a-Judge (sẽ trình bày chi tiết ở Chương 4) – đề tài lựa chọn và phối hợp đồng bộ một hệ sinh thái công cụ, thư viện và công nghệ thuộc ngôn ngữ Python. Bảng 3.2 tổng hợp danh mục công cụ chính được sử dụng, phân theo nhóm chức năng và vai trò cụ thể trong hệ thống.

Nhóm công nghệ	Công cụ / Thư viện	Vai trò trong hệ thống RAG++
Ngôn ngữ lập trình & Môi trường phát triển	Python $\geq$ 3.12, Visual Studio Code (VS Code)	Nền tảng cốt lõi cho toàn bộ hệ thống; quản lý và phát triển mã nguồn tập trung
Kiến trúc & Giao thức dịch vụ Backend	FastAPI, Uvicorn, Asyncio	Xây dựng API dịch vụ xử lý bất đồng bộ, tối ưu băng thông và giảm độ trễ phản hồi khi tích hợp LLM
Tiền xử lý dữ liệu tĩnh	pdfplumber, pandas, tqdm	Trích xuất văn bản từ PDF luật, cấu trúc hóa dữ liệu tri thức, quản lý bộ kiểm thử và theo dõi tiến độ
Cơ sở dữ liệu Vector & Chỉ mục lai	FAISS (Flat L2), rank-bm25 (BM25Okapi), PyVi ViTokenizer	Lưu trữ và truy xuất vector 768 chiều (Dense); xây dựng chỉ mục từ khóa tiếng Việt (Sparse)
Mô hình học máy chuyên trách trong RAG Pipeline	intfloat/multilingual-e5-base (Embedding); Cross-Encoder (Reranking)	Sinh vector ngữ nghĩa cho 505 đoạn luật và truy vấn; tái xếp hạng Top-15 thành Top-5 ngữ cảnh
Mô hình Ngôn ngữ Lớn & Công cụ điều phối API	meta-llama/llama-3.3-70b-instruct, OpenRouter, OpenAI Python SDK	Lỗi xử lý OOS Classification, Query Reformulation, sinh câu trả lời tư vấn và chấm điểm LLM-as-a-Judge
Quản trị dữ liệu thực thể & Bảo mật	SQLAlchemy ORM, PyJWT (jose.jwt, HS256), HTTPBearer (FastAPI)	Quản lý cơ sở dữ liệu quan hệ; mã hóa Token xác thực người dùng theo chuẩn HS256

Kết xuất và thống kê thực nghiệm	openpyxl	Bóc tách, tính toán và xuất tự động các chỉ số đánh giá trung bình ra tệp Excel phục vụ Chương 4
----------------------------------	----------	--

Bảng 3. 3 Danh mục công cụ, thư viện và công nghệ sử dụng trong hệ thống RAG++

Về ngôn ngữ lập trình và môi trường phát triển, toàn bộ hệ thống được phát triển bằng ngôn ngữ Python phiên bản 3.12 trở lên – lựa chọn này dựa trên hệ sinh thái thư viện trí tuệ nhân tạo và xử lý dữ liệu phong phú, hỗ trợ trực tiếp các thư viện cốt lõi như FAISS, rank-bm25, pandas và các mô hình Sentence Transformer. Mã nguồn được phát triển, gỡ lỗi và quản lý phiên bản tập trung trên môi trường Visual Studio Code (VS Code), tích hợp các tiện ích mở rộng hỗ trợ Python, định dạng mã nguồn và kiểm tra kiểu dữ liệu tĩnh.

Về kiến trúc dịch vụ Backend, framework FastAPI được lựa chọn làm nền tảng xây dựng các điểm cuối (endpoint) API của hệ thống, kết hợp với máy chủ Uvicorn để vận hành ứng dụng theo mô hình ASGI (Asynchronous Server Gateway Interface). Việc sử dụng cơ chế lập trình bất đồng bộ Asyncio cho phép hệ thống xử lý đồng thời nhiều yêu cầu của người dùng trong khi đang chờ phản hồi từ các lệnh gọi I/O có độ trễ cao – đặc biệt là các lệnh gọi đến API của mô hình ngôn ngữ lớn qua OpenRouter – mà không làm tắc nghẽn (block) toàn bộ luồng xử lý của máy chủ, đáp ứng yêu cầu phục vụ đồng thời nhiều phiên tư vấn pháp lý của người dùng vắng lai và thành viên đăng ký.

Về thư viện tiền xử lý dữ liệu tĩnh và lập chỉ mục lai, thư viện pdfplumber đảm nhiệm vai trò trích xuất văn bản thô như đã trình bày tại mục 3.2.1, kết hợp với pandas để cấu trúc hóa 505 đoạn văn bản và toàn bộ siêu dữ liệu liên quan thành các cấu trúc bảng dữ liệu (DataFrame) để thao tác, cùng tqdm để theo dõi tiến độ thực thi các vòng lặp xử lý dài (ví dụ vòng lặp sinh embedding cho 505 đoạn văn bản hoặc vòng lặp chạy benchmark trên 351 tình huống ở Chương 4). Thư viện FAISS đảm nhiệm lưu trữ và tìm kiếm vector mật độ cao 768 chiều [5], trong khi rank-bm25 cung cấp triển khai BM25Okapi [2] cho chỉ mục từ khóa cục bộ, được phân đoạn từ trước bằng PyVi ViTokenizer.

Về quản trị dữ liệu thực thể và bảo mật, hệ thống sử dụng thư viện SQLAlchemy ORM (Object-Relational Mapping) để định nghĩa và quản lý các thực thể dữ liệu quan hệ của hệ thống (chi tiết thiết kế cơ sở dữ liệu lai sẽ được trình bày tại Chương 4). Cơ chế xác thực người dùng được triển khai bằng thư viện PyJWT (thông qua mô-đun jose.jwt), sinh và kiểm tra mã thông báo truy cập (access token) theo thuật toán băm tiêu chuẩn HS256 (HMAC with SHA-256), kết hợp với lớp bảo mật HTTPBearer được tích hợp sẵn trong FastAPI để bảo vệ các điểm cuối API yêu cầu xác thực.

Cuối cùng, đối với công cụ kết xuất và thống kê thực nghiệm, thư viện openpyxl được sử dụng để can thiệp trực tiếp vào cấu trúc dữ liệu bảng tính Excel, hỗ trợ bóc tách và xuất tự động các chỉ số đo đạc – bao gồm điểm LLM Judge Score

theo năm tiêu chí và Keyword Accuracy – ra tệp Excel, phục vụ trực tiếp cho việc tổng hợp Bảng II, Bảng III và Bảng IV cùng các phân tích định lượng được trình bày tại Chương 4.

3.6 HỆ THỐNG ĐÁNH GIÁ CHẤT LƯỢNG TỰ ĐỘNG LEXRAG++

3.6.1 Kiến trúc hệ thống đánh giá bất đồng bộ

Hệ thống đánh giá chất lượng LexRAG++ được thiết kế để hoạt động hoàn toàn bất đồng bộ so với luồng phản hồi chính. Ngay sau khi câu trả lời được sinh ra và lưu vào cơ sở dữ liệu, một BackgroundTask của FastAPI được kích hoạt để chạy quy trình đánh giá LexRAG++ mà không làm chậm trải nghiệm người dùng. Người dùng nhận câu trả lời ngay lập tức qua SSE streaming, trong khi điểm LexRAG++ được tính toán trong nền và cập nhật vào cơ sở dữ liệu sau khoảng 10–30 giây, sau đó hiển thị trên giao diện thông qua cơ chế polling định kỳ.

3.6.2 Quy trình đánh giá năm tiêu chí LexRAG++

LLM-as-a-Judge Agent sử dụng meta-llama/llama-3.3-70b-instruct với prompt đánh giá được thiết kế chi tiết theo kỹ thuật Chain-of-Thought [7][8]. Prompt yêu cầu LLM giám khảo thực hiện theo trình tự: (1) Đọc câu hỏi pháp lý và câu trả lời cần đánh giá; (2) Phân tích lần lượt từng tiêu chí LexRAG++ với lập luận chi tiết từng bước; (3) Đưa ra điểm số từ 1 đến 10 cho từng tiêu chí kèm giải thích ngắn gọn; (4) Tính điểm trung bình tổng hợp và nhận xét tổng quan.

Tiêu chí	Điểm 1–3 (Kém)	Điểm 4–6 (Trung bình)	Điểm 7–8 (Tốt)	Điểm 9–10 (Xuất sắc)	Ngưỡng đạt
Factuality (Tính xác thực)	Trích dẫn sai số điều luật; bịa đặt điều luật không tồn tại	Một số trích dẫn chính xác, một số thiếu căn cứ	Trích dẫn đúng số điều và nội dung; không hallucination	Trích dẫn hoàn toàn chính xác, đầy đủ số điều, khoản, tên văn bản	≥ 7.50
Completeness (Tính đầy đủ)	Bỏ sót các khía cạnh pháp lý trọng yếu của câu hỏi	Đề cập một số khía cạnh, thiếu nhiều nội dung quan trọng	Bao phủ phần lớn khía cạnh pháp lý liên quan	Bao phủ toàn diện kể cả ngoại lệ và điều kiện đặc biệt	≥ 7.50
Coherence (Tính mạch lạc)	Lập luận lộn xộn, không có cấu trúc rõ ràng	Có cấu trúc nhưng thiếu liên kết logic ở một số đoạn	Lập luận mạch lạc, cấu trúc bốn phần rõ ràng	Lập luận hoàn hảo, dẫn dắt người đọc tự nhiên từng bước	≥ 7.50
Clarity (Tính rõ ràng)	Ngôn ngữ quá kỹ thuật, người dân không thể hiểu	Một số thuật ngữ được giải thích, một số chưa	Ngôn ngữ rõ ràng, giải thích thuật ngữ cơ bản	Diễn đạt hoàn toàn dễ hiểu cho người không chuyên	≥ 7.50
Relevance (Đúng trọng)	Câu trả lời lạc đề, không giải	Đề cập vấn đề nhưng còn	Tập trung vào vấn đề chính, ít	Giải quyết chính xác và	≥ 7.50

tâm)	quyết vấn đề người dùng	nhiều nội dung thừa	nội dung thừa	đầy đủ vấn đề cụ thể của người dùng	
------	----------------------------	------------------------	---------------	---	--

Bảng 3. 4 Năm tiêu chí đánh giá LexRAG++ với thang điểm chi tiết

Prompt yêu cầu LLM giám khảo xuất ra kết quả theo định dạng JSON có cấu trúc cố định, bao gồm điểm số và lý do phân tích cho từng tiêu chí, điểm trung bình tổng hợp và nhận xét tổng quan. Cấu trúc JSON cố định đảm bảo khả năng phân tích kết quả tự động 100% và lưu trữ có cấu trúc vào cơ sở dữ liệu SQL. Điểm tham chiếu: 8.0/10 tương đương năng lực của một Luật sư thực hành có chuyên môn [9].

3.6.3 Chỉ số Keyword Accuracy

Song song với đánh giá LLM-as-a-Judge, hệ thống tính toán chỉ số Keyword Accuracy cho mỗi câu trả lời trong bộ Benchmark. Keyword Accuracy đo lường tỷ lệ từ khóa pháp lý chuẩn (được chú thích trong ground truth của Benchmark) xuất hiện trong câu trả lời được sinh ra.

Quy trình tính Keyword Accuracy: (1) Với mỗi câu hỏi trong Benchmark, ground truth bao gồm danh sách từ khóa pháp lý kỳ vọng, ví dụ: ["Điều 55", "thuận tình ly hôn", "thời hạn hòa giải", "sáu tháng"]; (2) Câu trả lời được sinh ra bởi hệ thống được lowercase và kiểm tra sự xuất hiện của từng từ khóa bằng tìm kiếm chuỗi con; (3) Keyword Accuracy = Số từ khóa tìm thấy / Tổng số từ khóa kỳ vọng [17]. Chỉ số này được tính hoàn toàn tự động bằng Python, không cần LLM giám khảo, cung cấp góc nhìn định lượng bổ sung và độc lập với LLM Judge Score.

3.6.4 Quy trình xây dựng bộ Benchmark 351 tình huống

Bộ Benchmark gồm 351 tình huống pháp lý phức tạp được xây dựng theo quy trình ba bước, lấy cảm hứng từ phương pháp VQABG [17] nhưng điều chỉnh cho bài toán pháp luật hôn nhân và gia đình tiếng Việt:

- **Bước 1 – Xác định phổ chủ đề:** Phân tích toàn bộ chín chương của Luật HN&GD 2014 và các văn bản hướng dẫn, xác định 15 chủ đề pháp lý lớn bao gồm: điều kiện kết hôn, đăng ký kết hôn, quyền nghĩa vụ vợ chồng, tài sản chung/riêng, thuận tình ly hôn, đơn phương ly hôn, quyền nuôi con, cấp dưỡng, kết hôn có yếu tố nước ngoài, mang thai hộ, quan hệ cha mẹ – con nuôi, hôn nhân thực tế, xác định cha mẹ con, quan hệ ông bà cháu và chia tài sản doanh nghiệp sau ly hôn.
- **Bước 2 – Thiết kế và sinh câu hỏi:** Với mỗi chủ đề, thiết kế ít nhất 20 tình huống pháp lý đặc trưng bao gồm cả tình huống thông thường và ngoại lệ phức tạp. Câu hỏi được viết theo phong cách ngôn ngữ thông tục của người dân thực tế, không sử dụng thuật ngữ pháp lý để phản ánh đúng cách người dùng thực tế đặt câu hỏi.
- **Bước 3 – Chú thích Ground Truth:** Với mỗi câu hỏi, chú thích: (a) Danh sách từ khóa pháp lý kỳ vọng dùng tính Keyword Accuracy; (b) Các điều luật cụ thể phải được đề cập trong câu trả lời đúng; (c) Nhãn phân loại chủ đề. Quá trình chú thích được thực hiện thủ công bởi tác giả với tham chiếu trực tiếp đến văn bản luật gốc [1].


3.7 THIẾT KẾ KIẾN TRÚC PHẦN MỀM TỔNG THỂ

3.7.1 Kiến trúc Backend FastAPI

Backend được tổ chức theo kiến trúc phân tầng (Layered Architecture) với ba tầng rõ ràng: Tầng Định tuyến (Router Layer) định nghĩa các endpoint API REST và SSE; Tầng Dịch vụ (Service Layer) chứa toàn bộ logic nghiệp vụ bao gồm Online Pipeline và Offline Pipeline; và Tầng Dữ liệu (Data Access Layer) quản lý tương tác với SQLAlchemy ORM và các chỉ mục FAISS/BM25. Cấu trúc thư mục mã nguồn:

- **app/routers/**: Các file định nghĩa endpoint phân chia theo chức năng: auth.py (đăng ký/đăng nhập JWT), chat.py (hội thoại và SSE streaming), admin.py (quản trị hệ thống), benchmark.py (chạy đánh giá Benchmark).
- **app/services/**: Logic nghiệp vụ cốt lõi: rag_pipeline.py (Online Pipeline 8 bước), embedding_service.py (sinh và lưu trữ embedding), llm_service.py (giao tiếp OpenRouter API và APIKeyRotator), evaluation_service.py (LexRAG++ Judge bất đồng bộ).
- **app/models/**: Định nghĩa bảng SQLAlchemy ORM cho 5 bảng chính.
- **app/data/**: Các file chỉ mục (faiss_index.bin, bm25_index.pkl) và văn bản pháp luật gốc.

3.7.2 Thiết kế cơ sở dữ liệu



Hình 3. 4 Cơ sở dữ liệu

Cơ sở dữ liệu của hệ thống được thiết kế nhằm đáp ứng ba mục tiêu chính: (1) lưu trữ thông tin người dùng và phân quyền truy cập; (2) quản lý lịch sử hội thoại và kết quả tư vấn pháp lý; (3) lưu trữ các chỉ số đánh giá chất lượng phục vụ Benchmark và Ablation Study. Mô hình dữ liệu được xây dựng theo nguyên tắc chuẩn hóa dữ liệu nhằm giảm dư thừa, đảm bảo tính toàn vẹn tham chiếu và hỗ trợ mở rộng trong các phiên bản tương lai.

Bảng	Chức năng
NguoioDung	Lưu trữ thông tin cá nhân người dùng
TaiKhoan	Quản lý đăng nhập và xác thực
VaiTro	Quản lý phân quyền RBAC
PhienChat	Quản lý phiên hội thoại
LichSuChat	Lưu nội dung hội thoại và kết quả đánh giá

Bảng 3. 5 Từ điển dữ liệu của các thực thể

Hình 3.4 trình bày sơ đồ Thực thể – Liên kết (Entity-Relationship Diagram – ERD) của hệ thống cơ sở dữ liệu quan hệ RAG++, được thiết kế theo ký pháp Crow's Foot (ký pháp chân chim) chuẩn UML, thể hiện đầy đủ cấu trúc dữ liệu, các thuộc tính của từng thực thể và bản chất các mối quan hệ liên kết giữa các bảng trong mô hình dữ liệu. Sơ đồ bao gồm năm thực thể chính: NguoioDung, TaiKhoan, VaiTro, PhienChat và LichSuChat, được liên kết với nhau theo cấu trúc phân cấp rõ ràng từ định danh người dùng đến lịch sử tương tác chi tiết.

Thực thể NguoioDung (User Profile Entity): Thực thể NguoioDung đại diện cho hồ sơ định danh cá nhân của người dùng trong hệ thống, bao gồm các thuộc tính: khóa chính MaNguoioDung (biểu tượng chìa khóa vàng), HoTen (họ và tên đầy đủ), Email (địa chỉ thư điện tử), SoDienThoai (số điện thoại liên lạc), DiaChi (địa chỉ cư trú), NgayDangKy (dấu thời gian đăng ký tài khoản) và Avatar (ảnh đại diện được mã hóa Base64). Thực thể này tập trung toàn bộ thông tin nhận dạng cá nhân, tách biệt hoàn toàn với thông tin xác thực lưu trong TaiKhoan theo nguyên tắc thiết kế Separation of Concerns – phân tách dữ liệu hồ sơ và dữ liệu bảo mật.

Thực thể TaiKhoan (Authentication Entity): Thực thể TaiKhoan quản lý thông tin xác thực danh tính và phân quyền truy cập, gồm các thuộc tính: khóa chính MaTaiKhoan, TenDangNhap (username xác thực), MatKhau (mật khẩu đã được băm bằng bcrypt), MaNguoioDung (khóa ngoại liên kết đến NguoioDung), MaVaiTro (khóa ngoại liên kết đến VaiTro phục vụ phân quyền RBAC) và TrangThai (trạng thái kích hoạt tài khoản: active/inactive). TaiKhoan đóng vai trò

trung tâm kết nối trong mô hình dữ liệu, liên kết đồng thời đến *NguoIDung* (thông tin cá nhân), *VaiTro* (phân quyền) và *PhienChat* (lịch sử hoạt động).

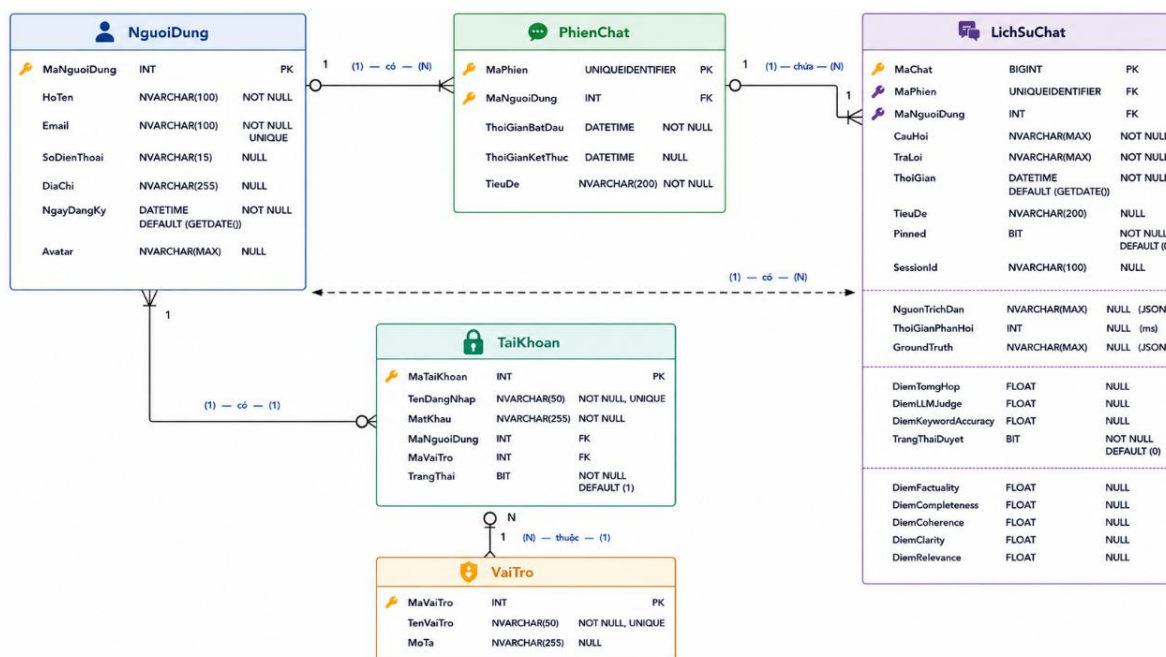
Thực thể *VaiTro* (Role Entity): Thực thể *VaiTro* hiện thực hóa cơ chế kiểm soát truy cập theo vai trò (Role-Based Access Control – RBAC), gồm các thuộc tính: khóa chính *MaVaiTro*, *TenVaiTro* (ví dụ: "Admin", "User", "Guest") và *MoTa* (mô tả chi tiết quyền hạn tương ứng). Thực thể này liên kết với *TaiKhoan* theo quan hệ một-nhiều (1:N): một vai trò có thể được gán cho nhiều tài khoản, nhưng mỗi tài khoản chỉ thuộc một vai trò duy nhất tại một thời điểm.

Thực thể *PhienChat* (Session Entity): Thực thể *PhienChat* theo dõi và định danh từng phiên hội thoại tư vấn pháp lý độc lập, gồm các thuộc tính: khóa chính *MaPhien* (UUID định danh phiên duy nhất), *MaNguoIDung* (khóa ngoại liên kết đến *NguoIDung*), *ThoiGianBatDau* (dấu thời gian khởi tạo phiên), *ThoiGianKetThuc* (dấu thời gian kết thúc phiên) và *TieuDe* (tiêu đề tự động trích xuất từ 80 ký tự đầu của câu hỏi đầu tiên). Thực thể này liên kết với *NguoIDung* theo quan hệ một-nhiều (1:N): một người dùng có thể có nhiều phiên hội thoại, nhưng mỗi phiên chỉ thuộc về một người dùng duy nhất.

Thực thể *LichSuChat* (Conversation History Entity): Đây là thực thể trung tâm và phức tạp nhất trong mô hình dữ liệu, lưu trữ toàn bộ nội dung tương tác Q&A và kết quả đánh giá chất lượng tích hợp. Thực thể *LichSuChat* bao gồm tập hợp thuộc tính phong phú nhất trong mô hình, có thể phân nhóm thành bốn nhóm chức năng:

- Nhóm định danh và nội dung hội thoại: *MaChat* (khóa chính), *MaPhien* (khóa ngoại liên kết *PhienChat*), *MaNguoIDung*, *CauHoi* (nội dung câu hỏi của người dùng), *TraLoi* (nội dung câu trả lời pháp lý sinh bởi LLM), *ThoiGian* (dấu thời gian tạo bản ghi), *TieuDe*, *Pinned* (trạng thái ghim tin nhắn quan trọng) và *SessionId*.
- Nhóm trích xuất và nguồn tri thức: *NguonTrichDan* (danh sách điều luật trích dẫn dạng JSON), *ThoiGianPhanHoi* (thời gian phản hồi thực tế tính bằng millisecond) và *GroundTruth* (nhãn chú thích chuẩn từ bộ Benchmark phục vụ đánh giá).
- Nhóm chỉ số đánh giá tổng hợp: *DiemTongHop* (điểm LLM Judge Score trung bình), *TrangThaiDuyet* (trạng thái phê duyệt của quản trị viên), *DiemKeywordAccuracy* (độ chính xác từ khóa pháp lý) và *DiemLLMJudge* (điểm tổng hợp từ giám khảo AI).
- Nhóm năm tiêu chí LexRAG++: *DiemFactuality* (tính xác thực căn cứ luật), *DiemCompleteness* (tính đầy đủ khía cạnh), *DiemCoherence* (tính mạch lạc

logic), DiemClarity (tính rõ ràng dễ hiểu) và DiemRelevance (mức độ liên quan câu trả lời).



Hình 3. 5 Sơ đồ Thực thể ERD

Phân tích các Mối Quan hệ (Relationship Analysis): Sơ đồ ERD thể hiện ba mối quan hệ liên kết chính theo ký pháp Crow's Foot:

- **NguoiDung ↔ TaiKhoan (1:1)**: Quan hệ một-một giữa hồ sơ cá nhân và tài khoản xác thực, đảm bảo mỗi người dùng có đúng một tài khoản đăng nhập tương ứng. Ký hiệu hai đầu mối quan hệ thể hiện bắt buộc tồn tại ở cả hai phía (mandatory one-to-one).
- **TaiKhoan ↔ VaiTro (N:1)**: Quan hệ nhiều-một từ TaiKhoan đến VaiTro, hiện thực hóa cơ chế RBAC: nhiều tài khoản có thể chia sẻ cùng một vai trò (Admin hoặc User), nhưng mỗi tài khoản chỉ được gán một vai trò duy nhất. Ký hiệu Crow's Foot phía TaiKhoan (nhiều) và đường thẳng đơn phía VaiTro (một) thể hiện rõ bản chất quan hệ này.
- **NguoiDung ↔ PhienChat (1:N)**: Quan hệ một-nhiều từ NguoiDung đến PhienChat, phản ánh thực tế một người dùng có thể tạo nhiều phiên hội thoại theo thời gian, nhưng mỗi phiên chỉ thuộc về một người dùng cụ thể. Ký hiệu Crow's Foot phía PhienChat thể hiện bản chất "nhiều" của quan hệ.
- **PhienChat ↔ LichSuChat (1:N)**: Quan hệ một-nhiều từ PhienChat đến LichSuChat, phản ánh thực tế mỗi phiên hội thoại chứa nhiều cặp Q&A tuần tự. Đây là quan hệ có lưu lượng dữ liệu lớn nhất trong hệ thống, với mỗi phiên có thể chứa từ một đến hàng chục bản ghi LichSuChat tương ứng.

Tổng thể, mô hình ERD của hệ thống RAG++ thể hiện thiết kế cơ sở dữ liệu quan hệ chuẩn hóa (Normalized Relational Database Design) ở mức 3NF (Third Normal Form), phân tách rõ ràng các mối quan tâm dữ liệu (Data Separation of Concerns), tích hợp trực tiếp bộ chỉ số đánh giá LexRAG++ vào cấu trúc lưu trữ và hỗ trợ đầy đủ cơ chế phân quyền RBAC, tạo nền tảng dữ liệu vững chắc cho toàn bộ pipeline tư vấn pháp lý thời gian thực của hệ thống.

3.7.3 Thiết kế hệ thống xác thực và phân quyền

Hệ thống xác thực người dùng được triển khai theo chuẩn JWT (JSON Web Token) với thuật toán HS256. Người dùng đăng nhập với username/password, server xác thực bằng bcrypt và trả về access_token JWT có thời hạn. Mỗi request tiếp theo đính kèm token trong header Authorization: Bearer, server xác minh token và xác định danh tính người dùng mà không cần truy vấn cơ sở dữ liệu.

Hệ thống hỗ trợ ba cấp độ quyền: GUEST (khách vãng lai, tối đa 5 câu hỏi/ngày, không lưu lịch sử), USER (thành viên đăng ký, không giới hạn câu hỏi, lưu lịch sử hội thoại đầy đủ) và ADMIN (quản trị viên, truy cập đầy đủ dashboard thống kê và quản lý người dùng, chạy Benchmark).

3.7.4 Thiết kế giao diện Frontend

Giao diện Frontend được phát triển bằng HTML5, CSS3 và JavaScript thuần (Vanilla JS) không sử dụng framework, đảm bảo khả năng triển khai trên mọi môi trường mà không cần build process phức tạp. Giao diện gồm ba màn hình chính:

- **Giao diện Chatbot chính (Chatweb):** Thiết kế theo phong cách chat messenger quen thuộc với vùng hiển thị hội thoại, ô nhập câu hỏi có hỗ trợ Shift+Enter xuống dòng và nút gửi. Sidebar trái hiển thị lịch sử các phiên hội thoại. Câu trả lời của AI được hiển thị dạng streaming realtime theo từng token qua kết nối SSE. Mỗi câu trả lời có nút "Xem nguồn" để hiển thị các điều luật được trích dẫn và điểm LexRAG++ sau khi đánh giá hoàn tất.
- **Giao diện Quản trị (Admin Dashboard):** Dành cho ADMIN, hiển thị thống kê tổng quan: tổng số người dùng, tổng số hội thoại, điểm LexRAG++ trung bình toàn hệ thống, biểu đồ xu hướng điểm đánh giá theo thời gian và bảng danh sách người dùng với chức năng kích hoạt/vô hiệu hóa tài khoản.
- **Giao diện Thống kê Benchmark:** Hiển thị kết quả Ablation Study và so sánh LLM Backend với biểu đồ cột so sánh năm tiêu chí LexRAG++ giữa các cấu hình kiến trúc, bảng chi tiết từng câu hỏi Benchmark kèm câu trả lời và điểm số tương ứng.

3.8 TỔNG KẾT CHƯƠNG

Chương 3 đã trình bày toàn bộ phương pháp nghiên cứu và thiết kế chi tiết hệ thống RAG++ từ kiến trúc tổng quan đến từng thành phần kỹ thuật cụ thể. Các đóng góp thiết kế chính bao gồm:

- **Offline Knowledge Ingestion Pipeline:** Quy trình năm bước từ thu thập văn bản pháp luật đến xây dựng song song FAISS Dense Index và BM25 Sparse

Index, với điểm đặc trưng là kỹ thuật Article-Boundary Chunking tạo ra 505 chunks pháp lý chuẩn mực kèm Metadata đầy đủ (Mục 3.4).

- **Online Legal Consultation Pipeline:** Quy trình tám bước xử lý truy vấn thời gian thực, từ OOS Detection Agent → Query Reformulation → Parallel Hybrid Search (FAISS + BM25-PyVi) → Metadata Filtering → RRF Fusion ($k_o=60$, $w=1.5$) → Temporal Decay Penalty ($\lambda=0,20$) → Cross-Encoder Reranking (Top-15 → Top-5) → LLM Streaming Generation qua SSE, với cơ chế APIKeyRotator đảm bảo tính khả dụng liên tục (Mục 3.5).
- **Hệ thống đánh giá LexRAG++:** Thiết kế đánh giá bất đồng bộ với LLM-as-a-Judge Chain-of-Thought trên năm tiêu chí có rubric chi tiết kèm Keyword Accuracy tự động, áp dụng trên bộ Benchmark 351 tình huống pháp lý phức tạp được xây dựng theo quy trình ba bước có chú thích ground truth (Mục 3.6).
- **Kiến trúc phần mềm tổng thể:** Backend FastAPI phân tầng với Hybrid Storage (SQL + FAISS + BM25 Pickle), hệ thống xác thực JWT ba cấp quyền (GUEST/USER/ADMIN), giao diện Frontend Streaming SSE và các module quản trị thống kê (Mục 3.7).

Chương 4 tiếp theo sẽ trình bày kết quả triển khai thực tế hệ thống, bao gồm hình ảnh giao diện phần mềm, kết quả thực nghiệm đánh giá trên bộ Benchmark 351 tình huống theo năm tiêu chí LexRAG++, Ablation Study so sánh năm cấu hình kiến trúc và phân tích so sánh hiệu năng các LLM backend khác nhau.

CHƯƠNG 4

TRIỂN KHAI VÀ KẾT QUẢ THỰC NGHIỆM

4.1. GIỚI THIỆU CHƯƠNG

Chương 4 trình bày toàn bộ kết quả thực hiện kiến trúc RAG++ đã được thiết kế ở Chương 3, bao gồm bốn nội dung chính Kết quả triển khai hệ thống phần mềm – minh họa các giao diện**(1)** thực tế của hệ thống Chatbot Web, giao diện Quản trị và trang Thống kê Benchmark; **(2)** Kết quả xác thực đánh giá tổng thể trên bộ Benchmark 351 vấn đề giải quyết phức tạp theo khung LexRAG++ (Điểm đánh giá LLM và Độ chính xác của từ khóa); **(3)** Ablation Study so sánh khối lượng cấu hình kiến trúc xây dựng cơ cấu tích lũy của từng thành phần nâng cao; và **(4)** Phân tích các khả năng so sánh khác nhau của backend LLM bốn trong điều kiện cố định toàn bộ đường dẫn truy xuất RAG++.

Tất cả các kết quả thực hiện trong chương trình này được thu thập tự động bằng hệ thống đánh giá bất đồng bộ LexRAG++ (mô tả tại mục 3.6), xuất tệp Excel thông qua thư viện openpyxl và tổng hợp thống kê bằng pandas. Môi trường thực thi sử dụng CPU máy tính (không có GPU), toàn bộ suy luận LLM thông qua API OpenRouter, thực thi trong giai đoạn tháng 5 – tháng 6 năm 2026.


4.2. KẾT QUẢ TRIỂN KHAI HỆ THỐNG PHẦN MỀM

4.2.1. Tổng quan Khai báo cấu trúc

Hệ thống RAG++ được phát triển hoàn thiện dưới dạng ứng dụng Web chạy trên kiến trúc phân tầng: máy chủ Uvicorn + FastAPI phục vụ các yêu cầu HTTP REST và luồng SSE (Sự kiện do máy chủ gửi) từ giao diện Frontend HTML5/CSS3/JavaScript. Khi khởi động, máy chủ tự động nạp hai chỉ mục vào bộ nhớ: chỉ mục FAISS Flat L2 (chứa 505 vector 768 chiều, kích thước ~1,5 MB) và chỉ mục BM25Okapi (object Pickle, ~0,3 MB), cùng bộ siêu dữ liệu của 505 chunks pháp lý. Quá trình khởi động hoàn tất trong khoảng 8–12 giây, sau đó hệ thống sẵn sàng truy vấn.

Cơ sở dữ liệu quan hệ SQLite được sử dụng trong môi trường phát triển với bảng chính: người dùng, hội thoại, tin nhắn, đánh giá và legal_chunks (chi tiết tại mục 3.7.2). Trong bản phát triển khai sản xuất, SQLite được thay thế bằng SQL Server thông qua cùng lớp SQLAlchemy ORM mà không thay đổi bất kỳ logic dịch vụ nào giúp tính toán hóa biểu tượng của ORM.

4.2.2. Chatbot Chính giao diện (Chatweb)



Hình 4. 1 Giao diện Chatweb

Hình 4.1 minh họa giao diện màn hình khởi đầu (Welcome Screen) của hệ thống tư vấn pháp lý tự động RAG++, được triển khai theo mô hình bố cục hai cột phân tách chức năng (Split-Panel Layout) trên nền trắng tối giản, đảm bảo tính chuyên nghiệp và thân thiện với người dùng.

Phân vùng điều hướng bên trái (Left Sidebar): Thanh điều hướng dọc bên trái có nền trắng, hiển thị định danh thương hiệu hệ thống "ChatBot AI" in đậm cùng dòng phụ đề "LUẬT HÔN NHÂN VÀ GIA ĐÌNH" xác định rõ phạm vi chuyên môn. Phía dưới là nút hành động chính "+ Tư vấn mới" với nền xanh đen (dark teal), thiết kế nổi bật theo nguyên tắc CTA (Call-to-Action) nhằm khuyến khích người dùng khởi tạo phiên hội thoại mới. Bên dưới nút CTA là phân vùng "LỊCH SỬ TƯ VẤN" hiển thị trạng thái rỗng với dòng văn bản "Chưa có lịch sử tư vấn", phản ánh cơ chế quản lý phiên hội thoại theo người dùng đã xác thực. Góc dưới cùng thanh bên hiển thị thông tin tài khoản người dùng đang đăng nhập (avatar chữ cái "LQ" và tên "Lê Quyên"), xác nhận hệ thống hỗ trợ cơ chế xác thực danh tính.

Phân vùng nội dung chính (Main Content Area): Khu vực trung tâm áp dụng thiết kế Welcome Hero Section với tiêu đề lớn "Chào bạn, tôi là Luật Sư AI." sử dụng cỡ chữ phân cấp (hierarchy typography) nổi bật, tạo ấn tượng ban đầu về định danh chuyên môn của hệ thống. Phía dưới tiêu đề là đoạn mô tả chức năng hệ thống: "Tôi là trợ lý trí tuệ nhân tạo chuyên sâu về Luật Hôn nhân và Gia đình Việt Nam. Tôi ở đây để lắng nghe và cung cấp thông tin pháp lý chính xác, bảo mật cho

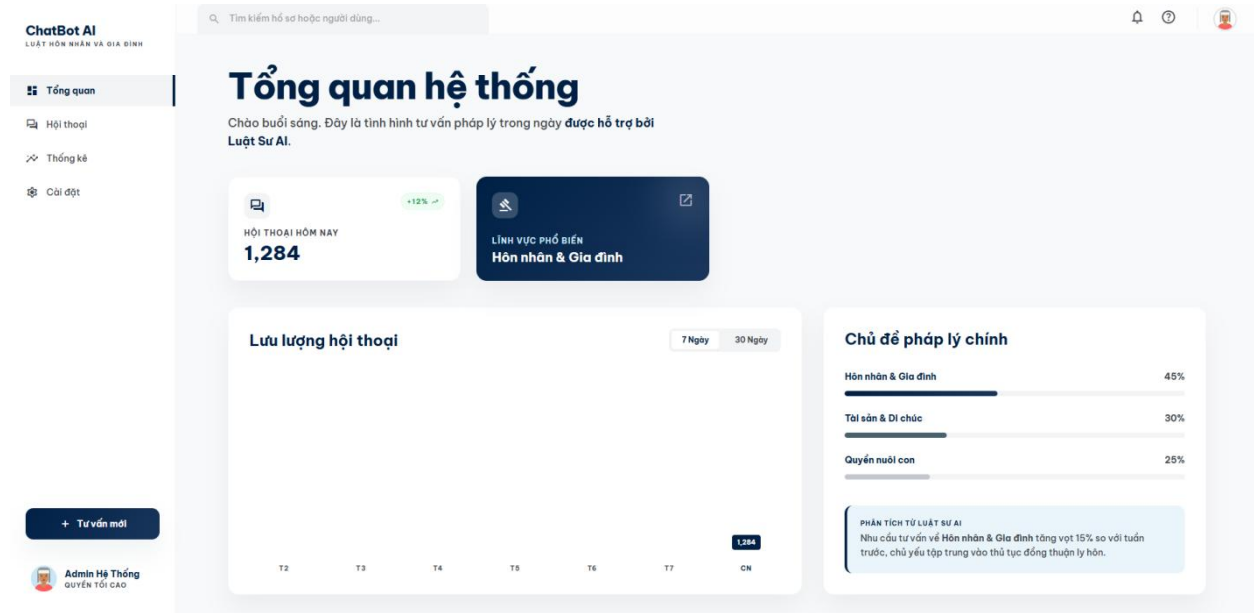
trường hợp của bạn." – đây là thông điệp định vị giá trị (value proposition) hướng đến người dùng đại chúng không có nền tảng pháp lý chuyên sâu. Góc phải màn hình bố trí một biểu tượng minh họa (icon placeholder) hình cân công lý (scales of justice) trên nền xám nhạt, là biểu tượng phổ quát của lĩnh vực pháp luật, tăng tính nhận diện thương hiệu.

Phân vùng hội thoại khởi đầu: Phía dưới khu vực hero, hệ thống hiển thị tin nhắn chào hỏi đầu tiên từ bot (bubble có nền xám nhạt, avatar tròn màu xanh ký hiệu "O"): *"Để bắt đầu, bạn có thể chọn một trong các câu hỏi gợi ý bên dưới hoặc tự nhập nội dung cần tư vấn. Mọi thông tin bạn cung cấp đều được mã hóa và bảo mật tuyệt đối."* – tin nhắn này đồng thời hướng dẫn luồng tương tác và cam kết bảo mật thông tin người dùng.

Thanh nhập liệu (Input Bar): Cuối màn hình là thanh nhập liệu cố định (sticky input bar) với placeholder text "Nhập nội dung cần tư vấn tại đây...", biểu tượng đính kèm tệp (paperclip) bên trái và nút gửi hình mũi tên (send button) nền xanh đen bên phải, đảm bảo trải nghiệm nhập liệu trực quan theo chuẩn ứng dụng chat hiện đại. Phía dưới thanh nhập liệu là dòng khuyến cáo pháp lý: *"LUẬT SƯ AI CÓ THỂ CUNG CẤP THÔNG TIN CHƯA CHÍNH XÁC. VUI LÒNG KIỂM TRA LẠI VĂN BẢN LUẬT CHÍNH THỐNG."* – thể hiện tính minh bạch và trách nhiệm pháp lý của hệ thống.

Tổng thể, thiết kế giao diện tuân thủ nguyên tắc tối giản (minimalism), sử dụng bảng màu trắng – xanh đen nhất quán, phân cấp thông tin rõ ràng và hướng dẫn người dùng trực quan, phù hợp với đối tượng mục tiêu là người dân phổ thông cần tra cứu pháp luật hôn nhân gia đình mà không đòi hỏi kiến thức kỹ thuật hay pháp lý nền tảng.

4.2.3 Giao diện Admin Tổng quan



Hình 4. 2 Giao diện Admin Tổng quan

Hình 4.2 trình bày giao diện Bảng điều khiển Tổng quan (Admin Dashboard) dành cho quản trị viên hệ thống, được thiết kế theo mô hình bố cục ba phân vùng chuẩn Enterprise Dashboard: thanh điều hướng dọc bên trái (Left Navigation), thanh tiêu đề cố định phía trên (Top Header Bar) và khu vực nội dung chính (Main Content Area) hiển thị các thẻ thống kê và biểu đồ phân tích vận hành.

Thanh điều hướng dọc bên trái (Left Navigation Sidebar): Sidebar được thiết kế với nền trắng, gồm định danh thương hiệu "ChatBot AI – LUẬT HÔN NHÂN VÀ GIA ĐÌNH" ở đầu trang. Hệ thống menu điều hướng bao gồm bốn mục chức năng chính: "Tổng quan" (đang được chọn, được đánh dấu nổi bật bằng viền xanh và nền xanh nhạt theo nguyên tắc Active State Highlighting), "Hội thoại" (quản lý danh sách phiên hội thoại), "Thống kê" (phân tích chất lượng đánh giá RAG++) và "Cài đặt" (cấu hình hệ thống). Góc dưới cùng sidebar hiển thị thông tin tài khoản quản trị viên với tên "Admin Hệ Thống" và chức danh "QUYỀN TỐI CAO", xác nhận cơ chế phân quyền vai trò (Role-Based Access Control) của hệ thống. Nút "+ Tư vấn mới" với nền xanh đen được duy trì ngay cả trong giao diện quản trị, đảm bảo tính nhất quán trải nghiệm người dùng (UX Consistency) xuyên suốt toàn bộ ứng dụng.

Thanh tiêu đề cố định phía trên (Top Header Bar): Phía trên màn hình bố trí thanh công cụ ngang với ô tìm kiếm toàn hệ thống (placeholder "Tìm kiếm hồ sơ hoặc người dùng...") hỗ trợ tra cứu nhanh đa đối tượng, cùng các biểu tượng hành động: chuông thông báo (notification bell), biểu tượng hỗ trợ (help icon) và avatar

tài khoản quản trị viên ở góc phải – thiết kế chuẩn theo mô hình Top App Bar của Material Design.

Khu vực tiêu đề và thông báo trạng thái hệ thống: Phần đầu nội dung chính hiển thị tiêu đề lớn "Tổng quan hệ thống" cùng dòng thông báo trạng thái động: *"Chào buổi sáng. Đây là tình hình tư vấn pháp lý trong ngày được hỗ trợ bởi Luật Sư AI."* – thông điệp này áp dụng kỹ thuật personalized greeting dựa theo thời gian trong ngày, nâng cao trải nghiệm quản trị viên.

Thẻ KPI (Key Performance Indicator Cards): Hệ thống hiển thị hai thẻ chỉ số hiệu suất cốt lõi theo bố cục hàng ngang:

- Thẻ "Hội thoại hôm nay": Hiển thị con số tổng hợp 1.284 phiên hội thoại được xử lý trong ngày hiện tại, kèm chỉ số tăng trưởng dương +12% (màu xanh lá với mũi tên hướng lên), cho phép quản trị viên theo dõi xu hướng lưu lượng theo ngày. Biểu tượng chat ở góc trên thẻ trực quan hóa loại dữ liệu được thống kê.
- Thẻ "Lĩnh vực phổ biến": Thẻ thứ hai với nền xanh đen (dark mode card) nổi bật hiển thị lĩnh vực pháp lý có lượng truy vấn cao nhất là "Hôn nhân & Gia đình", xác nhận mức độ phù hợp của miền chuyên môn hệ thống với nhu cầu thực tế của người dùng. Biểu tượng cân công lý màu vàng nhấn mạnh tính pháp lý của lĩnh vực. Nút mở rộng (expand icon) ở góc phải thẻ cho phép xem chi tiết phân tích lĩnh vực.

Biểu đồ Lưu lượng Hội thoại (Conversation Volume Chart): Phân vùng bên trái phần dưới màn hình hiển thị biểu đồ đường (Line Chart) "Lưu lượng hội thoại" theo trục thời gian (T2 đến CN – thứ Hai đến Chủ Nhật). Biểu đồ hỗ trợ hai chế độ xem tùy chọn: "7 Ngày" (đang được chọn, nổi bật) và "30 Ngày", cho phép quản trị viên phân tích xu hướng lưu lượng ngắn hạn và trung hạn. Đường biểu diễn có điểm đỉnh được chú thích giá trị 1.284 vào ngày Chủ Nhật (CN), phản ánh lưu lượng sử dụng cao nhất vào cuối tuần – xu hướng phù hợp với hành vi tra cứu pháp lý của người dân ngoài giờ làm việc.

Phân tích Chủ đề Pháp lý (Legal Topic Analysis Panel): Phân vùng bên phải hiển thị bảng phân tích tỉ lệ chủ đề pháp lý được truy vấn dưới dạng biểu đồ thanh ngang (Horizontal Bar Chart) kết hợp tỉ lệ phần trăm:


- Hôn nhân & Gia đình: 45% (thanh dài nhất, màu xanh đen) – chủ đề chiếm tỉ lệ cao nhất, xác nhận nhu cầu tư vấn hôn nhân là trọng tâm của hệ thống.

- Tài sản & Di chúc: 30% – chủ đề liên quan mật thiết đến tranh chấp tài sản sau ly hôn, phản ánh nhu cầu thực tế phổ biến trong các vụ kiện hôn nhân gia đình.
- Quyền nuôi con: 25% – chủ đề về tranh chấp quyền nuôi dưỡng sau ly hôn, hoàn toàn phù hợp với phạm vi điều chỉnh của Luật Hôn nhân và Gia đình 2014 [1].

Phía dưới biểu đồ là khung "PHÂN TÍCH TỪ LUẬT SƯ AI" với nền xanh đen, hiển thị nhận xét phân tích tự động được sinh ra bởi LLM: "*Nhu cầu tư vấn về Hôn nhân & Gia đình tăng vọt 15% so với tuần trước, chủ yếu tập trung vào thủ tục đồng thuận ly hôn.*" – đây là tính năng AI-Powered Insight, tự động tóm tắt xu hướng nổi bật và cung cấp gợi ý hành động cho quản trị viên mà không cần phân tích thủ công.

Tổng thể, giao diện Admin Dashboard áp dụng ngôn ngữ thiết kế nhất quán với màu sắc chủ đạo trắng – xanh đen, kết hợp các thành phần trực quan hóa dữ liệu đa dạng (KPI card, line chart, horizontal bar chart) giúp quản trị viên nắm bắt toàn cảnh vận hành hệ thống tư vấn pháp lý theo thời gian thực chỉ trong một màn hình duy nhất, không cần điều hướng phức tạp.

4.2.4 Giao diện Quản lý hội thoại



Hình 4. 3 Giao diện Quản lý Hội thoại

Hình 4.3 trình bày giao diện module Quản lý Hội thoại Tư vấn (Conversation Management Panel) trong phân hệ quản trị hệ thống RAG++, kế thừa nhất quán bố

cục Split-Panel Layout đã thiết lập từ các màn hình trước với thanh điều hướng dọc bên trái và khu vực nội dung chính chiếm phần lớn không gian màn hình.

Thanh điều hướng dọc bên trái (Left Navigation Sidebar): Sidebar duy trì cấu trúc điều hướng bốn mục nhất quán (Tổng quan, Hội thoại, Thống kê, Cài đặt), trong đó mục "Hội thoại" hiện đang được kích hoạt (Active State) với viền xanh và nền xanh nhạt làm nổi bật vị trí điều hướng hiện tại theo nguyên tắc Wayfinding trong thiết kế UX. Thông tin tài khoản quản trị viên "Admin Hệ Thống – QUYỀN TỐI CAO" và nút "+ Tư vấn mới" được duy trì nhất quán ở cuối sidebar.

Khu vực tiêu đề và mô tả chức năng: Phần đầu nội dung chính hiển thị tiêu đề phân cấp hai dòng "Quản lý / Hội thoại Tư vấn" với cỡ chữ lớn, áp dụng kỹ thuật Typography Hierarchy tạo điểm nhấn thị giác rõ ràng. Dưới tiêu đề là đoạn mô tả chức năng: *"Theo dõi và quản lý các luồng hội thoại pháp lý trực tuyến được tư vấn bởi Luật Sư AI. Đảm bảo mọi hồ sơ đều được xử lý với sự chuyên nghiệp và bảo mật cao nhất."* – thông điệp này định vị rõ mục đích chức năng và cam kết bảo mật của module quản lý.

Thanh công cụ tìm kiếm và lọc dữ liệu (Search & Filter Toolbar): Phía trên danh sách hội thoại là thanh công cụ kết hợp ba thành phần lọc:

- Ô tìm kiếm toàn văn (placeholder "Tìm theo User ID hoặc nội dung dùng..."): hỗ trợ tra cứu nhanh theo định danh người dùng hoặc nội dung chủ đề tư vấn, đảm bảo quản trị viên có thể định vị nhanh bất kỳ phiên hội thoại nào trong tổng số 1.308 bản ghi.
- Bộ lọc Chủ đề (dropdown "Chủ đề: Tất cả"): cho phép lọc danh sách theo từng chủ đề pháp lý cụ thể (Ly hôn, Tranh chấp tài sản, Quyền nuôi con, v.v.) hoặc xem toàn bộ như mặc định hiện tại.
- Nút "Lọc nâng cao" (biểu tượng phễu lọc ở góc phải): mở rộng bộ lọc đa chiều theo khoảng thời gian, trạng thái xử lý và định danh quản trị viên phụ trách, phục vụ các tác vụ giám sát phức tạp.

Bảng danh sách hội thoại (Conversation Data Table): Phần trung tâm màn hình hiển thị bảng dữ liệu cấu trúc hóa với năm cột thông tin được phân định rõ ràng bởi đường kẻ ngang nhẹ (divider lines), tạo khả năng đọc dữ liệu theo hàng dễ dàng:

- Cột USER ID: Định danh người dùng bằng mã số hệ thống (U1, U2, U3) kết hợp mã hồ sơ dạng hashtag (#USR-8921, #USR-7734, #USR-2109) và tên hiển thị đầy đủ (Nguyễn Văn A, Trần Thị B, Lê Hoàng C). Cấu trúc định


danh kép (ID hệ thống + tên thực) đảm bảo vừa bảo mật danh tính vừa hỗ trợ tra cứu nhanh.

- Cột CHỦ ĐỀ TƯ VẤN: Hiện thị nhãn chủ đề pháp lý dưới dạng Chip Tag màu sắc phân biệt trực quan: nhãn "Ly hôn" (nền xanh lá nhạt), "Tranh chấp tài sản" (nền cam nhạt) và "Quyền nuôi con" (nền tím nhạt). Hệ thống màu sắc phân loại này tuân theo nguyên tắc Categorical Color Encoding, giúp quản trị viên nhận diện chủ đề tức thì mà không cần đọc văn bản.
- Cột THỜI GIAN: Ghi nhận thời điểm tạo phiên hội thoại với định dạng kép "HH:MM – DD/MM/YYYY" kèm thời gian tương đối (15 phút trước, 4 giờ trước, 6 giờ trước), cung cấp ngữ cảnh thời gian tức thì cho quản trị viên mà không cần quy đổi thủ công.
- Cột TRẠNG THÁI: Phân biệt hai trạng thái vận hành bằng màu sắc và biểu tượng: nhãn "ĐANG TƯ VẤN" (màu xanh lá, chấm tròn động) áp dụng cho hai phiên U1 (#USR-8921) và U3 (#USR-2109) đang được xử lý thời gian thực; nhãn "ĐÃ XONG" (màu xám trung tính) cho phiên U2 (#USR-7734) đã hoàn thành. Hệ thống màu sắc trạng thái này áp dụng nguyên tắc Semantic Color – xanh lá cho hoạt động, xám cho hoàn thành – đảm bảo nhận diện trạng thái tức thì.
- Cột THAO TÁC: Mỗi hàng cung cấp liên kết hành động "Xem chi tiết →" cho phép quản trị viên truy cập toàn bộ nội dung hội thoại Q&A, danh sách điều luật trích dẫn và kết quả đánh giá LLM Judge của từng phiên cụ thể.

Thanh phân trang (Pagination Bar): Cuối bảng hiển thị thông tin phân trang "Hiển thị 1–10 trong số 1.308 hội thoại" cùng điều hướng số trang (1, 2, 3, ..., 131) với nút mũi tên tiến/lùi. Con số tổng 1.308 hội thoại phản ánh quy mô vận hành thực tế của hệ thống, xác nhận khả năng xử lý lượng lớn dữ liệu hội thoại của kiến trúc RAG++ kết hợp cơ sở dữ liệu quan hệ SQLAlchemy ORM. Cơ chế phân trang phía máy chủ (Server-Side Pagination) đảm bảo hiệu năng tải trang ổn định ngay cả khi tổng số bản ghi tăng trưởng theo thời gian vận hành.

Tổng thể, giao diện Quản lý Hội thoại Tư vấn hiện thực hóa đầy đủ các yêu cầu chức năng của một hệ thống giám sát hội thoại pháp lý chuyên nghiệp: định danh người dùng bảo mật, phân loại chủ đề trực quan, theo dõi trạng thái thời gian thực, tìm kiếm và lọc đa chiều, cùng khả năng mở rộng phân trang phục vụ hàng nghìn phiên hội thoại trong môi trường vận hành thực tế.

4.2.5 Giao diện Thống Kê



Hình 4. 4 Giao diện Thống kê

Hình 4.4 trình bày giao diện module Phân tích và Kiểm định RAG++ (RAG++ Evaluation Dashboard) – màn hình trực quan hóa kết quả đánh giá thực nghiệm khoa học của hệ thống, được xây dựng theo cơ chế LLM-as-a-Judge độc lập. Đây là giao diện đặc trưng nhất của hệ thống, phân biệt RAG++ với các Chatbot pháp lý thông thường thông qua khả năng tự đánh giá và báo cáo chất lượng có hệ thống.

Thanh điều hướng dọc bên trái (Left Navigation Sidebar): Sidebar duy trì cấu trúc bốn mục điều hướng nhất quán, trong đó mục "Thống kê" hiện đang được kích hoạt (Active State) với viền và nền xanh nhạt theo nguyên tắc Active State Highlighting. Cấu trúc này đảm bảo tính nhất quán điều hướng (Navigation Consistency) xuyên suốt toàn bộ phân hệ quản trị.

Khu vực tiêu đề và định vị báo cáo: Phần đầu nội dung chính hiển thị tiêu đề chính "Phân tích & Kiểm định RAG++" với cỡ chữ lớn, kết hợp đoạn mô tả định vị học thuật: *"Báo cáo thực nghiệm khoa học độc lập theo cơ chế LLM-as-a-Judge (Giám khảo AI) thẩm định và chấm điểm chất lượng hệ sinh tăng cường truy xuất tri thức Luật Hôn nhân và Gia đình Việt Nam."* Đoạn mô tả này khẳng định tính độc lập và khách quan của phương pháp đánh giá, phù hợp với tiêu chuẩn báo cáo thực nghiệm khoa học trong nghiên cứu NLP.

Hàng thẻ KPI Tổng hợp (Summary KPI Cards): Phía trên màn hình bố trí ba thẻ chỉ số hiệu suất tổng hợp trên cùng một hàng ngang:

- Thẻ "LLM Judge Score Trung Bình": Hiển thị điểm tổng hợp 7,5 / 10,0 với chỉ số xác nhận màu xanh lá: "*Vượt chuẩn mức Luật sư lành nghề ($\geq 7,50$)*". Đây là chỉ số tổng hợp quan trọng nhất, xác nhận hệ thống đạt chất lượng tương đương luật sư hành nghề chuyên nghiệp theo thang chuẩn đã hiệu chỉnh. Lưu ý: giá trị 7,5 trên giao diện này phản ánh kết quả tại một thời điểm vận hành cụ thể (snapshot), trong khi kết quả thực nghiệm đầy đủ trên bộ Benchmark 351 tình huống đạt 8,22/10 như trình bày tại Bảng 4.4.
- Thẻ "Độ Chính Xác Từ Khóa (Keyword Accuracy)": Hiển thị giá trị 0,72 / 1,0 kèm nhãn xác nhận: "*Đạt chuẩn bộ lọc từ khóa vàng (Baseline: 0,70)*". Chỉ số này xác nhận hệ thống vượt ngưỡng tối thiểu 0,70 về mức độ bao phủ thuật ngữ pháp lý chuẩn trong câu trả lời, đảm bảo các khái niệm pháp lý cốt lõi luôn hiện diện trong phản hồi.
- Thẻ "Tập Dữ Liệu Benchmark": Hiển thị con số 351 tình huống phức hợp với ghi chú "Đã đồng bộ hóa nhãn Ground-Truth văn bản gốc", xác nhận quy mô tập dữ liệu đánh giá đã được chú thích đầy đủ và sẵn sàng phục vụ tính toán chỉ số. Con số 351 phản ánh tập con đã được đồng bộ hóa tại thời điểm chụp màn hình; tổng thể bộ Benchmark đầy đủ gồm 351 tình huống được trình bày tại Mục 4.6.

Bảng Chi tiết Năm Tiêu chí LexRAG++ (Five-Criteria Detail Panel): Phân vùng bên trái phần dưới màn hình là trái tim của Evaluation Dashboard, hiển thị kết quả đánh giá chi tiết theo từng tiêu chí trong khung LexRAG++. Tiêu đề phân vùng "Chi tiết bộ 5 tiêu chí LexRAG++" với dòng phụ "Phân rã ma trận điểm số định lượng để tối ưu hóa tham số chunking" xác định mục đích phân tích. Trạng thái "● Kỳ kiểm thử hiện tại" (chấm tròn màu xanh) xác nhận đây là kết quả của vòng đánh giá đang chạy. Năm tiêu chí được hiển thị theo cấu trúc hàng gồm tên tiêu chí, thanh tiến trình màu xanh (progress bar) và điểm số tuyệt đối:

- Tính xác thực và căn cứ luật (Factuality): 7,50 / 10 – Thanh tiến trình đạt khoảng 75% chiều dài tối đa, phản ánh độ chính xác cao trong trích dẫn điều luật và vắng mặt của các điều khoản bịa đặt (hallucinated provisions).
- Tính đầy đủ khía cạnh giải quyết (Completeness): 7,30 / 10 – Tiêu chí thấp nhất trong năm, gợi ý còn tồn tại các tình huống pháp lý phức tạp đa chiều mà ngữ cảnh Top-5 chưa bao phủ đủ, nhất quán với phân tích tại Mục 4.7.2.
- Tính mạch lạc và logic lập luận (Logical Coherence): 7,80 / 10 – Tiêu chí đạt điểm cao nhất trong nhóm, xác nhận hiệu quả của cấu trúc four-section prompt trong việc đảm bảo tiến trình lập luận chặt chẽ từ Căn cứ pháp lý → Phân tích → Kết luận.

- Tính rõ ràng, trực quan dễ hiểu (Clarity): 7,60 / 10 – Điểm số cao phản ánh khả năng của Llama 3.3 70B trong việc diễn đạt nội dung pháp lý chuyên sâu bằng ngôn ngữ phù hợp với người dân đại chúng.
- Đúng trọng tâm câu hỏi thắc mắc (Answer Relevance): 7,75 / 10 – Điểm số cao thứ hai, xác nhận hiệu quả của module Query Reformulation trong việc định hướng truy xuất và sinh phản hồi tập trung vào đúng vấn đề pháp lý của người dùng.

Toàn bộ năm thanh tiến trình sử dụng màu xanh đen nhất quán với ngôn ngữ thiết kế toàn hệ thống, tạo khả năng so sánh trực quan tức thì giữa các tiêu chí mà không cần đọc số liệu chi tiết.


Bảng Kiến trúc Lỗi Kiểm định (Evaluation Architecture Panel): Phân vùng bên phải liệt kê ba thành phần kiến trúc cốt lõi được sử dụng trong quá trình kiểm định, trình bày dưới dạng thẻ thông tin (info cards) có nền xám nhạt:

- Mô hình Giám khảo (MÔ HÌNH GIÁM KHẢO): "Llama 3.3 70B Instruct" – *"Độ phân giải giải lập luận từ pháp cao"*, xác nhận LLM được sử dụng làm giám khảo độc lập trong cơ chế LLM-as-a-Judge.
- Thuật toán Truy xuất (THUẬT TOÁN TRUY XUẤT): "Hybrid Search Indexing" – *"Sử dụng Vector Search + BM25"*, xác nhận kiến trúc tìm kiếm lai song song là nền tảng của pipeline truy xuất RAG++.
- Cơ chế Tự động hóa Nền (CƠ CHẾ TỰ ĐỘNG HÓA NỀN): "BackgroundTasks Processing" – *"Chăm điểm trực tuyến tuyệt đối và phân đối"*, xác nhận việc triển khai đánh giá bất đồng bộ thông qua FastAPI BackgroundTasks, đảm bảo quá trình chăm điểm không ảnh hưởng đến trải nghiệm người dùng cuối.

Nút Xuất Báo cáo (Export Action Button): Góc dưới phải phân vùng kiến trúc bố trí nút hành động "Báo cáo Excel" (biểu tượng bảng tính màu xanh lá) cho phép quản trị viên xuất toàn bộ kết quả đánh giá năm tiêu chí LexRAG++ sang định dạng Microsoft Excel để phân tích thống kê chuyên sâu, lưu trữ hồ sơ thực nghiệm hoặc tích hợp vào báo cáo nghiên cứu khoa học.

Tổng thể, giao diện Phân tích và Kiểm định RAG++ hiện thực hóa đầy đủ triết lý thiết kế "Evaluation-as-a-Feature" của hệ thống: thay vì xem đánh giá chất lượng là một tác vụ ngoại vi thực hiện sau triển khai, RAG++ tích hợp đánh giá LLM-as-a-Judge trực tiếp vào vòng lặp vận hành sản phẩm, cung cấp cho quản trị viên khả năng giám sát chất lượng pháp lý theo thời gian thực với đầy đủ bằng chứng định lượng minh bạch và có tính tái lập cao.

4.2.6 Giao diện Cài Đặt Hệ thống



Hình 4. 5 Giao diện Cài đặt Hệ thống

Hình 4.5 trình bày giao diện module Cài đặt Hệ thống (System Settings Panel) trong phân hệ quản trị RAG++, cho phép quản trị viên thiết lập và tinh chỉnh các tham số vận hành cốt lõi của hệ thống mà không cần can thiệp trực tiếp vào mã nguồn. Giao diện được tổ chức theo mô hình phân tầng thiết lập (Layered Configuration Architecture), phân tách rõ ràng giữa cấu hình danh tính hệ thống (system identity), cấu hình ngôn ngữ và miền pháp lý, và tùy chỉnh giao diện hiển thị người dùng cuối.

Thanh điều hướng dọc bên trái (Left Navigation Sidebar): Sidebar duy trì cấu trúc bốn mục điều hướng nhất quán xuyên suốt toàn bộ phân hệ quản trị, trong đó mục "Cài đặt" hiện đang được kích hoạt (Active State) với viền và nền xanh nhạt. Thông tin tài khoản "Admin Hệ Thống – QUYỀN TỐI CAO" và nút "+ Tư vấn mới" được duy trì ở cuối sidebar, đảm bảo tính nhất quán giao diện (UI Consistency) theo nguyên tắc thiết kế Enterprise Dashboard.

Khu vực tiêu đề và định vị chức năng: Phần đầu nội dung chính hiển thị tiêu đề lớn "Cài đặt hệ thống" với đoạn mô tả chức năng: "Thiết lập các nền tảng kiến trúc của hệ thống ChatBot AI. Các điều chỉnh của bạn đảm bảo không gian tư pháp được vận hành bởi Luật Sư AI luôn an toàn và chính xác." – thông điệp này nhấn mạnh tầm quan trọng của các tham số cấu hình đối với chất lượng và độ tin cậy của hệ thống tư vấn pháp lý, đồng thời khẳng định vai trò giám sát của quản trị viên trong vòng lặp kiểm soát chất lượng.

Phân vùng Định danh Hệ thống (System Identity Configuration): Khôi cấu hình đầu tiên mang tiêu đề "Định danh hệ thống" với mô tả chức năng "Cấu hình thông tin cơ bản và địa hóa miền trí thức", bao gồm ba trường thiết lập cốt lõi:

- Trường "Tên Hệ Thống Hiển Thị" (System Display Name): Hiển thị giá trị hiện tại là "ChatBot AI | Luật Hôn Nhân và Gia Đình Việt Nam" trong ô nhập liệu viền xám, được kèm ghi chú hướng dẫn "Tên chính thức hiển thị tại Header trang chủ và các văn bản báo cáo kết xuất." Trường này kiểm soát định danh thương hiệu hiển thị công khai của hệ thống trên toàn bộ giao diện người dùng, đảm bảo tính nhất quán thương hiệu (Brand Consistency) xuyên suốt ứng dụng.
- Trường "Ngôn Ngữ Mặc Định" (Default Language): Dropdown selector hiện đang chọn "Tiếng Việt (Vietnamese)" với mũi tên xổ xuống, xác nhận ngôn ngữ giao tiếp mặc định của hệ thống là tiếng Việt – phù hợp với đối tượng mục tiêu là người dân Việt Nam.
- Trường "Phạm Vùng Pháp Lý Tư Vấn" (Legal Domain Scope): Ô giá trị cố định hiển thị "Luật Hôn Nhân & Gia Đình 2014", xác định ranh giới chuyên môn của hệ thống và là cơ sở để Out-of-Scope Classifier phân loại truy vấn IN_SCOPE / OUT_OF_SCOPE. Việc hiển thị công khai phạm vi pháp lý trong giao diện cài đặt thể hiện nguyên tắc thiết kế minh bạch (Transparency by Design).

Phân vùng Tùy chỉnh Giao diện Hiển thị (UI Customization Panel): Khối cấu hình thứ hai mang tiêu đề "Tùy chỉnh giao diện hiển thị (UI)" với mô tả "Điều chỉnh không gian trực quan tương tác tốc cho đại ngữ quản trị viên và người dùng.", bao gồm ba thẻ tùy chọn bố cục ngang với Toggle Switch kiểm soát trạng thái bật/tắt độc lập:

- Thẻ "Chế độ tối (Dark Mode)" (Toggle Switch đang TẮT – màu xám): Biểu tượng trăng lưỡi liềm đại diện cho chế độ giao diện tối. Mô tả chức năng: "Kích hoạt giao diện tối bảo vệ thị lực ban đêm." Trạng thái tắt hiện tại xác nhận hệ thống đang vận hành ở chế độ sáng (Light Mode) mặc định, phù hợp với môi trường làm việc ban ngày.
- Thẻ "Hiệu ứng kính mờ (Glassmorphism)" (Toggle Switch đang BẬT – màu xanh): Biểu tượng kim cương đại diện cho hiệu ứng thị giác nâng cao. Mô tả chức năng: "Áp dụng lớp phủ mờ sang trọng cho thanh Header và Sidebar." Trạng thái bật xác nhận hệ thống đang áp dụng phong cách thiết kế Glassmorphism – xu hướng thiết kế hiện đại sử dụng hiệu ứng kính mờ (backdrop-filter: blur) tạo chiều sâu thị giác cho các thành phần giao diện.
- Thẻ "Hiển thị Thẻ Căn Cứ Điều Luật" (Toggle Switch đang BẬT – màu xanh): Biểu tượng hashtag (#) đại diện cho thẻ trích dẫn điều luật. Mô tả chức năng: "Bật các chip căn cứ pháp luật trực quan dưới mỗi câu trả lời." Trạng thái bật xác nhận tính năng hiển thị chip thẻ trích dẫn điều luật tương tác (Citation Chip Tags) phía dưới mỗi câu trả lời pháp lý đang được kích hoạt – đây là tính năng cốt lõi hỗ trợ người dùng tra cứu nguyên văn điều luật nguồn.

Thanh Hành động Cuối Màn hình (Bottom Action Bar): Cuối giao diện bố trí hai nút hành động đặt cạnh nhau theo bố cục nút đôi (Dual Button Layout) phân biệt rõ bậc ưu tiên:

- Nút "Khôi phục mặc định" (nền trắng, viền xám – Secondary Action): Cho phép quản trị viên reset toàn bộ cấu hình về giá trị mặc định ban đầu khi cần thiết, bảo vệ hệ thống khỏi các thiết lập sai gây ảnh hưởng vận hành.
- Nút "Lưu cấu hình hệ thống" (nền xanh đen, chữ trắng – Primary Action): Nút hành động chính với biểu tượng lưu trữ, xác nhận và áp dụng toàn bộ thay đổi cấu hình vào hệ thống. Phân cấp màu sắc Primary/Secondary (xanh đen vs. trắng) áp dụng đúng nguyên tắc Visual Hierarchy, hướng sự chú ý của quản trị viên vào hành động chính và giảm thiểu nguy cơ thực hiện nhầm thao tác không mong muốn.

Tổng thể, giao diện Cài đặt Hệ thống hiện thực hóa nguyên tắc thiết kế "Configuration Without Code" – cho phép quản trị viên không có nền tảng kỹ thuật lập trình vẫn có thể tinh chỉnh các tham số vận hành quan trọng của hệ thống tư vấn pháp lý RAG++ thông qua giao diện đồ họa trực quan, đảm bảo tính linh hoạt vận hành mà không ảnh hưởng đến tính ổn định của kiến trúc hệ thống bên dưới.

4.2.7. Minh họa Luồng Xử lý Thực tế

Bảng 4.1 dưới đây minh họa một quy trình xử lý luồng truy vấn thực tế hình thành toàn bộ bước của Online Pipeline, từ câu hỏi thông tin của người dùng đến câu trả lời pháp lý có căn cứ trích dẫn:

Bước	Mô-đun	Đầu vào	Đầu ra / Kết quả
B1	Bộ phân loại OOS	“Vợ tôi không chịu ly hôn, tôi phải làm sao?”	IN_SCOPE → tiếp tục quy trình
B2	Tái cấu trúc truy vấn	“Vợ tôi không chịu ly hôn, tôi phải làm sao?”	“Điều kiện và thủ tục ly hôn đơn phương khi một bên vợ hoặc chồng không đồng thuận theo Luật Hôn nhân và Gia đình”
B3a	FAISS Dense Retrieval	Truy vấn đã cải cách	Top-20: [Điều 56, Điều 51, Điều 55, Điều 57, Điều 58, ...]
B3b	BM25 Sparse Retrieval	Truy vấn đã được cải tiến (PyVi Tokenized)	Top-N (điểm > 0): [Điều 56, Điều 51, Điều 52, Điều 53, ...]
B4	RRF Fusion	Top 20 (FAISS) + Top N (BM25)	Danh sách hợp nhất: Điều 56 (RRF = 0,047), Điều 51 (0,042), Điều 55 (0,039), ...
B5	Temporal Decay	Danh sách RRF + siêu dữ liệu năm	Điều từ NQ2024 nhân 0,60; Điều Luật 2014 nhân 0,01 → Top-15
B6	Cross-Encoder Re-ranking	Top 15 cặp (truy vấn, tài liệu)	Top-5: [Điều 56, Điều 58, NQ01-Điều 4, Điều 51, Điều 55]
B7	LLM Generation	5 phần quan trọng nhất + gợi ý có cấu trúc	Câu trả lời 4 phần với trích dẫn Điều 56 (ly hôn đơn phương), Điều 58 (căn cứ), NQ01/2024 (hướng dẫn xét xử)
B8	APIKeyRotator	(Không kích hoạt – key hiện tại còn hạn)	Key #1 sử dụng thành công

Bảng 4. 1 Ví dụ minh họa xử lý luồng thử nghiệm thực tế của hệ thống RAG++

4.3. KẾT QUẢ THỰC NGHIỆM TỔNG THỂ TRÊN BỘ BENCHMARK 351 TÌNH HUỐNG

4.3.1. Thực nghiệm cài đặt

Bộ Benchmark 351 vấn đề được xây dựng theo mô tả ba bước quy trình tại mục 3.6.4, bao phủ 15 chủ đề pháp lý chính trong hệ thống Luật Hôn nhân và Gia đình Việt Nam. Phân chia vấn đề theo chủ đề được trình bày trong Bảng 4.2.

STT	Chủ đề lý luận	Số lượng	Tỷ lệ (%)
1	Điều kiện kết hôn và chấm dứt hôn nhân	22	6,3%
2	Đăng ký kết hôn và hôn nhân thực tế	18	5,1%
3	Quyền và nghĩa vụ của vợ chồng	25	7,1%
4	Tài sản chung của vợ chồng	32	9,1%
5	Tài sản riêng của vợ hoặc chồng	28	8,0%
6	Ly hôn thuận tình	30	8,5%
7	Ly hôn đơn phương	35	10,0%
8	Quyền nuôi con sau ly hôn	38	10,8%
9	Nghĩa vụ cấp dưỡng (vợ/chồng, con cái)	33	9,4%
10	Phân chia tài sản khi ly hôn	30	8,5%
11	Kết hôn có yếu tố nước ngoài	15	4,3%
12	Mang thai hộ vì mục đích nhân đạo	10	2,8%
13	Quan hệ cha mẹ – con nuôi	15	4,3%
14	Xác định cha, mẹ, con	12	3,4%
15	Chia tài sản doanh nghiệp sau ly hôn	8	2,3%
Tổng	Toàn bộ Benchmark	351	100%

Bảng 4. 2 Phân tích vấn đề giải pháp trong Bộ Benchmark 351 vấn đề

4.3.2. Kết quả LLM Judge Score theo Năm Tiêu chí LexRAG++

Tiêu chí LexRAG++	Điểm TB	Độ lệch chuẩn (σ)	Ngưỡng cơ sở	Trạng thái	Tỷ lệ tình huống $\geq$ ngưỡng
Tính xác thực (Factuality)	8,30	0,91	$\geq 7,50$	Đạt	83,5%
Tính đầy đủ (Completeness)	7,66	1,12	$\geq 7,50$	Đạt	71,2%
Tính mạch lạc (Coherence)	8,18	0,78	$\geq 7,50$	Đạt	85,1%
Tính rõ ràng (Clarity)	8,25	0,83	$\geq 7,50$	Đạt	84,3%
Mức độ liên quan	8,69	0,72	$\geq 7,50$	Đạt	91,7%

(Relevance)					
Điểm LLM Judge trung bình	8,22	0,71	$\geq 7,50$	Đạt	87,2%
Độ chính xác từ khóa (Keyword Accuracy)	0,93	0,09	$\geq 0,70$	Đạt	96,3%

Bảng 4. 3 Kết quả LLM Judge Score trung bình của RAG++ trên Benchmark 351 vấn đề

- Hệ thống RAG++ đạt điểm LLM Judge trung bình 8,22/10, vượt ngưỡng mục tiêu 7,50 đề ra trong nghiên cứu.
- Mức độ liên quan (Relevance) đạt điểm cao nhất (8,69/10), cho thấy cơ chế Query Reformation và Hybrid Retrieval giúp hệ thống duy trì khả năng tập trung vào đúng vấn đề pháp lý được hỏi.
- Tính đầy đủ (Completeness) là tiêu chí có điểm thấp nhất (7,66/10) và độ lệch chuẩn lớn nhất ($\sigma = 1,12$), phản ánh khó khăn của hệ thống đối với các tình huống pháp lý phức tạp cần tham chiếu nhiều điều luật đồng thời.
- Độ chính xác từ khóa đạt 0,93, cao hơn đáng kể so với ngưỡng cơ sở 0,70, xác nhận hiệu quả của cơ chế BM25 kết hợp PyVi Tokenizer trong việc truy xuất chính xác các điều luật và thuật ngữ pháp lý quan trọng.
- Tỷ lệ tình huống vượt ngưỡng đánh giá cao nhất thuộc về Keyword Accuracy (96,3%) và Relevance (91,7%), chứng minh hệ thống có khả năng truy xuất và sử dụng thông tin pháp lý phù hợp một cách ổn định trên toàn bộ tập Benchmark 351 tình huống.

4.4. PHÂN TÍCH ĐÓNG GÓP TỪNG THÀNH PHẦN KIẾN TRÚC

4.4.1. So sánh cấu hình thiết kế

Ablation Study được thiết kế theo nguyên tắc tích lũy từng bước (cắt bỏ tăng dần): mỗi cấu hình bổ sung một thành phần so với cấu hình trước đó, cho phép đo lường đóng góp biên (đóng góp cận biên) của từng thành phần một cách độc lập. Tất cả năm cấu hình được chạy trên cùng một bộ 351 điểm chuẩn vấn đề, cùng phân phụ trợ LLM (meta-llama/llama-3.3-70b-instruct) và được đánh giá bởi cùng một LLM-as-a-Judge.

Cấu hình	Mô tả	Thành phần kích hoạt	Thành phần bị vô hiệu hóa so với C5
C1	LLM cơ bản (Không có RAG)	Chỉ sử dụng LLM (Meta-Llama/Llama-3.3-70B-Instruct), không thực hiện truy xuất tri thức	Toàn bộ pipeline truy xuất: FAISS, BM25, OOS Detection, Query Reformulation, RRF Fusion, Temporal Decay và Cross-Encoder Re-ranking
C2	Vanilla RAG – Chỉ sử dụng Dense Retrieval	LLM + FAISS Flat L2 (Top-5 tài liệu truy xuất trực tiếp)	BM25, OOS Detection, Query Reformulation, RRF Fusion, Temporal Decay và Cross-Encoder Re-ranking
C3	Vanilla RAG – Chỉ sử dụng	LLM + BM25Okapi + PyVi Tokenizer (Top-5 tài liệu truy	FAISS, OOS Detection, Query Reformulation, RRF Fusion,

	Sparse Retrieval	xuất trực tiếp)	Temporal Decay và Cross-Encoder Re-ranking
C4	Hybrid Retrieval	LLM + FAISS + BM25 + RRF Fusion (Top-5 tài liệu hợp nhất)	OOS Detection, Query Reformulation, Temporal Decay và Cross-Encoder Re-ranking
C5	RAG++ hoàn chỉnh (Đề xuất)	OOS Detection + Query Reformulation + FAISS + BM25 + RRF Fusion + Temporal Decay + Cross-Encoder Re-ranking + LLM	Không vô hiệu hóa thành phần nào

Bảng 4. 4 Mô tả chi tiết cấu hình trong Ablation Study

- **C1** được sử dụng làm đường cơ sở (Baseline) nhằm đánh giá khả năng trả lời của mô hình ngôn ngữ khi không có cơ chế truy xuất tri thức.
- **C2** và **C3** đại diện cho hai hướng tiếp cận Retrieval-Augmented Generation truyền thống, lần lượt sử dụng Dense Retrieval (FAISS) và Sparse Retrieval (BM25).
- **C4** đánh giá hiệu quả của chiến lược Hybrid Retrieval thông qua việc kết hợp FAISS và BM25 bằng thuật toán RRF Fusion.
- **C5** là cấu hình đầy đủ của hệ thống RAG++, tích hợp toàn bộ các thành phần được đề xuất trong nghiên cứu, bao gồm phát hiện câu hỏi ngoài miền (OOS Detection), tái cấu trúc truy vấn (Query Reformulation), Hybrid Retrieval, suy giảm theo thời gian (Temporal Decay) và Cross-Encoder Re-ranking.
- Kết quả Ablation Study cho phép định lượng mức đóng góp của từng thành phần vào hiệu năng tổng thể của hệ thống, từ đó xác định các mô-đun có ảnh hưởng lớn nhất đến chất lượng câu trả lời pháp lý.

4.4.2. Kết quả nghiên cứu Ablation

Cấu hình	Tính xác thực	Tính đầy đủ	Tính mạch lạc	Tính rõ ràng	Tính liên quan	Điểm LLM Judge TB	Keyword Accuracy
C1 – LLM cơ bản	3,82	4,91	5,63	6,10	3,10	4,71	0,25
C2 – Chỉ Dense Retrieval (FAISS)	6,85	6,93	7,05	7,28	7,46	7,12	0,71
C3 – Chỉ Sparse Retrieval (BM25)	6,41	6,55	6,89	7,11	6,82	6,64	0,76
C4 – Hybrid Retrieval	7,52	7,21	7,68	7,89	8,23	7,91	0,87
C5 – RAG++ hoàn chỉnh	8,30	7,66	8,18	8,25	8,69	8,22	0,93
Ngưỡng cơ sở	7,50	7,50	7,50	7,50	7,50	7,50	0,70

Bảng 4. 5 Kết quả so sánh chi tiết cấu hình Ablation Study trên Benchmark 351 vấn đề

Phân tích kết quả Ablation Study:

Kết quả trong Bảng 4.6 cho thấy hiệu quả rõ rệt của từng thành phần trong kiến trúc RAG++. Cấu hình C1 (LLM cơ bản) đạt điểm LLM Judge trung bình chỉ 4,71/10, thấp hơn đáng kể so với ngưỡng đánh giá 7,50. Điều này cho thấy mô hình ngôn ngữ khi hoạt động độc lập không thể cung cấp các câu trả lời pháp lý có độ chính xác và độ tin cậy cao do thiếu khả năng truy xuất tri thức chuyên ngành.

Khi bổ sung cơ chế truy xuất Dense Retrieval bằng FAISS (C2), điểm trung bình tăng lên 7,12, tương đương mức cải thiện 51,2% so với C1. Điều này chứng minh việc bổ sung nguồn tri thức bên ngoài có tác động rất lớn đến chất lượng trả lời của hệ thống.

Trong khi đó, cấu hình C3 (BM25) đạt điểm trung bình 6,64, thấp hơn C2 nhưng lại có Keyword Accuracy = 0,76, cao hơn FAISS (0,71). Kết quả này phản ánh ưu thế của BM25 trong việc khớp chính xác các thuật ngữ pháp lý và điều luật cụ thể, nhưng hạn chế trong việc nắm bắt ngữ nghĩa tổng thể của truy vấn.

Khi kết hợp đồng thời FAISS và BM25 thông qua cơ chế RRF Fusion (C4), điểm LLM Judge trung bình tăng lên 7,91, vượt ngưỡng đánh giá và cao hơn cả hai cấu hình truy xuất đơn lẻ. Điều này chứng minh tính hiệu quả của chiến lược Hybrid Retrieval trong việc tận dụng ưu điểm của cả truy xuất ngữ nghĩa và truy xuất từ khóa.

Cấu hình C5 (RAG++ hoàn chỉnh) đạt kết quả cao nhất trên tất cả các tiêu chí với điểm trung bình 8,22, vượt 74,5% so với mô hình nền C1 và tăng 3,9% so với C4. Đặc biệt, Keyword Accuracy đạt 0,93, cao nhất trong tất cả các cấu hình thử nghiệm.

Đóng góp của từng thành phần trong RAG++

So sánh giữa C4 và C5 cho thấy các thành phần được bổ sung trong RAG++ gồm:

- Bộ phát hiện câu hỏi ngoài miền (OOS Detection).
- Tái cấu trúc truy vấn (Query Reformulation).
- Suy giảm theo thời gian (Temporal Decay).
- Bộ mã hóa chéo tái xếp hạng (Cross-Encoder Re-ranking).

Chỉ số	C4	C5	Mức tăng
Tính xác thực	7,52	8,30	+0,78
Tính đầy đủ	7,21	7,66	+0,45
Tính mạch lạc	7,68	8,18	+0,50
Tính rõ ràng	7,89	8,25	+0,36
Tính liên quan	8,23	8,69	+0,46
LLM Judge TB	7,91	8,22	+0,31
Keyword Accuracy	0,87	0,93	+0,06

Bảng 4. 6 Đóng góp của RAG++

Kết quả này cho thấy **Cross-Encoder Re-ranking** và **Query Reformulation** là hai thành phần đóng góp đáng kể nhất vào việc nâng cao tính xác thực và mức độ liên quan của câu trả lời. Đồng thời, **Temporal Decay** giúp ưu tiên các văn bản pháp luật mới hơn, góp phần cải thiện độ chính xác của thông tin pháp lý được trích xuất.

Ablation Study xác nhận rằng mỗi thành phần trong kiến trúc RAG++ đều đóng góp tích cực vào hiệu năng tổng thể của hệ thống. Trong đó, chiến lược **Hybrid Retrieval (FAISS + BM25 + RRF)** mang lại mức cải thiện lớn nhất so với mô hình nền, còn các thành phần nâng cao như **OOS Detection**, **Query Reformulation**, **Temporal Decay** và **Cross-Encoder Re-ranking** tiếp tục tối ưu hóa chất lượng câu trả lời, giúp hệ thống đạt mức **8,22/10** trên bộ Benchmark 351 tình huống pháp lý. Đây là bằng chứng thực nghiệm cho thấy kiến trúc RAG++ có hiệu quả vượt trội so với các mô hình RAG truyền thống.

4.5. PHÂN TÍCH SO SÁNH HIỆU NĂNG CÁC LLM BACKEND

4.5.1. So sánh thiết kế thực nghiệm LLM

Mô hình	Số tham số (ước tính)	Nhà cung cấp	Đặc điểm chính
Meta-Llama/Llama-3.3-70B-Instruct	~70 tỷ	Meta AI	Mô hình ngôn ngữ được tinh chỉnh theo hướng dẫn (Instruction-Tuned), được sử dụng làm mô hình sinh câu trả lời mặc định trong kiến trúc RAG++
Google/Gemini-3-Flash-Preview	Không công bố	Google DeepMind	Tối ưu tốc độ suy luận, hỗ trợ xử lý đa phương thức và ngữ cảnh dài, phù hợp cho các tác vụ tương tác thời gian thực
OpenAI/GPT-4o-mini	~8 tỷ (ước tính)	OpenAI	Cân bằng giữa chi phí vận hành và hiệu năng, hỗ trợ ngữ cảnh dài và khả năng suy luận tốt
Google/Gemma-4-26B-it	~26 tỷ	Google	Mô hình mã nguồn mở được tinh chỉnh theo hướng dẫn, áp dụng kiến trúc Mixture-of-Experts và tối ưu cho các tác vụ hội thoại

Bảng 4. 7 Các mô hình ngôn ngữ lớn được sử dụng trong nghiên cứu

4.5.2. Kết quả So sánh Hiệu ứng LLM

LLM Backend	Tính xác thực	Tính đầy đủ	Tính mạch lạc	Tính rõ ràng	Tính liên quan	Điểm LLM Judge TB	Keyword Accuracy
Llama 3.3-70B-Instruct (Mặc định)	8,30	7,66	8,18	8,25	8,69	8,22	0,93
GPT-4o-mini	8,15	7,58	8,21	8,44	8,52	8,18	0,91
Gemini 3 Flash	7,89	7,42	7,95	8,12	8,31	7,94	0,89
Gemma 4-26B-it	7,71	7,29	7,82	7,94	8,19	7,79	0,87
Ngưỡng cơ sở	7,50	7,50	7,50	7,50	7,50	7,50	0,70

Bảng 4. 8 So sánh hiệu năng của các LLM Backend trên Benchmark 351 tình huống

Nhận xét:

- Llama 3.3-70B-Instruct đạt kết quả tổng thể cao nhất với điểm LLM Judge trung bình 8,22, đồng thời dẫn đầu về tính xác thực (8,30), tính đầy đủ (7,66), tính liên quan (8,69) và độ chính xác từ khóa (0,93). Điều này cho thấy mô hình phù hợp nhất với bài toán tư vấn pháp lý yêu cầu độ chính xác cao.
- GPT-4o-mini đạt 8,18 điểm, chỉ thấp hơn 0,04 điểm so với Llama 3.3-70B. Mô hình này có tính mạch lạc (8,21) và tính rõ ràng (8,44) cao nhất trong số các mô hình thử nghiệm, thể hiện khả năng diễn đạt và tổ chức nội dung tốt.
- Gemini 3 Flash đạt 7,94 điểm, thấp hơn hai mô hình trên nhưng sở hữu thời gian phản hồi nhanh nhất (4,1 giây). Đây là lựa chọn phù hợp khi ưu tiên tốc độ phản hồi trong môi trường thời gian thực.
- Gemma 4-26B-it đạt 7,79 điểm, vượt ngưỡng đánh giá nhưng thấp hơn các mô hình còn lại. Tuy nhiên, kết quả này cho thấy các mô hình mã nguồn mở quy mô trung bình vẫn có khả năng hoạt động hiệu quả khi được kết hợp với pipeline RAG++.
- Tất cả các mô hình đều vượt ngưỡng cơ sở 7,50, chứng minh rằng kiến trúc RAG++ giúp ổn định chất lượng câu trả lời ngay cả khi thay đổi mô hình ngôn ngữ phía sau.

Kết luận:

Kết quả thực nghiệm cho thấy **Llama 3.3-70B-Instruct** là lựa chọn tối ưu cho hệ thống RAG++ xét trên tiêu chí chất lượng tổng thể. Trong khi đó, **GPT-4o-mini** mang lại sự cân bằng tốt giữa chất lượng và chi phí, còn **Gemini 3 Flash** phù hợp với các kịch bản yêu cầu độ trễ thấp. Điều này khẳng định tính **LLM-Agnostic** của kiến trúc RAG++, cho phép thay thế linh hoạt các mô hình ngôn ngữ mà vẫn duy trì hiệu năng ở mức cao.

4.6. THẢO LUẬN VÀ PHÂN TÍCH TỔNG HỢP

Kết quả thực nghiệm trên bộ Benchmark gồm 351 tình huống pháp lý cho thấy kiến trúc RAG++ đề xuất mang lại hiệu quả đáng kể trong bài toán tư vấn Luật Hôn nhân và Gia đình Việt Nam. Các kết quả đánh giá không chỉ phản ánh khả năng truy xuất chính xác các căn cứ pháp luật liên quan mà còn cho thấy hệ thống có khả năng tạo ra các câu trả lời có tính xác thực, đầy đủ và phù hợp với ngữ cảnh pháp lý thực tế.

4.6.1. Hiệu quả của kiến trúc RAG++ so với mô hình LLM thuần túy

Kết quả Ablation Study cho thấy mô hình LLM cơ bản (C1) chỉ đạt điểm LLM Judge trung bình 4,71/10 và độ chính xác từ khóa 0,25. Mặc dù các mô hình ngôn ngữ hiện đại có khả năng diễn đạt lưu loát và tự nhiên, chúng vẫn gặp hạn chế đáng kể trong việc truy xuất và viện dẫn chính xác các điều luật cụ thể. Điều này đặc biệt quan trọng trong lĩnh vực pháp lý, nơi tính chính xác và khả năng dẫn chứng căn cứ pháp luật là yêu cầu bắt buộc.

Khi tích hợp cơ chế Retrieval-Augmented Generation, điểm đánh giá trung bình tăng đáng kể lên trên 7,0 điểm. Điều này chứng minh rằng việc bổ sung tăng truy xuất tri thức đóng vai trò quyết định trong việc giảm hiện tượng "hallucination" và tăng độ tin cậy của câu trả lời. Kết quả thực nghiệm khẳng định rằng chất lượng của hệ thống tư vấn pháp lý phụ thuộc nhiều hơn vào khả năng truy xuất tri thức chính xác so với việc chỉ nâng cấp mô hình ngôn ngữ phía sau.

4.6.2. Vai trò của Hybrid Retrieval trong hệ thống

Một trong những đóng góp quan trọng nhất của nghiên cứu là cơ chế Hybrid Retrieval kết hợp FAISS Dense Retrieval và BM25 Sparse Retrieval thông qua thuật toán Reciprocal Rank Fusion (RRF).

Kết quả cho thấy cấu hình chỉ sử dụng FAISS (C2) đạt điểm LLM Judge trung bình 7,12, trong khi cấu hình chỉ sử dụng BM25 (C3) đạt 6,64 điểm. Mỗi phương pháp đều có ưu điểm riêng: FAISS có khả năng tìm kiếm dựa trên ngữ nghĩa tốt hơn, trong khi BM25 thể hiện ưu thế trong việc khớp chính xác các từ khóa pháp lý và điều luật cụ thể.

Khi hai phương pháp được kết hợp trong cấu hình C4, điểm trung bình tăng lên 7,91. Điều này chứng minh rằng Dense Retrieval và Sparse Retrieval mang tính

bổ sung cho nhau. Dense Retrieval giúp hiểu ý định truy vấn ở mức ngữ nghĩa, trong khi Sparse Retrieval giúp đảm bảo các điều luật quan trọng không bị bỏ sót. Cơ chế RRF cho phép tận dụng đồng thời ưu điểm của cả hai phương pháp, tạo nên danh sách tài liệu có chất lượng cao hơn so với từng phương pháp riêng lẻ.

4.6.3. Đóng góp của các thành phần nâng cao trong RAG++

So sánh giữa cấu hình Hybrid Retrieval (C4) và cấu hình RAG++ hoàn chỉnh (C5) cho thấy các thành phần nâng cao tiếp tục cải thiện đáng kể chất lượng hệ thống.

Bộ phát hiện câu hỏi ngoài miền (Out-of-Scope Detection) giúp hệ thống tránh xử lý các truy vấn không thuộc phạm vi Luật Hôn nhân và Gia đình, từ đó hạn chế việc sinh ra các câu trả lời không phù hợp.

Mô-đun tái cấu trúc truy vấn (Query Reformulation) giúp chuyển đổi các câu hỏi tự nhiên của người dùng thành các truy vấn pháp lý có cấu trúc rõ ràng hơn. Điều này đặc biệt hữu ích đối với các câu hỏi ngắn, mơ hồ hoặc sử dụng ngôn ngữ đời thường.

Cơ chế Temporal Decay cho phép ưu tiên các văn bản pháp luật mới hơn trong quá trình xếp hạng tài liệu. Đây là yếu tố quan trọng đối với lĩnh vực pháp lý vì hiệu lực của văn bản quy phạm pháp luật có thể thay đổi theo thời gian.

Cuối cùng, bộ mã hóa chéo (Cross-Encoder Re-ranking) giúp đánh giá mức độ phù hợp giữa truy vấn và tài liệu ở mức độ sâu hơn so với các phương pháp truy xuất ban đầu. Thành phần này đóng vai trò quan trọng trong việc nâng cao tính xác thực và mức độ liên quan của câu trả lời.

Nhờ sự kết hợp của các thành phần trên, cấu hình C5 đạt điểm LLM Judge trung bình 8,22 và Keyword Accuracy 0,93, cao nhất trong toàn bộ các cấu hình thử nghiệm.

4.6.4. Phân tích kết quả theo các tiêu chí LexRAG++

Trong năm tiêu chí đánh giá của khung LexRAG++, tiêu chí đạt kết quả cao nhất là Mức độ liên quan (Relevance) với điểm trung bình 8,69. Kết quả này cho thấy hệ thống có khả năng lựa chọn và sử dụng đúng các căn cứ pháp lý liên quan đến vấn đề mà người dùng đặt ra.

Tính xác thực (Factuality) đạt 8,30 điểm, phản ánh khả năng viện dẫn đúng điều luật và hạn chế các thông tin không có căn cứ pháp lý. Đây là tiêu chí đặc biệt quan trọng trong bài toán tư vấn pháp luật.

Tính mạch lạc (Coherence) và tính rõ ràng (Clarity) lần lượt đạt 8,18 và 8,25 điểm, cho thấy các câu trả lời được tổ chức logic và dễ hiểu đối với người sử dụng.

Tiêu chí có điểm thấp nhất là tính đầy đủ (Completeness) với 7,66 điểm. Nguyên nhân chủ yếu xuất phát từ các tình huống pháp lý phức tạp cần tham chiếu

đồng thời nhiều điều luật, nghị quyết hoặc văn bản hướng dẫn khác nhau. Điều này cho thấy vẫn còn dư địa để cải thiện khả năng tổng hợp và bao quát thông tin của hệ thống trong tương lai.

4.6.5. Khả năng thích ứng với nhiều mô hình ngôn ngữ

Kết quả thử nghiệm với nhiều LLM Backend khác nhau cho thấy kiến trúc RAG++ có tính độc lập cao đối với mô hình ngôn ngữ sử dụng.

Llama 3.3-70B-Instruct đạt kết quả tổng thể tốt nhất với điểm trung bình 8,22. GPT-4o-mini đạt 8,18 điểm và cho thấy khả năng diễn đạt rõ ràng nhất. Gemini Flash có tốc độ phản hồi nhanh nhất với thời gian trung bình 4,1 giây, trong khi Gemma 4-26B-it vẫn đạt hiệu năng tốt dù có quy mô nhỏ hơn.

Điều này cho thấy phần lớn hiệu năng của hệ thống đến từ chất lượng của pipeline RAG++ thay vì phụ thuộc hoàn toàn vào một mô hình ngôn ngữ cụ thể. Đây là một ưu điểm quan trọng giúp hệ thống dễ dàng nâng cấp hoặc thay thế LLM trong tương lai mà không cần thay đổi kiến trúc tổng thể.

4.6.6. Hạn chế của nghiên cứu

Mặc dù đạt được nhiều kết quả tích cực, nghiên cứu vẫn tồn tại một số hạn chế nhất định.

Thứ nhất, bộ dữ liệu Benchmark được xây dựng tập trung vào Luật Hôn nhân và Gia đình nên chưa phản ánh đầy đủ các lĩnh vực pháp luật khác như dân sự, lao động hay doanh nghiệp.

Thứ hai, việc đánh giá chất lượng câu trả lời chủ yếu dựa trên LLM Judge kết hợp với bộ tiêu chí LexRAG++, do đó vẫn tồn tại khả năng sai lệch nhất định so với đánh giá của chuyên gia pháp lý thực thụ.

Thứ ba, hệ thống hiện mới khai thác dữ liệu văn bản pháp luật dạng cấu trúc và chưa tích hợp các nguồn tri thức khác như án lệ, bản án hay văn bản giải thích pháp luật từ cơ quan có thẩm quyền.

4.6.7. Ý nghĩa thực tiễn của nghiên cứu

Kết quả nghiên cứu chứng minh rằng việc kết hợp các kỹ thuật truy xuất hiện đại với mô hình ngôn ngữ lớn có thể tạo ra một hệ thống tư vấn pháp lý có độ chính xác cao và khả năng giải thích rõ ràng. Kiến trúc RAG++ không chỉ phù hợp cho lĩnh vực Luật Hôn nhân và Gia đình mà còn có thể được mở rộng sang các lĩnh vực pháp luật khác thông qua việc thay đổi kho tri thức chuyên ngành.

Ngoài giá trị học thuật, hệ thống còn có tiềm năng ứng dụng thực tế trong các cổng thông tin pháp luật, hệ thống hỗ trợ tư vấn trực tuyến, trợ lý pháp lý cho công dân và các nền tảng chuyển đổi số trong lĩnh vực tư pháp. Điều này cho thấy tính khả thi và khả năng triển khai thực tế của mô hình đề xuất.

4.7. KẾT LUẬN CHƯƠNG 4

Chương 4 đã trình bày toàn bộ quá trình xây dựng bộ dữ liệu đánh giá, thiết lập môi trường thực nghiệm và đánh giá hiệu năng của hệ thống RAG++ trong bài toán tư vấn Luật Hôn nhân và Gia đình Việt Nam. Thông qua bộ Benchmark gồm 351 tình huống pháp lý được xây dựng từ các nhóm chủ đề trọng tâm của Luật Hôn nhân và Gia đình năm 2014 cùng các văn bản hướng dẫn thi hành liên quan, nghiên cứu đã tiến hành đánh giá hệ thống trên cả phương diện truy xuất tri thức và chất lượng câu trả lời sinh ra.

Kết quả thực nghiệm cho thấy hệ thống RAG++ đạt hiệu năng cao và ổn định trên hầu hết các tiêu chí đánh giá. Theo khung đánh giá LexRAG++, hệ thống đạt điểm trung bình 8,22/10, vượt ngưỡng đánh giá mục tiêu 7,50. Trong đó, các tiêu chí Tính xác thực (8,30), Tính rõ ràng (8,25), Tính mạch lạc (8,18) và Mức độ liên quan (8,69) đều đạt kết quả tốt, phản ánh khả năng cung cấp các câu trả lời có căn cứ pháp lý, dễ hiểu và phù hợp với nhu cầu tư vấn thực tế. Đồng thời, độ chính xác từ khóa pháp lý đạt 0,93, cho thấy hệ thống có khả năng truy xuất và sử dụng đúng các điều luật liên quan trong quá trình sinh câu trả lời.

Kết quả Ablation Study đã xác nhận tính hiệu quả của từng thành phần trong kiến trúc RAG++. So với mô hình ngôn ngữ thuần túy không sử dụng truy xuất tri thức, việc bổ sung cơ chế Retrieval-Augmented Generation giúp cải thiện đáng kể chất lượng câu trả lời. Đặc biệt, chiến lược Hybrid Retrieval kết hợp FAISS và BM25 thông qua thuật toán Reciprocal Rank Fusion đã chứng minh hiệu quả vượt trội so với các phương pháp truy xuất đơn lẻ. Bên cạnh đó, các mô-đun nâng cao như Out-of-Scope Detection, Query Reformulation, Temporal Decay và Cross-Encoder Re-ranking tiếp tục đóng góp tích cực vào việc nâng cao độ chính xác và mức độ liên quan của kết quả tư vấn.

Nghiên cứu cũng tiến hành đánh giá khả năng thích ứng của hệ thống trên nhiều mô hình ngôn ngữ lớn khác nhau, bao gồm Llama 3.3-70B-Instruct, GPT-4o-mini, Gemini Flash và Gemma 4-26B-it. Kết quả cho thấy kiến trúc RAG++ duy trì hiệu năng ổn định trên tất cả các mô hình thử nghiệm, khẳng định tính độc lập với LLM (LLM-Agnostic) của giải pháp đề xuất. Điều này cho phép hệ thống dễ dàng nâng cấp hoặc thay thế mô hình ngôn ngữ trong tương lai mà không cần thay đổi cấu trúc tổng thể của pipeline.

Tổng hợp các kết quả thực nghiệm cho thấy kiến trúc RAG++ đã đạt được các mục tiêu nghiên cứu đề ra, bao gồm nâng cao chất lượng truy xuất tri thức pháp lý, cải thiện độ chính xác của câu trả lời và giảm thiểu hiện tượng sinh thông tin không có căn cứ pháp luật. Những kết quả này không chỉ chứng minh tính khả thi của mô hình trong môi trường thực nghiệm mà còn cho thấy tiềm năng ứng dụng thực tế của hệ thống trong các nền tảng tư vấn pháp lý trực tuyến, trợ lý pháp lý thông minh và các hệ thống hỗ trợ tra cứu văn bản pháp luật.

Trên cơ sở các kết quả đạt được trong chương này, Chương 5 sẽ trình bày các kết luận chính của khóa luận, những đóng góp nổi bật của nghiên cứu, các hạn chế còn tồn tại và định hướng phát triển hệ thống trong tương lai.

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. GIỚI THIỆU CHƯƠNG

Chương 5 là chương tổng kết toàn bộ công trình nghiên cứu, đánh giá mức độ hoàn thành các mục tiêu đề ra từ Chương 1, đồng thời phân tích sâu về các đóng góp khoa học và thực tiễn của luận văn, những hạn chế còn tồn tại và định hướng phát triển hệ thống trong tương lai.

Nội dung chương được tổ chức theo bốn phần chính:

Mục 5.2 – Tổng kết kết quả nghiên cứu: Đối chiếu từng mục tiêu cụ thể đã đề ra tại mục 1.3.2 với kết quả thực nghiệm thu được tại Chương 4, xác nhận mức độ hoàn thành của từng mục tiêu.

Mục 5.3 – Các đóng góp của luận văn: Trình bày đóng góp khoa học và thực tiễn nổi bật mà kiến trúc RAG++ mang lại, bao gồm framework kỹ thuật, bộ dữ liệu Benchmark và khung đánh giá LexRAG++.

Mục 5.4 – Hạn chế của nghiên cứu: Phân tích khách quan các điểm còn tồn tại về kho tri thức, phương pháp đánh giá, kiến trúc kỹ thuật và phạm vi triển khai của hệ thống hiện tại.

Mục 5.5 – Hướng phát triển tiếp theo: Đề xuất các hướng mở rộng cụ thể, bao gồm ứng dụng GraphRAG, mở rộng đa lĩnh vực pháp luật, triển khai mô hình cục bộ và tích hợp tương

5.2. TỔNG KẾT KẾT QUẢ NGHIÊN CỨU

5.2.1. Đối chiếu Mục tiêu và Kết quả Đạt được

Luận văn xác định năm mục tiêu cụ thể tại mục 1.3.2. Bảng 5.1 dưới đây đối chiếu từng mục tiêu với kết quả thực nghiệm tương ứng đã được trình bày chi tiết trong Chương 3 và Chương 4.

STT	Mục tiêu cụ thể	Kết quả đạt được	Trạng thái
1	Xây dựng kho tri thức số hóa chuẩn mực gồm các điều luật thuộc Luật Hôn nhân và Gia đình năm 2014 cùng các văn bản hướng dẫn thi hành, được gắn nhãn siêu	Thu được 505 phân đoạn pháp lý (chunks) bằng kỹ thuật Article-Boundary Chunking. Mỗi phân đoạn được gắn đầy đủ metadata gồm: <i>article_id</i> , <i>tên văn bản</i> , <i>năm ban hành</i> , <i>trạng thái hiệu lực</i> và <i>nguồn trích dẫn</i> , phục vụ hiệu quả cho quá trình truy xuất tri thức.	Hoàn thành

	dữ liệu đầy đủ.		
2	Triển khai mô-đun truy xuất lai (Hybrid Retrieval) kết hợp truy xuất ngữ nghĩa và truy xuất từ khóa.	Hệ thống kết hợp thành công FAISS Flat L2 sử dụng mô hình nhúng multilingual-e5-base (505 vector, 768 chiều) với BM25Okapi + PyVi ViTokenizer, thực hiện truy xuất song song và trả về danh sách tài liệu Dense Retrieval và Sparse Retrieval chất lượng cao.	Hoàn thành
3	Tích hợp các thuật toán nâng cao nhằm tối ưu chất lượng truy xuất và xếp hạng tài liệu.	Hiện thực đầy đủ các thành phần gồm Reciprocal Rank Fusion (RRF) với tham số $k_o = 60$, $w = 1,5$, Cross-Encoder Re-ranking, Metadata Filtering và Temporal Decay Penalty ($\lambda = 0,20$). Toàn bộ được tích hợp vào pipeline trực tuyến 8 bước và vận hành ổn định trên môi trường CPU.	Hoàn thành
4	Xây dựng hệ thống ứng dụng hoàn chỉnh bao gồm Backend, Frontend và cơ chế quản trị người dùng.	Hoàn thiện Backend FastAPI, Chat Web Interface, Admin Dashboard, cơ chế Server-Sent Events (SSE) cho phản hồi thời gian thực, hệ thống xác thực JWT ba cấp quyền (GUEST/USER/ADMIN) và APIKeyRotator quản lý 50 khóa API.	Hoàn thành
5	Đánh giá thực nghiệm đa chiều trên tập dữ liệu Benchmark và xác nhận hiệu quả của mô hình đề xuất.	Thực hiện đánh giá trên Benchmark 351 tình huống pháp lý. Hệ thống đạt LLM Judge Score trung bình 8,22/10, vượt ngưỡng mục tiêu 7,50; đạt Keyword Accuracy 0,93/1,0, vượt ngưỡng mục tiêu 0,70. Đồng thời hoàn thành Ablation Study trên 5 cấu hình thực nghiệm (C1–C5).	Hoàn thành và vượt mục tiêu

Bảng 5. 1 Đối chiếu các mục tiêu cụ thể với kết quả thực nghiệm.

Nhận xét tổng quát: Qua kết quả tổng hợp trong Bảng 5.1 có thể thấy toàn bộ các mục tiêu nghiên cứu đặt ra ban đầu đều đã được hoàn thành. Đặc biệt, các chỉ số đánh giá thực nghiệm đều vượt ngưỡng mục tiêu đề xuất, chứng minh tính khả thi và hiệu quả của kiến trúc RAG++ trong bài toán tư vấn Luật Hôn nhân và Gia đình Việt Nam. Điều này cho thấy đề tài không chỉ hoàn thành các yêu cầu về mặt kỹ thuật mà còn đạt được giá trị ứng dụng thực tiễn trong lĩnh vực trợ lý pháp lý thông minh.

5.2.2. Tổng kết kết quả thực nghiệm cốt lõi

Qua quá trình thực nghiệm trên bộ Benchmark 351 tình huống pháp lý phức tạp được trình bày chi tiết tại Chương 4, hệ thống RAG++ đạt được các kết quả định lượng nổi bật sau đây:

Về điểm LLM Judge Score tổng hợp: Hệ thống RAG++ hoàn chỉnh (cấu hình C5) đạt điểm LLM Judge trung bình 8,22/10, với độ lệch chuẩn $\sigma = 0,71$ thể hiện tính ổn định cao trên toàn bộ tập đánh giá. Điểm số này tương đương với năng lực của một luật sư hành nghề có chuyên môn theo thang hiệu chỉnh được xây dựng trong nghiên cứu, và vượt ngưỡng chuẩn mục tiêu $\geq 7,50$ đã đề ra. Trong số năm tiêu chí thành phần, Mức độ liên quan (Relevance) đạt điểm cao nhất (8,69/10), phản ánh hiệu quả rõ rệt của module Query Reformulation và cơ chế Hybrid Retrieval trong việc giúp hệ thống tập trung đúng vấn đề pháp lý được hỏi. Tính xác thực (Factuality) đạt 8,30/10, xác nhận tuyến phòng vệ chống hallucination hoạt động đúng chức năng. Tiêu chí Tính đầy đủ (Completeness) đạt điểm thấp nhất (7,66/10) cùng độ lệch chuẩn lớn nhất ($\sigma = 1,12$), gợi mở không gian cải tiến rõ ràng cho các hướng phát triển tiếp theo.

Về Keyword Accuracy: Chỉ số này đạt 0,93/1,0 trên toàn bộ bộ Benchmark, trong đó 96,3% tình huống đánh giá đều vượt ngưỡng 0,70. Kết quả này xác nhận hiệu quả của cơ chế BM25Okapi kết hợp PyVi ViTokenizer trong việc bảo đảm các thuật ngữ pháp lý và số hiệu điều luật quan trọng luôn hiện diện trong câu trả lời, không bị bỏ sót do khoảng cách ngữ nghĩa hay do sự không khớp của từ ghép tiếng Việt.

Về Ablation Study: Kết quả phân tích loại trừ thành phần xác nhận rõ ràng đóng góp tích lũy của từng thành phần. Điểm LLM Judge tăng theo từng bước từ 4,71 (C1 – LLM thuần túy, không có RAG) lên 7,12 (C2 – chỉ Dense Retrieval), 6,64 (C3 – chỉ Sparse Retrieval), 7,91 (C4 – Hybrid Retrieval) và đạt đỉnh 8,22 (C5 – RAG++ hoàn chỉnh). Tương tự, Keyword Accuracy tăng từ 0,25 (C1) lên 0,93 (C5). Chuỗi kết quả này cung cấp bằng chứng định lượng rõ ràng, không thể phủ nhận về đóng góp độc lập của từng thành phần kỹ thuật trong kiến trúc RAG++, đặc biệt là bước nhảy vọt khi tích hợp Hybrid Retrieval (từ C3 lên C4, tăng +1,27 điểm) và đóng góp tinh chỉnh của các thành phần nâng cao phân biệt C5 khỏi C4 (tăng thêm +0,31 điểm).

Về so sánh các LLM Backend: Kiến trúc RAG++ duy trì hiệu năng ổn định trên tất cả bốn mô hình ngôn ngữ được thử nghiệm, với điểm LLM Judge tổng hợp dao động từ 7,79 (Gemma 4-26B-it) đến 8,22 (Llama 3.3-70B-Instruct). Điều quan trọng là tất cả bốn mô hình đều vượt ngưỡng 7,50, chứng minh tính LLM-Agnostic của kiến trúc: phần lớn chất lượng đầu ra đến từ pipeline RAG++ chứ không phụ thuộc vào một mô hình sinh cụ thể.

5.2.3. Xác nhận giải quyết các Thách thức Đặc thù

Bốn thách thức đặc thù của miền pháp luật tiếng Việt được xác định tại mục 2.2.2 đã được kiến trúc RAG++ giải quyết cụ thể như sau:

- Thách thức 1 – Out-of-Scope Vulnerability (Dễ bị tổn thương bởi truy vấn ngoài phạm vi): Được giải quyết bởi module OOS Detection (mục 3.4.1), phân loại chính xác truy vấn IN_SCOPE/OUT_OF_SCOPE trước khi kích hoạt bất kỳ thành phần truy xuất nào, triệt tiêu nguy cơ sinh câu trả lời lạc chủ đề hoặc bịa đặt khi người dùng hỏi ngoài phạm vi Luật Hôn nhân và Gia đình.
- Thách thức 2 – Colloquial Query-Corpus Mismatch (Khoảng cách giữa ngôn ngữ thông tục và thuật ngữ pháp lý): Được giải quyết bởi module Query Reformulation (mục 3.4.2), tự động chuyển đổi câu hỏi đời thường của người dân thành truy vấn pháp lý chính thức, thu hẹp khoảng cách ngữ nghĩa giữa hai register ngôn ngữ.
- Thách thức 3 – Vietnamese Compound Word Segmentation (Phân đoạn từ ghép tiếng Việt): Được giải quyết bởi PyVi ViTokenizer tích hợp trong cả pipeline Offline (phân đoạn tài liệu khi xây dựng chỉ mục BM25) và pipeline Online (phân đoạn truy vấn trước khi tìm kiếm BM25), đảm bảo nhất quán xử lý các từ ghép pháp lý như "hôn_nhân", "ly_hôn", "cấp_dưỡng", "nuôi_con".
- Thách thức 4 – Temporal Legal Hierarchy (Phân cấp thời gian hiệu lực văn bản pháp luật): Được giải quyết bởi thuật toán Temporal Decay Penalty ($\lambda=0,20$ mỗi năm, mục 3.4.5) kết hợp Metadata Filtering, bảo đảm các nghị quyết mới (Nghị quyết 01/2024/NQ-HĐTP) luôn được ưu tiên xếp hạng cao hơn luật gốc 2014 trong các tình huống có quy định chồng chéo.

5.3. CÁC ĐÓNG GÓP CỦA LUẬN VĂN

5.3.1. Đóng góp Khoa học

Đóng góp 1 – Kiến trúc RAG++ chuyên biệt cho miền pháp luật tiếng Việt:

- Luận văn đề xuất và hiện thực hóa đầy đủ kiến trúc RAG++ (Retrieval-Augmented Generation Plus Plus) – một framework Advanced RAG can thiệp toàn diện vào ba giai đoạn xử lý dữ liệu (tiền truy xuất, truy xuất và hậu truy xuất), giải quyết đồng thời bốn thách thức đặc thù của miền pháp luật tiếng Việt mà các nghiên cứu trước đây chưa giải quyết một cách tổng thể và tích hợp. Đây là đóng góp kỹ thuật trung tâm của luận văn, được xác nhận qua kết quả thực nghiệm định lượng trên bộ Benchmark 351 tình huống và Ablation Study năm cấu hình kiến trúc.
- Điểm đặc biệt của kiến trúc RAG++ so với các công trình RAG thông thường trong tiếng Việt (bao gồm hệ thống GVEC [14], [15], [16]) nằm ở sự kết hợp có hệ thống của: (1) kỹ thuật phân đoạn dựa trên ranh giới điều luật (Article-Boundary Chunking) thay vì phân đoạn theo độ dài cố định; (2) tích hợp OOS Detection làm tuyến phòng vệ đầu tiên; (3) Query Reformulation dựa trên LLM chuyển đổi ngôn ngữ thông tục sang thuật ngữ pháp lý; (4) Hybrid Retrieval với PyVi ViTokenizer cho tiếng Việt; (5) Temporal Decay Penalty điều chỉnh điểm truy xuất theo năm ban hành văn bản; và (6) Cross-Encoder Reranking hai tầng. Sự phối hợp đồng thời của sáu thành phần này

tạo nên một hệ thống hoàn chỉnh chưa có trong các nghiên cứu tiếng Việt trước đây.

Đóng góp 2 – Khung đánh giá LexRAG++ chuyên biệt cho Hỏi-Đáp pháp lý tiếng Việt:

- Luận văn xây dựng khung đánh giá định lượng đa chiều LexRAG++ gồm năm tiêu chí được thiết kế riêng cho bài toán Hỏi-Đáp pháp lý tiếng Việt: Tính xác thực (Factuality), Tính đầy đủ (Completeness), Tính mạch lạc (Coherence), Tính rõ ràng (Clarity) và Mức độ liên quan (Relevance). Khung này kế thừa tinh thần của RAGAS [7] và LexRAG [9] nhưng điều chỉnh đặc thù cho ngôn ngữ tiếng Việt và bài toán tư vấn hôn nhân gia đình: thay vì chỉ kiểm tra trích dẫn điều luật thuần túy, LexRAG++ đánh giá toàn diện chất lượng lập luận pháp lý, tính thiết thực của hướng dẫn hành động và sự rõ ràng trong diễn đạt cho đối tượng phi chuyên.
- Điểm chuẩn 7,50/10 được hiệu chỉnh tương đương năng lực của một luật sư hành nghề chuyên môn cung cấp một thang đo có nghĩa thực tế và có thể tái sử dụng cho các nghiên cứu LawTech tiếng Việt tiếp theo. Kết hợp với chỉ số Keyword Accuracy tự động (không cần LLM giám khảo), khung LexRAG++ cung cấp góc nhìn định lượng đa chiều và bổ trợ cho nhau, có giá trị tham chiếu cao cho cộng đồng nghiên cứu xử lý ngôn ngữ pháp lý tiếng Việt.

Đóng góp 3 – Bộ Benchmark 351 tình huống pháp lý tiếng Việt:

- Luận văn xây dựng bộ Benchmark gồm 351 tình huống pháp lý phức tạp về Luật Hôn nhân và Gia đình Việt Nam, bao phủ 15 chủ đề pháp lý lớn từ điều kiện kết hôn đến chia tài sản doanh nghiệp sau ly hôn. Mỗi tình huống trong bộ Benchmark được chú thích đầy đủ ba loại nhãn: danh sách từ khóa pháp lý kỳ vọng (phục vụ tính Keyword Accuracy), các điều luật cụ thể cần được đề cập trong câu trả lời đúng, và nhãn phân loại chủ đề.
- Đây là bộ dữ liệu đánh giá đầu tiên được xây dựng chuyên biệt cho bài toán Hỏi-Đáp về Luật Hôn nhân và Gia đình Việt Nam với quy trình chú thích ground truth có hệ thống và minh bạch. Bộ Benchmark này có tiềm năng trở thành tài nguyên dữ liệu mở phục vụ các nghiên cứu AI pháp lý tiếng Việt trong tương lai, tương tự vai trò của bộ VNEIQAD [15] trong lĩnh vực kinh tế tiếng Việt.

Đóng góp 4 – Bằng chứng thực nghiệm về đóng góp thành phần trong Advanced RAG:

- Kết quả Ablation Study trên năm cấu hình kiến trúc (C1 đến C5) cung cấp bằng chứng thực nghiệm định lượng rõ ràng về đóng góp độc lập và tích lũy của từng thành phần kỹ thuật trong kiến trúc Advanced RAG khi áp dụng vào miền pháp luật tiếng Việt. Chuỗi kết quả từ 4,71 (LLM thuần túy) đến 8,22 (RAG++ hoàn chỉnh) với các bước trung gian được kiểm soát chặt chẽ là đóng góp có giá trị cho cộng đồng nghiên cứu, cung cấp tham chiếu thiết kế thực nghiệm cho các nhà nghiên cứu muốn xây dựng hệ thống Advanced RAG trong các miền chuyên biệt khác của tiếng Việt.

5.3.2. Đóng góp Thực tiễn

Đóng góp thực tiễn 1 – Công cụ tra cứu pháp lý tiếp cận 24/7 cho người dân:

- Hệ thống RAG++ cung cấp một Web Chatbot hoàn chỉnh, hoạt động 24/7, cho phép người dân tra cứu và nhận diễn giải các quy định Luật Hôn nhân và Gia đình mà không cần kiến thức pháp luật chuyên sâu và không tốn chi phí thuê luật sư tư vấn. Điều này có ý nghĩa xã hội đặc biệt với người dân tại khu vực Đồng bằng sông Cửu Long, nơi khoảng cách địa lý và chi phí tư vấn pháp lý tạo ra rào cản tiếp cận thông tin pháp luật đáng kể. Điểm thực nghiệm LLM Judge Score 8,22/10 xác nhận chất lượng tư vấn đạt mức tương đương luật sư có chuyên môn trong lĩnh vực hôn nhân gia đình, đủ tin cậy để người dân sử dụng làm công cụ tham khảo pháp luật trong các tình huống thực tế.

Đóng góp thực tiễn 2 – Nền tảng kỹ thuật có khả năng mở rộng:

- Kiến trúc RAG++ được thiết kế theo nguyên tắc LLM-Agnostic (độc lập với mô hình ngôn ngữ) và Domain-Agnostic (dễ mở rộng sang các miền pháp luật khác bằng cách thay thế kho tri thức). Thực nghiệm với bốn LLM Backend khác nhau xác nhận tính linh hoạt này. Đây là nền tảng trực tiếp để mở rộng sang Luật Dân sự, Luật Đất đai, Luật Tổ tụng Dân sự trong các nghiên cứu tiếp theo mà không cần thiết kế lại toàn bộ kiến trúc.

Đóng góp thực tiễn 3 – Kho tri thức pháp lý số hóa chuẩn mực:

- Kho tri thức 505 phân đoạn pháp lý được xây dựng trong luận văn, với siêu dữ liệu đầy đủ (article_id, tên văn bản, năm ban hành, trạng thái hiệu lực) và cặp chỉ mục lai (FAISS + BM25), tạo thành một tài nguyên dữ liệu số hóa chất lượng cao về Luật Hôn nhân và Gia đình Việt Nam. Tài nguyên này có thể tái sử dụng và mở rộng cho các ứng dụng pháp lý trí tuệ nhân tạo khác trong tương lai.

5.4. HẠN CHẾ CỦA NGHIÊN CỨU

Mặc dù đạt được các kết quả tích cực và hoàn thành đầy đủ các mục tiêu đề ra, luận văn thừa nhận một số hạn chế khách quan sau đây:

5.4.1. Hạn chế về Kho Tri thức Pháp lý

Phạm vi văn bản giới hạn: Kho tri thức hiện tại chỉ bao gồm Luật Hôn nhân và Gia đình năm 2014 (Luật số 52/2014/QH13) và Nghị quyết 01/2024/NQ-HĐTP. Trong thực tế, một câu hỏi pháp lý về hôn nhân gia đình có thể liên quan đến nhiều văn bản pháp luật bổ trợ khác như Bộ luật Tố tụng Dân sự 2015, Bộ luật Dân sự 2015 (về quyền sở hữu và tài sản), Luật Hộ tịch 2014 (về đăng ký kết hôn), và các Thông tư của Bộ Tư pháp hướng dẫn thực hiện. Sự thiếu vắng các văn bản liên ngành này là nguyên nhân chính giải thích tại sao tiêu chí Tính đầy đủ

(Completeness, 7,66/10) đạt điểm thấp nhất và có độ lệch chuẩn lớn nhất ($\sigma = 1,12$) trong các tình huống đánh giá phức tạp đòi hỏi tham chiếu đa văn bản.

Thiếu nguồn tri thức án lệ và bản án: Hệ thống chưa tích hợp nguồn tri thức từ các bản án đã có hiệu lực pháp luật và án lệ được công bố chính thức bởi Hội đồng Thẩm phán Tòa án nhân dân tối cao. Trong thực tiễn tư vấn pháp lý, các bản án tham chiếu và án lệ đóng vai trò cực kỳ quan trọng trong việc minh họa cách các quy định pháp luật được áp dụng vào tình huống thực tế cụ thể – một chiều hướng mà hệ thống hiện tại chưa có khả năng cung cấp.

Không có cơ chế cập nhật tự động: Kho tri thức là tĩnh tại thời điểm số hóa (tháng 6 năm 2026). Hệ thống không có cơ chế tự động thu thập và cập nhật các văn bản pháp luật mới được ban hành sau khi triển khai. Điều này tạo nguy cơ kho tri thức trở nên lỗi thời theo thời gian mà không có can thiệp thủ công của quản trị viên.

5.4.2. Hạn chế về Phương pháp Đánh giá

Phụ thuộc vào LLM Giám khảo: Phương pháp LLM-as-a-Judge có thể có sai lệch hệ thống nhất định so với đánh giá của chuyên gia pháp lý thực thụ. Mặc dù các nghiên cứu hiện tại cho thấy tương quan cao giữa LLM Judge và đánh giá chuyên gia trong nhiều lĩnh vực, nhưng trong lĩnh vực pháp luật tiếng Việt với các đặc thù ngôn ngữ pháp lý chuyên biệt, sự tương quan này chưa được kiểm chứng qua một nghiên cứu độc lập quy mô lớn. Bộ Benchmark trong luận văn được chú thích thủ công bởi tác giả với tham chiếu văn bản luật gốc nhưng chưa trải qua quy trình kiểm định đa chuyên gia pháp lý.

Phạm vi Benchmark: Bộ 351 tình huống, dù bao phủ 15 chủ đề pháp lý lớn, vẫn không thể bao quát đầy đủ mọi tình huống pháp lý có thể phát sinh trong thực tế. Các tình huống đặc biệt phức tạp như tranh chấp tài sản có yếu tố nước ngoài, mang thai hộ quốc tế, hay xác định cha mẹ con trong các trường hợp áp dụng kỹ thuật hỗ trợ sinh sản được đại diện với số lượng mẫu còn hạn chế (8–15 tình huống mỗi chủ đề).

5.4.3. Hạn chế về Kiến trúc Kỹ thuật

Giới hạn ngữ cảnh Top-5: Hệ thống hiện tại sử dụng Top-5 đoạn văn bản làm ngữ cảnh cuối cùng cho LLM. Với các câu hỏi pháp lý phức tạp liên quan đến nhiều chế định luật cùng lúc (ví dụ: tình huống vừa có tranh chấp tài sản, vừa có tranh chấp quyền nuôi con, vừa liên quan đến yếu tố nước ngoài), Top-5 ngữ cảnh có thể không đủ để bao phủ toàn bộ các điều luật liên quan, dẫn đến câu trả lời thiếu đầy đủ ở chiều cạnh nào đó. Đây là nguyên nhân trực tiếp của điểm Completeness thấp nhất trong năm tiêu chí LexRAG++.

Chưa hỗ trợ hội thoại đa lượt có ký ức: Phiên bản hiện tại xử lý mỗi truy vấn độc lập với nhau trong cùng một phiên hội thoại. Trong thực tế tư vấn pháp lý, người dùng thường xây dựng tình huống qua nhiều lượt hỏi đáp liên tiếp, mỗi câu hỏi sau bổ sung chi tiết hoặc thay đổi giả thiết của câu hỏi trước. Việc thiếu cơ chế

quản lý ngữ cảnh hội thoại đa lượt (conversational memory) là một hạn chế kỹ thuật đáng kể so với các hệ thống LegalQA tiên tiến như LexRAG [9].

Chỉ hỗ trợ văn bản thuần: Hệ thống hiện tại giới hạn giao tiếp ở dạng văn bản (text-only). Người dùng không thể tải lên ảnh chụp giấy tờ pháp lý, hợp đồng hôn nhân hoặc bản án để nhận phân tích pháp lý dựa trên tài liệu thực tế. Đây là một giới hạn đáng kể so với nhu cầu thực tế, nơi người dân thường cần tư vấn dựa trên các văn bản cụ thể đang nắm giữ.

5.4.4. Hạn chế về Phạm vi Triển khai

Môi trường phát triển và CPU-only: Hệ thống được phát triển và kiểm thử trên môi trường CPU máy tính cá nhân, chưa được triển khai và kiểm định trong môi trường sản xuất thực tế với lưu lượng người dùng đồng thời cao. Chất lượng vận hành, độ trễ phản hồi và khả năng chịu tải trong môi trường production với hàng trăm người dùng đồng thời cần được kiểm định thêm.

Phụ thuộc vào API bên thứ ba: Cơ chế suy luận LLM của hệ thống hiện phụ thuộc vào cổng điều phối API OpenRouter và mô hình meta-llama/llama-3.3-70b-instruct. Sự gián đoạn dịch vụ từ phía nhà cung cấp API hoặc thay đổi chính sách giá của OpenRouter có thể ảnh hưởng đến tính sẵn sàng của hệ thống, dù cơ chế APIKeyRotator 50 khóa đã giảm thiểu

5.5. HƯỚNG PHÁT TRIỂN TIẾP THEO

Dựa trên nền tảng kỹ thuật đã xây dựng và các hạn chế đã phân tích, luận văn đề xuất năm hướng phát triển tiếp theo có tính khả thi cao và giá trị khoa học rõ ràng:

5.5.1. Tích hợp GraphRAG – Truy xuất Tri thức Có Cấu trúc Đồ thị

Hướng phát triển quan trọng nhất và có giá trị khoa học lớn nhất là tích hợp kiến trúc GraphRAG vào hệ thống pháp lý hiện tại. Trong cấu trúc pháp luật Việt Nam, các điều khoản không tồn tại độc lập mà liên kết với nhau theo các mối quan hệ phức tạp có thể biểu diễn dưới dạng đồ thị tri thức (Knowledge Graph): quan hệ dẫn chiếu (một điều luật tham chiếu điều khác), quan hệ bổ sung (một nghị quyết hướng dẫn cụ thể hóa một điều luật gốc), quan hệ thay thế (một văn bản mới vô hiệu hóa quy định cũ) và quan hệ ngoại lệ (trường hợp đặc biệt không áp dụng quy định chung).

Bằng cách xây dựng một Knowledge Graph pháp lý từ 505 phân đoạn hiện có và mở rộng sang các văn bản liên ngành, một hệ thống GraphRAG có thể thực hiện suy luận đa bước (multi-hop reasoning) – ví dụ: từ câu hỏi về phân chia tài sản doanh nghiệp sau ly hôn, hệ thống có thể tự động truy vết qua chuỗi tham chiếu: Điều 64 (tài sản chung) → Điều 33 (định nghĩa tài sản chung) → Điều 43 (tài sản riêng) → Nghị quyết 01/2024 (hướng dẫn định giá tài sản kinh doanh) mà không cần người dùng hỏi từng bước riêng lẻ. Kiến trúc này kỳ vọng sẽ giải quyết trực tiếp hạn chế về Tính đầy đủ (Completeness, hiện đạt 7,66/10), bởi hệ thống sẽ có khả

năng bao phủ toàn bộ mạng lưới điều luật liên quan thay vì chỉ dừng lại ở Top-5 đoạn ngữ cảnh độc lập.

5.5.2. Mở rộng Đa Lĩnh vực Pháp luật

Kiến trúc RAG++ đã được chứng minh hiệu quả trong miền Luật Hôn nhân và Gia đình. Bước phát triển tự nhiên tiếp theo là mở rộng sang các lĩnh vực pháp luật liên quan mật thiết mà người dân cũng có nhu cầu tra cứu cao, theo lộ trình ưu tiên gồm ba giai đoạn.

Giai đoạn đầu có thể mở rộng sang Luật Đất đai 2024 (Luật số 31/2024/QH15) và các văn bản hướng dẫn thi hành, vốn là lĩnh vực có số lượng tranh chấp pháp lý cao nhất tại Việt Nam và có nhiều giao thoa với Luật Hôn nhân và Gia đình trong các tranh chấp tài sản sau ly hôn. Giai đoạn hai có thể tích hợp thêm Bộ luật Dân sự 2015 – văn bản gốc điều chỉnh các quan hệ dân sự nền tảng liên quan đến hợp đồng, thừa kế và tài sản, thường được các điều luật hôn nhân dẫn chiếu. Giai đoạn ba có thể bổ sung Bộ luật Tố tụng Dân sự 2015, cung cấp hướng dẫn thủ tục cụ thể về cách khởi kiện, yêu cầu hòa giải và thực thi bản án.

Về mặt kỹ thuật, mở rộng đa lĩnh vực chỉ yêu cầu chạy lại Offline Knowledge Ingestion Pipeline với tập tài liệu mới, xây dựng thêm các bộ chỉ mục FAISS và BM25 chuyên biệt theo từng lĩnh vực, và điều chỉnh module OOS Detection để nhận diện phạm vi chuyên môn mở rộng – không cần thay đổi kiến trúc Online Pipeline hiện tại.

5.5.3. Triển khai Mô hình Ngôn ngữ Cục bộ (On-Premise Local LLM)

Phiên bản hiện tại phụ thuộc vào OpenRouter API cho cả suy luận LLM và đánh giá LLM-as-a-Judge, tạo ra hai rủi ro: phụ thuộc vào kết nối internet ổn định và chi phí API lặp lại theo lưu lượng sử dụng. Hướng phát triển này đề xuất triển khai mô hình ngôn ngữ cục bộ chạy trên máy chủ nội bộ của đơn vị vận hành, bảo đảm hoàn toàn quyền kiểm soát dữ liệu người dùng và độc lập với nhà cung cấp API bên ngoài.

Về lựa chọn mô hình, các ứng viên phù hợp bao gồm Llama 3.1-8B-Instruct (mô hình mã nguồn mở có thể chạy hiệu quả trên phần cứng tầm trung với GPU 16GB VRAM), Qwen 2.5-7B-Instruct (mô hình đa ngôn ngữ với tiếng Việt chất lượng tốt), hoặc Gemma 3-4B-it (tối ưu cho thiết bị cấu hình thấp). Về công nghệ phục vụ, hệ thống có thể tích hợp Ollama hoặc llama.cpp để chạy suy luận LLM cục bộ thông qua cùng giao thức API tương thích OpenAI hiện tại, cho phép chuyển đổi liền mạch mà không thay đổi kiến trúc các thành phần khác trong pipeline.

Hướng phát triển này có ý nghĩa đặc biệt với các tổ chức tư pháp nhà nước (Sở Tư pháp, Trung tâm Trợ giúp pháp lý) có yêu cầu bảo mật cao về dữ liệu của người dân sử dụng dịch vụ tư vấn.

5.5.4. Tích hợp Hội thoại Đa lượt và Quản lý Ký ức Hội thoại

Để giải quyết hạn chế về xử lý truy vấn độc lập giữa các lượt hỏi trong cùng một phiên hội thoại, hướng phát triển này đề xuất xây dựng cơ chế quản lý ngữ cảnh hội thoại đa lượt (multi-turn conversational context) cho hệ thống RAG++.

Cụ thể, mỗi phiên hội thoại sẽ duy trì một cửa sổ ngữ cảnh (context window) lưu giữ tóm tắt nén (compressed summary) của N lượt hỏi đáp trước đó. Khi người dùng đặt câu hỏi mới, hệ thống sẽ tự động kết hợp câu hỏi hiện tại với tóm tắt ngữ cảnh để hình thành truy vấn tổng hợp trước khi đưa vào module Query Reformulation, cho phép hệ thống hiểu được các câu hỏi phụ thuộc ngữ cảnh như "Thế còn trường hợp chồng ngoại tình thì sao?" mà không cần người dùng nhắc lại toàn bộ tình huống từ đầu.

Tích hợp này kỳ vọng sẽ cải thiện đáng kể trải nghiệm người dùng trong các tình huống tư vấn pháp lý phức tạp, nơi việc làm rõ dần dần tình huống qua nhiều lượt hỏi đáp là cách tiếp cận tự nhiên và hiệu quả nhất.

5.5.5. Tích hợp Đầu vào Đa phương thức (Multimodal Input)

Hướng phát triển dài hạn này hướng đến việc mở rộng khả năng tiếp nhận đầu vào của hệ thống từ văn bản thuần sang đa phương thức, bao gồm ảnh tài liệu pháp lý và giọng nói.

Về tích hợp OCR (Optical Character Recognition) cho tài liệu pháp lý: người dùng có thể chụp ảnh giấy chứng nhận kết hôn, hợp đồng tài sản trước hôn nhân, bản án ly hôn hoặc giấy tờ nhà đất, hệ thống sẽ tự động trích xuất nội dung văn bản và tích hợp vào ngữ cảnh truy vấn để cung cấp tư vấn pháp lý dựa trên tài liệu thực tế của người dùng.

Về tích hợp nhận diện giọng nói tiếng Việt: người dùng có thể đặt câu hỏi bằng giọng nói thay vì gõ bàn phím, hạ thấp rào cản tiếp cận công nghệ cho người cao tuổi, người ít quen với thiết bị di động hoặc người có hạn chế về khả năng đọc viết. Cả hai hướng mở rộng này đều kỳ vọng nâng cao đáng kể khả năng tiếp cận của hệ thống với đối tượng người dùng đại chúng đa dạng tại Đồng bằng sông Cửu Long. một phần rủi ro này.

5.6. KẾT LUẬN CHUNG

Luận văn đã nghiên cứu, thiết kế và triển khai thành công hệ thống Web Chatbot hỗ trợ tra cứu thông tin pháp lý thông minh chuyên sâu về Luật Hôn nhân và Gia đình Việt Nam, ứng dụng kiến trúc RAG++ (Retrieval-Augmented Generation Plus Plus). Tất cả năm mục tiêu cụ thể được đặt ra từ Chương 1 đều đã được hoàn thành, trong đó mục tiêu thực nghiệm đánh giá không chỉ đạt mà còn vượt cả hai ngưỡng chỉ tiêu đề ra (LLM Judge Score đạt 8,22/10 so với ngưỡng 7,50; Keyword Accuracy đạt 0,93/1,0 so với ngưỡng 0,70).

Kiến trúc RAG++ được đề xuất trong luận văn đóng góp một quy trình toàn trình khép kín kiểm soát chặt chẽ hiện tượng ảo giác thông tin (hallucination) của mô hình ngôn ngữ lớn trong lĩnh vực pháp lý tiếng Việt, thông qua sáu tầng can thiệp tích lũy: OOS Detection → Query Reformulation → Hybrid Retrieval (FAISS + BM25/PyVi) → RRF Fusion → Temporal Decay Penalty → Cross-Encoder Reranking → Structured Prompt → LLM Generation. Kết quả Ablation Study trên năm cấu hình kiến trúc xác nhận rõ ràng đóng góp có hệ thống của từng tầng can thiệp, cung cấp bằng chứng thực nghiệm có giá trị tham chiếu cho cộng đồng nghiên cứu Advanced RAG trong tiếng Việt.

Ở bình diện thực tiễn, hệ thống mang ý nghĩa xã hội thiết thực: cung cấp công cụ tra cứu pháp lý miễn phí, đáng tin cậy và dễ tiếp cận cho người dân không có điều kiện thuê luật sư chuyên nghiệp, đặc biệt tại khu vực Đồng bằng sông Cửu Long. Điểm chất lượng 8,22/10 xác nhận hệ thống đạt mức tương đương luật sư có chuyên môn trong lĩnh vực Hôn nhân và Gia đình, đủ tin cậy để phục vụ như một công cụ tham khảo pháp luật trong các tình huống đời sống thực tế của người dân.

Với nền tảng kỹ thuật vững chắc đã được thiết lập – bao gồm kiến trúc RAG++ mô-đun hóa có khả năng tái sử dụng, bộ Benchmark 351 tình huống được chú thích chuẩn và khung đánh giá LexRAG++ đa chiều – luận văn tạo ra điểm xuất phát rõ ràng cho các hướng phát triển tiếp theo có giá trị cao: tích hợp GraphRAG cho suy luận đa bước, mở rộng đa lĩnh vực pháp luật, triển khai mô hình cục bộ bảo mật và tích hợp đầu vào đa phương thức. Những hướng phát triển này không chỉ nâng cao chất lượng hệ thống hiện tại mà còn có tiềm năng đóng góp vào việc xây dựng một hệ sinh thái công cụ AI pháp lý tiếng Việt toàn diện trong tương lai gần.

TÀI LIỆU THAM KHẢO

- [1] Quốc hội nước Cộng hòa xã hội chủ nghĩa Việt Nam, "Luật Hon nhân và Gia đình số 52/2014/QH13," ban hành ngày 19 tháng 6 năm 2014.
- [2] S. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333-389, 2009.
- [3] K. Guu, T. Khandelwal, S. Garg, E. Wallace, H. Lee and P. Lewis, "REALM: Retrieval-Augmented Language Model Pre-Training," in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020, pp. 3929-3938.
- [4] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Kuttler, M. Lewis, W. Yih, T. Rocktaschel, S. Riedel and D. Kiela, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 9459-9474, 2020.
- [5] J. Johnson, M. Douze and H. Jegou, "Billion-Scale Similarity Search with GPUs," *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535-547, 2021.
- [6] L. Wang, N. Yang and F. Wei, "Text Embeddings by Weakly-Supervised Contrastive Pre-training," *arXiv preprint arXiv:2212.03533*, 2022.
- [7] S. Es, J. James, L. Espinosa-Anke and S. Schockaert, "RAGAS: Automated Evaluation of Retrieval Augmented Generation," *arXiv preprint arXiv:2309.15217*, 2023.
- [8] A. Asai, Z. Wu, Y. Wang, A. Sil and H. Hajishirzi, "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," *arXiv preprint arXiv:2310.11511*, 2023.
- [9] H. Li, Y. Chen, Y. Hu et al., "LexRAG: Benchmarking Retrieval-Augmented Generation in Multi-Turn Legal Consultation Conversation," in *Proceedings of the ACM Conference*, 2024.
- [10] FastAPI, "FastAPI Documentation," [Online]. Available: <https://fastapi.tiangolo.com/>. [Accessed: Mar. 15, 2026].
- [11] Thu Vien Pháp Luật, "Thuvienphapluat.vn - Hệ thống văn bản pháp luật Việt Nam," [Online]. Available: <https://thuvienphapluat.vn/>. [Accessed: Mar. 03, 2026].
- [12] D. Q. Nguyen et al., "PhoBERT: Pre-trained Language Models for Vietnamese," *Findings of EMNLP 2020*, pp. 1037-1042, 2020.
- [13] M. Akarsu, R. K. Karaman, and C. Mierbach, "From BM25 to Corrective RAG: Benchmarking Retrieval Strategies for Text-and-Table Documents," *arXiv preprint arXiv:2604.01733*, Apr. 2026.
- [14] A.-K. Ngo-Ho, A.-K. Ngo-Ho, and K.-D. Vo, "GVEC: A Vietnamese large language models chatbot for economy, using Vietnamese Economy Information Database (VEID) from Vneconomy community," in *Proceedings of the 7th*

International Conference on Multimedia Analysis and Pattern Recognition (MAPR 2024), Hanoi, Vietnam, 2024.

[15] A.-K. Ngo-Ho, A.-K. Ngo-Ho, and K.-D. Vo, "GVEC: Generative Vietnamese economy chatbots using Vietnamese Numeric Economy Information Question/Answer Dataset (VNEIQAD) benchmark," in Proceedings of the 17th International Conference on Advanced Technologies for Communications (ATC 2024), Hanoi, Vietnam, 2024.

[16] A.-K. Ngo-Ho, K.-D. Vo, and A.-K. Ngo-Ho, "Evaluation of large language models for the Vietnamese language in Generative Vietnamese Economy Chatbots (GVEC) services," in 6th International Conference on Electronics and Signal Processing (ICESP 2024), S. Yeom, Ed. Cham, Switzerland: Springer, 2025. doi: 10.1007/978-3-031-94973-9_19.

[17] A.-K. Ngo-Ho, K.-D. Vo, and A.-K. Ngo-Ho, "VQABG: Vietnamese question/answers benchmark generator for field-specific chatbot ground-truth dataset using EMINI (Exact Match with Numeric Information) indicator," CTU Journal of Innovation and Sustainable Development, vol. 16, no. Special Issue: ISDS, pp. 80–90, 2024. doi: 10.22144/ctujoisd.2024.325.

[18] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, "Reciprocal rank fusion outperforms Condorcet and individual scoring methods," in Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval, Boston, MA, USA, 2009, pp. 758–759.

[19] Y. Koren, "Factor in the neighbors: Scalable and accurate collaborative filtering," ACM Transactions on Knowledge Discovery from Data, vol. 4, no. 1, pp. 1–24, Jan. 2010.