

Báo Cáo Tiến Độ Tham Khảo các Bài Báo Khoa Học

Đề tài: *Ứng dụng công nghệ RAG++ xây dựng chatbot trợ giúp pháp lý thông minh về luật hôn nhân và gia đình*

Bài Báo 1:

- **Tên bài báo:** Agentic RAG-Based Legal Advisory Chatbot: A Knowledge-Driven Approach for Vietnamese Legal System
- **Tên bài báo(Tiếng việt):** Chatbot tư vấn pháp luật dựa trên Agentic RAG: Một cách tiếp cận định hướng tri thức cho hệ thống pháp luật Việt Nam
- **Vấn đề nghiên cứu:** Hệ thống pháp luật Việt Nam có quy mô đồ sộ với hơn 54.000 văn bản trải dài trên 12 cấp độ phân cấp phức tạp (mang đặc thù của hệ thống dân luật). Các hệ thống RAG (Retrieval-Augmented Generation) truyền thống và tìm kiếm từ khóa hiện tại gặp nhiều hạn chế trong việc xử lý các truy vấn pháp lý phức tạp, không nắm bắt được mức độ thẩm quyền của văn bản, thiếu khả năng suy luận chuyên ngành và khó tích hợp nhiều nguồn tài liệu khác nhau
- **Phương pháp nghiên cứu:**
 - + Nhóm tác giả đề xuất một kiến trúc Agentic RAG trung tâm, sử dụng một "Tác tử điều phối" (Router Agent) để phân tích truy vấn và phân chia tác vụ một cách thông minh cho các "Tác tử pháp lý chuyên biệt" (như Tác tử luật định, Tác tử án lệ, Tác tử tuân thủ, Tác tử thủ tục).
 - + Các tác tử này được kết nối thông qua một hạ tầng máy chủ thống nhất (Tools/MCP Server) cho phép tìm kiếm thông tin đa phương thức: tìm kiếm vector (vector search), truy vấn cơ sở dữ liệu đồ thị (graph database), tìm kiếm trên web và tích hợp các API bên ngoài (vbpl.vn, thuvienphapluat.vn).
 - + Dữ liệu được xử lý bằng phương pháp phân đoạn ngữ nghĩa (semantic chunking) nhiều cấp độ, sử dụng các mô hình câu tiếng Việt (Vietnamese sentence transformers) để tối ưu hóa việc giữ lại cấu trúc phân cấp của văn bản pháp luật.
- **Dữ liệu sử dụng:**
 - + Hệ thống thu thập và xử lý 54.000 văn bản quy phạm pháp luật đang có hiệu lực từ Cơ sở dữ liệu quốc gia về văn bản pháp luật (vbpl.vn). Dữ liệu này trải dài trên 12 cấp độ tài liệu khác nhau (Hiến pháp, Bộ luật, Nghị định, Thông tư, Quyết định của tòa án...).

- + Để đánh giá, nhóm nghiên cứu đã sử dụng một tập dữ liệu gồm 1.247 câu hỏi truy vấn pháp lý thực tế do các chuyên gia pháp lý có hơn 8 năm kinh nghiệm biên soạn.
- **Kết quả đạt được:**
 - + Hệ thống đạt độ chính xác 82,3% trong các tình huống tư vấn pháp lý thực tế.
 - + Vượt trội hơn các hệ thống RAG cơ sở hiện tại với mức cải thiện 17,2% về độ chính xác ngữ cảnh (context precision) và 29,7% về độ bao phủ ngữ cảnh (context recall).
 - + Đánh giá thực tế từ người dùng và chuyên gia (gồm 47 người tham gia với 847 câu hỏi) cho thấy mức độ hài lòng tổng thể rất cao, đạt 4,18/5,0.
 - + Các chuyên gia pháp lý đánh giá tính chính xác của trích dẫn đạt 4,31/5,0 và điểm chấp nhận chuyên môn tổng thể đạt 4,16/5,0.
- **Những hạn chế:**
 - + Hệ thống chỉ được đào tạo trên dữ liệu pháp lý, nên dễ gặp lỗi với các câu hỏi ngoài phạm vi (khoảng 20% đánh giá thấp xuất phát từ các truy vấn không liên quan đến pháp luật).
 - + Việc cập nhật dữ liệu theo thời gian thực gặp độ trễ xử lý trước khi các văn bản mới có thể được tìm kiếm.
 - + Thời gian phản hồi (latency) kéo dài từ 5-15 giây có thể gây khó chịu cho người dùng kỳ vọng nhận được câu trả lời ngay lập tức.
 - + Khoảng 31,4% các lỗi của hệ thống liên quan đến việc diễn giải pháp lý quá phức tạp, điều này cho thấy AI vẫn cần có sự giám sát và xác nhận từ các chuyên gia con người.
- **Link tham khảo:** <https://www.scitepress.org/Papers/2025/137354/137354.pdf>
- **Các tác giả:** Pham Thi Xuan Hien (Đại học Công nghiệp TP.HCM), Duong Ngoc Thao Nhi (Học viện Hành chính Quốc gia), và Pham Thi Ngoc Huyen (Đại học Luật TP.HCM)

Bài Báo 2:

- **Tên bài báo:** LexRAG: Benchmarking Retrieval-Augmented Generation in Multi-Turn Legal Consultation Conversation.
- **Tên bài báo(Tiếng việt):** LexRAG: Xây dựng bộ tiêu chuẩn đánh giá hệ thống tạo văn bản tăng cường truy xuất (RAG) trong hội thoại tư vấn pháp luật đa lượt.
- **Vấn đề nghiên cứu:**
 - + Mặc dù RAG (Retrieval-Augmented Generation) rất hiệu quả trong việc cải thiện các Mô hình ngôn ngữ lớn (LLM), nhưng hiện tại chưa có một bộ tiêu chuẩn (benchmark) nào được thiết kế riêng để đánh giá hiệu quả

của hệ thống RAG trong lĩnh vực pháp lý, đặc biệt là trong các cuộc tư vấn pháp luật đa lượt thực tế.

- + Các kịch bản tư vấn pháp luật thường rất phức tạp: người dùng thiếu kiến thức chuyên môn nên câu hỏi thường tiến triển qua nhiều lượt, yêu cầu làm rõ, xác nhận và sửa đổi chi tiết.
- + Hệ thống cần phải xử lý các thông tin không liên quan từ những lượt hội thoại trước, quản lý những thay đổi chủ đề đột ngột, và hiểu được logic pháp lý ẩn chứa thay vì chỉ dựa vào sự tương đồng về từ vựng hay ngữ nghĩa thông thường. Các bộ tiêu chuẩn cũ chỉ tập trung vào nhiệm vụ đơn giản như tìm kiếm án lệ hay dự đoán bản án.

- **Phương pháp nghiên cứu:**

- + Nhóm tác giả đề xuất LexRAG, bộ tiêu chuẩn đầu tiên để đánh giá hệ thống RAG trong tư vấn pháp luật đa lượt, tập trung vào 2 tác vụ cốt lõi: (1) Truy xuất kiến thức hội thoại (Conversational knowledge retrieval) và (2) Tạo phản hồi (Response generation).
- + Phát triển bộ công cụ mã nguồn mở LexiT dành riêng cho hệ thống RAG pháp lý. LexiT bao gồm quy trình xử lý dữ liệu (Data), quy trình thực thi (Pipeline: gồm các chiến lược tiền xử lý như Last Query, Full Context, Full Queries, Query Rewrite và nhiều công cụ truy xuất như BM25, BGE, GTE), và mô-đun đánh giá (Evaluation).
- + Thiết kế một hệ thống tự động đánh giá LLM-as-a-judge (dùng LLM làm giám khảo) kết hợp với kỹ thuật lập luận từng bước (Chain-of-Thought) để chấm điểm phản hồi theo 5 chiều: Tính xác thực (Factuality), Sự hài lòng của người dùng (User Satisfaction), Độ rõ ràng (Clarity), Tính mạch lạc logic (Logical Coherence), và Tính đầy đủ (Completeness).

- **Dữ liệu sử dụng:**

- + 1.013 mẫu hội thoại đa lượt, mỗi mẫu bao gồm 5 lượt hỏi đáp tiến triển.
- + Kho lưu trữ truy xuất (candidate legal articles) gồm 17.228 điều luật được lấy từ 222 bộ luật phổ biến nhất tại Trung Quốc. Ngoài ra, bộ công cụ còn bao gồm thêm 26.951 quy định từ Sách hướng dẫn thi tư pháp và 2.370 án lệ hướng dẫn.
- + Bộ dữ liệu được thu thập từ các câu hỏi hạt giống trên nền tảng tư vấn pháp luật thực tế, sau đó được 11 chuyên gia pháp lý (những người đã vượt qua kỳ thi tư pháp Trung Quốc) tiến hành biên soạn, mở rộng, chú thích và kiểm tra chéo nghiêm ngặt.

- **Kết quả đạt được:**

- + Hoàn thiện thành công bộ tiêu chuẩn LexRAG và bộ công cụ LexiT để phục vụ việc đánh giá hiệu suất của các mô hình RAG pháp lý.

- + Về mảng Truy xuất: Phương pháp truy xuất ngữ nghĩa (Dense retrieval - cụ thể là mô hình GTE-Qwen2-1.5B) cho hiệu suất cao hơn so với tìm kiếm từ khóa truyền thống (BM25). Chiến lược "viết lại truy vấn bằng LLM" (Query rewrite) kết hợp với Dense retrieval mang lại hiệu quả truy xuất tốt nhất.
- + Về mảng Tạo phản hồi: Mô hình Qwen-2.5-72B-Instruct đạt hiệu suất trả lời tốt nhất, theo sau là GLM-4. Các mô hình tạo ra câu trả lời chính xác hơn rất nhiều khi được cung cấp văn bản luật chuẩn xác (Reference setting).
- + Nghiên cứu cũng làm nổi bật một thực tế: Ngay cả với phương pháp tốt nhất, tỷ lệ truy xuất thành công (Recall@10) cao nhất mới chỉ đạt 33,33%. Nếu đưa cho LLM những tài liệu truy xuất bị nhiễu, điểm số đánh giá đôi khi còn kém hơn cả khi LLM tự trả lời (Zero-shot) vì chúng thiếu khả năng hiểu sâu kiến thức pháp lý để lọc nhiễu.
- **Những hạn chế:**
 - + LexRAG hiện tại chỉ tập trung vào các tình huống của hệ thống pháp luật Trung Quốc, làm hạn chế khả năng áp dụng của nó cho các ngôn ngữ và hệ thống pháp lý khác trên thế giới (mặc dù nhóm tác giả có kế hoạch mở rộng sang tiếng Anh trong tương lai).
 - + Vì lý do bảo mật và quyền riêng tư, các lượt hội thoại từ lượt thứ 2 trở đi đều được mô phỏng và biên soạn bởi các chuyên gia pháp lý dựa trên câu hỏi gốc. Dù điều này đảm bảo tính chính xác, nhưng nó không hoàn toàn phản ánh được tính đa dạng và sự "phi tiêu chuẩn" có thể xảy ra trong các cuộc trò chuyện thực tế của người dùng thông thường.
- **Link tham khảo:** <https://arxiv.org/pdf/2502.20640>
- **Các tác giả:** Bài báo được thực hiện bởi nhóm tác giả: Haitao Li, Yifan Chen, Yiran Hu, Qingyao Ai, Junjie Chen, Xiaoyu Yang, Jianhui Yang, Yueyue Wu, Zeyang Liu, và Yiqun Liu (Đến từ các tổ chức: Đại học Thanh Hoa, Phòng thí nghiệm Quan Cheng, Đại học Bưu chính Viễn thông Bắc Kinh, và Đại học Sơn Đông, Trung Quốc).

Bài Báo 3:

- **Tên bài báo:** Towards Reliable Retrieval in RAG Systems for Large Legal Datasets.
- **Tên bài báo(Tiếng việt):** Hướng tới việc truy xuất đáng tin cậy trong các hệ thống RAG đối với các tập dữ liệu pháp lý lớn.
- **Vấn đề nghiên cứu:**
 - + Các hệ thống RAG trong lĩnh vực pháp lý gặp nhiều khó khăn do đặc thù của văn bản luật: tính lặp lại từ vựng cao (boilerplate clauses), cấu

trúc phân cấp phức tạp, thông tin phân mảnh và yêu cầu bắt buộc về tính minh bạch của nguồn gốc thông tin.

- + Quá trình chia nhỏ văn bản (chunking) tiêu chuẩn làm mất đi bối cảnh tổng quát của tài liệu. Điều này dẫn tới một lỗi hệ thống nghiêm trọng được nhóm tác giả định nghĩa là DRM (Document-Level Retrieval Mismatch - Mismatch truy xuất cấp tài liệu), trong đó hệ thống tìm kiếm trích xuất thông tin từ các tài liệu nguồn hoàn toàn sai lệch nhưng có cấu trúc tương tự nhau (ví dụ: lấy thông tin từ một hợp đồng NDA của công ty khác).

- **Phương pháp nghiên cứu:**

- + Tác giả đề xuất một giải pháp thực tiễn có tên Summary-Augmented Chunking (SAC - Phân đoạn tăng cường tóm tắt).
- + Cụ thể, hệ thống sử dụng LLM (gpt-4o-mini) để tự động tạo một đoạn tóm tắt ngắn (khoảng 150 ký tự) làm "dấu vân tay" cho toàn bộ tài liệu. Đoạn tóm tắt này sau đó được gắn (prepend) vào đầu mọi phân đoạn văn bản nhỏ (chunk) của tài liệu đó trước khi đem đi mã hóa (embedding).
- + Nghiên cứu tiến hành so sánh hai chiến lược tạo tóm tắt: (1) Tóm tắt khái quát thông thường (generic summarization) và (2) Tóm tắt theo hướng dẫn của chuyên gia pháp lý với các trường thông tin đặc thù của từng loại hợp đồng (expert-guided summarization).

- **Dữ liệu sử dụng:** Nghiên cứu sử dụng bộ tiêu chuẩn đánh giá LegalBench-RAG, bao gồm các tập dữ liệu văn bản pháp lý tiếng Anh: CUAD (hợp đồng chung), MAUD (thỏa thuận sáp nhập), ContractNLI (thỏa thuận bảo mật thông tin - NDA) và PrivacyQA (chính sách bảo mật)

- **Kết quả đạt được:**

- + Phương pháp SAC giúp giảm mạnh (giảm tới một nửa) tỷ lệ lỗi DRM so với quy trình RAG tiêu chuẩn trên nhiều tham số thiết lập.
- + Việc chỉ dẫn mô hình truy xuất đến đúng tài liệu nguồn đã kéo theo sự cải thiện đáng kể về độ chính xác (precision) và độ bao phủ (recall) ở cấp độ trích xuất đoạn văn bản.
- + Phát hiện đáng chú ý: Chiến lược tóm tắt khái quát (generic) lại đem đến hiệu suất truy xuất tốt hơn so với tóm tắt chuyên gia (expert-guided). Lý do là tóm tắt khái quát cân bằng được sự khác biệt và duy trì liên kết ngữ nghĩa rộng, trong khi tóm tắt chuyên gia quá đặc thù, cấu trúc phức tạp làm giảm hiệu quả hoạt động của các mô hình embedding thông thường.

- **Những hạn chế:**

- + Nghiên cứu chỉ thực hiện trên một số loại văn bản pháp lý nhất định (như hợp đồng, chính sách) và hoàn toàn bằng tiếng Anh, tập trung chủ

yếu vào môi trường thông luật (common-law), chưa bao phủ các văn bản luật lệ hay án lệ phức tạp.

- + Phương pháp SAC mới chỉ làm giảm thiểu, chứ không giải quyết được hoàn toàn tình trạng sai lệch truy xuất tài liệu (DRM).
- + Nghiên cứu mới chỉ đánh giá hiệu suất ở công đoạn "truy xuất" (retrieval) của RAG, cần có thêm các đánh giá end-to-end cho công đoạn "tạo phản hồi" (generation) của LLM trong tương lai.
- **Link tham khảo:** <https://arxiv.org/pdf/2510.06999>
- **Các tác giả:** Markus Reuter, Tobias Lingenberg, Rūta Liepiņa, Francesca Lagioia, Marco Lippi, Giovanni Sartor, Andrea Passerini, và Burcu Sayin (Nhóm tác giả đến từ các Đại học Kỹ thuật Darmstadt, Florence, Bologna, Trento và Viện Đại học Châu Âu).

Bài Báo 4:

- **Tên bài báo:** Vietnamese Legal Information Retrieval in Question-Answering System Natural Language Processing – IT4772E.
- **Tên bài báo(Tiếng việt):** Truy xuất thông tin pháp lý Việt Nam trong Hệ thống Hỏi - Đáp của môn Xử lý Ngôn ngữ Tự nhiên – IT4772E.
- **Vấn đề nghiên cứu:**
 - + Mặc dù RAG (Retrieval-Augmented Generation) rất hiệu quả trong việc giảm thiểu hiện tượng "ảo giác" của các Mô hình ngôn ngữ lớn (LLM) trong lĩnh vực pháp lý, nhưng khi áp dụng cho tiếng Việt lại gặp nhiều thách thức.
 - + Các phương pháp hiện tại gặp vấn đề do xử lý dữ liệu tiếng Việt không hiệu quả (dẫn đến độ dài token quá lớn), hoặc các kỹ thuật kết hợp (ensemble) quá đơn giản dẫn đến sự thiếu ổn định và cải thiện hạn chế.
 - + Một vấn đề quan trọng thường bị bỏ qua là việc sắp xếp thứ tự các tài liệu tham khảo cuối cùng để LLM sử dụng làm cơ sở trả lời, ảnh hưởng trực tiếp đến độ chính xác của hệ thống.
- **Phương pháp nghiên cứu:**
 - + Tiền xử lý dữ liệu (Data Processing): Chia nhỏ văn bản pháp luật thành các đoạn (chunk) dưới 256 token, ưu tiên chia theo điều khoản hoặc chia theo kỹ thuật gối nhau (overlap chunking). Sử dụng bộ phân tách RDR segmenter để cắt từ tiếng Việt trước khi đưa vào mô hình.
 - + Viết lại truy vấn (Query Rewriting): Dùng LLM để viết lại câu hỏi gốc của người dùng nhằm sửa lỗi chính tả, làm rõ nghĩa và giảm sự mơ hồ.
 - + Tìm kiếm kết hợp (Hybrid Search): Kết hợp thuật toán tìm kiếm từ khóa BM25 (đã loại bỏ stopwords) và tìm kiếm vector ngữ nghĩa (sử dụng mô hình Vietnamese Bi-Encoder của BKAI). Điểm số từ hai phương pháp

này được chuẩn hóa (đưa về thang) và kết hợp với trọng số bằng nhau (0.5 cho mỗi bên).

- + Truy xuất chủ động và xếp hạng lại bằng LLM (Active Retrieval & LLM Re-ranking): Đưa các đoạn văn bản truy xuất được cho LLM (LLaMA 3 70B) để tạo câu trả lời. Nếu không tìm thấy đáp án, hệ thống sẽ chủ động tìm kiếm tiếp ở các kết quả xếp hạng thấp hơn. Cuối cùng, hệ thống dùng chính câu trả lời do LLM tạo ra để đánh giá và xếp hạng lại (re-rank) các đoạn văn bản một lần nữa, xem đây như một phương pháp thay thế hiệu quả cho cross-encoder truyền thống.

- **Dữ liệu sử dụng:**

- + Nhóm nghiên cứu thu thập các cặp Câu hỏi - Trả lời từ trang web "Thư viện pháp luật" (gồm câu hỏi của người dùng và đáp án của luật sư).
- + Dữ liệu được làm sạch kỹ lưỡng, tổng hợp được khoảng 1.293.347 điều luật riêng biệt và 2.081 câu hỏi dùng để kiểm thử.
- + Hệ thống cũng sử dụng kết hợp với "Zalo Legal Dataset" để tránh hiện tượng học vẹt (overfitting).

- **Kết quả đạt được:**

- + Các bước tiền xử lý dữ liệu (như chunking gói nhau, thêm siêu dữ liệu, loại bỏ stopwords) đóng vai trò then chốt, giúp cải thiện đáng kể các chỉ số đánh giá.
- + Phương pháp tìm kiếm ngữ nghĩa (Bi-encoder) mang lại hiệu quả vượt trội so với tìm kiếm từ khóa truyền thống (BM25). Đặc biệt, sự kết hợp (Hybrid Search) giúp hệ thống phát huy thế mạnh của cả hai phương pháp và cho ra kết quả tốt hơn.
- + Hệ thống toàn diện với mô-đun LLM Re-ranker do nhóm đề xuất đạt hiệu suất cao nhất, với chỉ số Recall@10 và Recall@100 lên tới 0.98 trên tập dữ liệu đã qua xử lý.

- **Những hạn chế:**

- + Do hạn chế về tài nguyên huấn luyện và thiếu dữ liệu, nhóm không thể thực hiện tinh chỉnh (fine-tune) mô hình embedding và re-ranking ban đầu như mục tiêu đề ra, mà phải chuyển sang dùng các mô hình có sẵn.
- + Giới hạn đầu vào (token length) của LLM khiến mỗi lần hệ thống chỉ có thể đưa vào từ 2 đến 5 điều luật. Nếu số tài liệu cần tra cứu nhiều hơn, hệ thống phải thực hiện lặp đi lặp lại (iteration) các cụm tài liệu cho đến khi tìm được câu trả lời, điều này có thể gây tốn tài nguyên

- **Link tham khảo:** <https://arxiv.org/pdf/2409.13699>

- **Các tác giả:** Bài báo được thực hiện bởi nhóm sinh viên Nguyễn Bá Thiêm, Đoàn Thế Vinh, Phạm Quang Tùng, Trần Văn Toàn thuộc Đại học Bách Khoa Hà Nội, dưới sự hướng dẫn của Giáo sư Lê Thanh Hương

Bài Báo 5:

- **Tên bài báo:** A Retrieval Augmented Generation Based System for Enhanced Legal Accessibility in India.
- **Tên bài báo(Tiếng việt):** LawPal: Hệ thống dựa trên Tạo văn bản Tăng cường Truy xuất (RAG) nhằm nâng cao khả năng tiếp cận pháp lý tại Ấn Độ.
- **Vấn đề nghiên cứu:**
 - + Việc tiếp cận kiến thức pháp luật ở Ấn Độ thường gặp khó khăn do người dân thiếu nhận thức, thông tin sai lệch và hạn chế trong việc tra cứu các tài nguyên tư pháp.
 - + Nhiều cá nhân chật vật khi điều hướng các khuôn khổ pháp lý phức tạp, dẫn đến việc lạm dụng luật và thiếu sự bảo vệ pháp lý cần thiết.
 - + Bên cạnh đó, các AI chatbot pháp lý hiện tại vẫn gặp khó khăn trong việc xử lý các truy vấn liên quan đến nhiều khu vực pháp lý (multi-jurisdictional) và hiểu các lập luận pháp lý có ngữ cảnh dài.
- **Phương pháp nghiên cứu:**
 - + Tác giả đề xuất xây dựng hệ thống LawPal, một chatbot pháp lý hoạt động dựa trên kiến trúc RAG (Retrieval-Augmented Generation) dạng mô-đun.
 - + Mô hình cốt lõi: Sử dụng LLM DeepSeek-R1:5B để tạo các vector nhúng (embedding 1.024 chiều) từ văn bản pháp luật và tổng hợp câu trả lời tự nhiên.
 - + Lưu trữ và Truy xuất: Áp dụng FAISS (Facebook AI Similarity Search) làm cơ sở dữ liệu vector. Bài báo cũng chứng minh FAISS vượt trội hơn Chroma về tốc độ truy xuất, khả năng tính toán mở rộng và độ bao phủ ngữ cảnh (recall) nhờ các kỹ thuật tối ưu như PQ, IVF và đồ thị HNSW.
 - + Tiền xử lý dữ liệu: Phân đoạn văn bản (chunking) bằng công cụ LangChain, chia tài liệu thành các khối 500–750 ký tự với độ gối nhau 50–100 ký tự để duy trì tính liên tục của ngữ cảnh.
 - + Kiểm thử và đánh giá: Áp dụng các chỉ số truy xuất (Precision@K, MRR, NDCG) kết hợp các chỉ số xử lý ngôn ngữ tự nhiên (BLEU, ROUGE, Legal Consistency Score - LCS) và có sự tham gia của các chuyên gia pháp lý để kiểm định câu trả lời. Giao diện người dùng được xây dựng bằng Streamlit.
- **Dữ liệu sử dụng:**
 - + Hệ thống sử dụng bộ dữ liệu pháp luật đa dạng bao gồm: các kho lưu trữ luật pháp công cộng, hồ sơ án lệ của tòa án (bao gồm Tòa án Tối cao), cơ sở dữ liệu luật định, Hiến pháp Ấn Độ, sách luật và các bài nghiên cứu học thuật.
 - + Ngoài ra, hệ thống áp dụng web scraping và các API để tự động thu thập thông tin cập nhật về các luật mới và các phán quyết hiện hành.
- **Kết quả đạt được:**

- + Hệ thống đạt độ chính xác pháp lý trên 90% theo kết quả xác nhận của các chuyên gia đánh giá.
- + Tốc độ xử lý cực nhanh để đảm bảo trải nghiệm thời gian thực: Quá trình truy xuất của FAISS chỉ mất 10-50 mili-giây, quá trình tạo câu trả lời của DeepSeek mất từ 800-1.500 mili-giây.
- + Thử nghiệm thực tế với luật sư, sinh viên luật và người tìm kiếm hỗ trợ pháp lý cho thấy mức độ hài lòng đạt 85% về độ chính xác và tính tin cậy.
- + Tính nhất quán của mô hình cao, tỷ lệ dao động câu trả lời khi hỏi lại dưới 5%.
- + LawPal vượt trội hoàn toàn so với các chatbot dựa trên quy tắc thông thường hay các công cụ tìm kiếm từ khóa nhờ khả năng bắt được ngữ cảnh và loại bỏ các thông tin, câu hỏi mang tính chất sai lệch.
- **Những hạn chế:**
 - + Hệ thống thỉnh thoảng vẫn gặp lỗi hoặc gặp khó khăn khi người dùng đặt các câu hỏi pháp lý quá mơ hồ.
 - + Do chỉ mới tập trung vào luật chung, hệ thống cần được tinh chỉnh (fine-tuning) thêm để xử lý tốt các ngành luật chuyên biệt như luật doanh nghiệp (corporate law) hay luật quốc tế.
 - + Vẫn còn hạn chế trong việc giải quyết các câu hỏi liên quan đến nhiều khu vực pháp lý và khả năng tổng hợp các điều khoản luật có ngữ cảnh quá dài.
 - + Hệ thống hiện tại chưa có tính năng đa ngôn ngữ, không hỗ trợ các ngôn ngữ địa phương phổ biến khác tại Ấn Độ.
- **Link tham khảo:** <https://arxiv.org/pdf/2502.16573>
- **Các tác giả:** Bài viết được thực hiện bởi Dnyanesh Panchal, Aaryan Gole, Vaibhav Narute, và Phó giáo sư Raunak Joshi (Thuộc Khoa Trí tuệ nhân tạo và Khoa học dữ liệu - AI & DS, Trường Cao đẳng Kỹ thuật và Công nghệ Vidyavardhini, bang Maharashtra, Ấn Độ).

CÁC TÀI LIỆU LIÊN QUAN ĐẾN MÔ HÌNH RAG NÂNG CAO(Advanced RAG& Modular RAG) HAY CÒN GỌI TẮT LÀ RAG++

1. Tài liệu nền tảng & Tổng quan kiến trúc (Bắt buộc có)

Tên bài báo: *Retrieval-Augmented Generation for Large Language Models: A Survey*

Link tham khảo: <https://arxiv.org/pdf/2312.10997>

Báo cáo Tóm tắt: Hệ thống Tăng cường Truy xuất (RAG) cho Các Mô hình Ngôn ngữ Lớn

Tóm tắt Điều hành

Tài liệu này tổng hợp các phát hiện chính từ nghiên cứu toàn diện về Hệ thống Tăng cường Truy xuất (Retrieval-Augmented Generation - RAG). RAG đã nổi lên như một giải pháp quan trọng để khắc phục những hạn chế cố hữu của các Mô hình Ngôn ngữ Lớn (LLM), bao gồm hiện tượng "ảo giác" (hallucination), kiến thức lỗi thời và quy trình suy luận thiếu minh bạch. Bằng cách kết hợp kiến thức tham số (parametric knowledge) của LLM với kho lưu trữ động, không lỗi từ cơ sở dữ liệu bên ngoài, RAG nâng cao độ chính xác, khả năng cập nhật và độ tin cậy của nội dung được tạo ra. Nghiên cứu xác định sự phát triển của RAG qua ba giai đoạn: **RAG Sơ khai (Naive RAG)**, **RAG Nâng cao (Advanced RAG)** và **RAG Mô-đun (Modular RAG)**. Ngoài ra, tài liệu cũng phân tích các kỹ thuật tối ưu hóa trong truy xuất, tạo văn bản và các phương pháp đánh giá hệ thống hiện đại.

1. Sự Tiến hóa của Các Mô hình RAG

Sự phát triển của RAG gắn liền với các bước tiến của LLM, được phân chia thành ba mô hình chính với các đặc điểm kỹ thuật riêng biệt:

1.1. RAG Sơ khai (Naive RAG)

Đây là phương pháp sớm nhất, tuân theo quy trình "Truy xuất - Đọc" (Retrieve-Read):

- **Lập chỉ mục (Indexing):** Dữ liệu thô được làm sạch, chia nhỏ thành các đoạn (chunks), mã hóa thành vector thông qua mô hình embedding và lưu trữ trong cơ sở dữ liệu vector.
- **Truy xuất (Retrieval):** Chuyển đổi câu hỏi của người dùng thành vector, tính toán độ tương đồng ngữ nghĩa để tìm ra K đoạn văn bản liên quan nhất.
- **Tạo văn bản (Generation):** Tổng hợp câu hỏi và các đoạn văn bản đã truy xuất vào một lời nhắc (prompt) để LLM đưa ra câu trả lời.
- **Hạn chế:** Thường gặp vấn đề về độ chính xác (precision) thấp, thông tin truy xuất không liên quan hoặc gây nhiễu, và LLM dễ bị ảo giác do thông tin hỗ trợ rời rạc.

1.2. Advanced RAG (RAG Nâng cao)

Nhằm khắc phục yếu điểm của Naive RAG, mô hình này tập trung vào tối ưu hóa trước và sau truy xuất:

- **Tiền truy xuất (Pre-retrieval):** Tối ưu hóa cấu trúc chỉ mục (như sliding window, granularity) và làm rõ câu hỏi của người dùng (Query Rewriting, Expansion).
- **Hậu truy xuất (Post-retrieval):** Sử dụng các kỹ thuật **Tái xếp hạng (Reranking)** để đưa thông tin quan trọng nhất lên đầu và **Nén ngữ cảnh (Context Compression)** để loại bỏ nhiễu trước khi đưa vào LLM.

1.3. Modular RAG (RAG Mô-đun)

Đây là mô hình tiên tiến nhất, mang lại tính linh hoạt cao bằng cách tích hợp các mô hình chức năng chuyên biệt:

- **Mô-đun mới:** Bao gồm mô-đun Tìm kiếm (Search), Bộ nhớ (Memory), Định tuyến (Routing) và Dự đoán (Predict).
- **Tính linh hoạt:** Cho phép thay thế hoặc cấu hình lại các mô hình để giải quyết các thách thức cụ thể, hỗ trợ truy xuất lặp lại (iterative) và thích ứng (adaptive).

2. Các Thành phần Kỹ thuật Cốt lõi

2.1. Tối ưu hóa Truy xuất (Retrieval)

Nghiên cứu nhấn mạnh ba yếu tố ảnh hưởng đến chất lượng truy xuất:

1. **Nguồn dữ liệu:** Mở rộng từ văn bản phi cấu trúc sang dữ liệu bán cấu trúc (PDF), cấu trúc (Knowledge Graph) và thậm chí là nội dung do chính LLM tạo ra.
2. **Độ mịn của dữ liệu (Granularity):** Việc lựa chọn đơn vị truy xuất (từ ngữ, câu, đoạn, tài liệu) ảnh hưởng trực tiếp đến hiệu suất. Các đơn vị quá thô có thể gây nhiễu, trong khi quá mịn sẽ thiếu ngữ cảnh.
3. **Tối ưu hóa Embedding:** Tinh chỉnh các mô hình embedding (như BGE, Voyage) để phù hợp với các lĩnh vực chuyên biệt (y tế, pháp luật).

2.2. Tối ưu hóa Tạo văn bản (Generation)

Sau khi truy xuất, thông tin cần được xử lý để tránh tình trạng "Lost in the middle" (LLM chỉ tập trung vào đầu và cuối văn bản dài):

- **Reranking:** Sử dụng các mô hình dựa trên quy tắc hoặc mô hình ngôn ngữ để sắp xếp lại các đoạn văn bản theo độ liên quan.
- **Context Selection/Compression:** Sử dụng các mô hình nhỏ (như GPT-2 Small) để loại bỏ các token không quan trọng, giúp giảm nhiễu và chi phí xử lý.

3. Quy trình Tăng cường (Augmentation Process)

RAG không chỉ giới hạn ở việc truy xuất một lần. Nghiên cứu phân loại ba quy trình tăng cường chính: | Quy trình | Đặc điểm chính | ----- | ----- || **Iterative Retrieval** | Truy xuất và tạo văn bản luân phiên để xây dựng nền tảng kiến thức toàn diện hơn. || **Recursive Retrieval** | Liên tục tinh chỉnh câu hỏi dựa trên kết quả tìm kiếm trước đó để đi sâu vào các vấn đề phức tạp. || **Adaptive Retrieval** | LLM tự quyết định khi nào cần truy xuất thêm thông tin bên ngoài dựa trên độ tin cậy của quá trình tạo văn bản (ví dụ: mô hình Flare). |

4. So sánh RAG và Fine-tuning (FT)

Nghiên cứu chỉ ra rằng RAG và FT không loại trừ lẫn nhau mà có tính bổ trợ:

- **RAG:** Giống như cung cấp một "sách giáo khoa" cho mô hình. Xuất sắc trong việc cập nhật kiến thức thời gian thực, tính minh bạch cao và không yêu cầu đào tạo lại mô hình tốn kém.
- **Fine-tuning:** Giống như một học sinh tiếp thu kiến thức qua thời gian. Phù hợp để điều chỉnh phong cách, định dạng và hành vi cụ thể của mô hình.
- **Kết luận:** RAG thường vượt trội hơn FT trong việc xử lý kiến thức mới hoặc kiến thức hiếm (long-tail knowledge). Sự kết hợp giữa hai phương pháp thường mang lại kết quả tối ưu.

5. Hệ thống Đánh giá RAG

Đánh giá hiệu suất RAG tập trung vào hai mục tiêu chính: Chất lượng truy xuất và Chất lượng tạo văn bản.

5.1. Các chỉ số đo lường (Metrics)

- **Chất lượng truy xuất:** Sử dụng Hit Rate, MRR (Mean Reciprocal Rank) và NDCG.
- **Chất lượng tạo văn bản:** Tập trung vào các yếu tố:
- **Faithfulness (Độ trung thực):** Câu trả lời phải dựa trên ngữ cảnh đã truy xuất.
- **Answer Relevance (Độ liên quan):** Câu trả lời phải giải quyết trực tiếp câu hỏi.
- **Context Relevance (Độ liên quan của ngữ cảnh):** Các đoạn văn bản truy xuất phải chính xác và ít nhiễu.

5.2. Công cụ và Điểm chuẩn (Benchmarks)

Các khung đánh giá phổ biến bao gồm **RAGAS** , **ARES** , và các bộ dữ liệu điểm chuẩn như **RGB** , **RECALL** và **CRUD** .

6. Thách thức và Hướng phát triển Tương lai

Mặc dù có những bước tiến đáng kể, RAG vẫn đối mặt với các thách thức:

- **Tính mạnh mẽ (Robustness):** Khả năng xử lý thông tin sai lệch hoặc mâu thuẫn trong dữ liệu truy xuất.
- **RAG cho ngữ cảnh dài:** Khi LLM có thể xử lý hơn 200,000 token, vai trò của RAG cần được định nghĩa lại để tập trung vào hiệu suất và khả năng kiểm chứng.
- **RAG đa phương thức (Multi-modal):** Mở rộng từ văn bản sang hình ảnh, âm thanh, video và mã nguồn.
- **Sẵn sàng cho sản xuất:** Cải thiện hiệu suất truy xuất, bảo mật dữ liệu và giảm độ trễ trong các ứng dụng thực tế.

2. Nhóm tài liệu về Tối ưu Truy xuất (Retrieval)

Về Hybrid Search và Kỹ thuật Tiên truy xuất (BM25 + Semantic)

Hybrid Search (Từ khóa + Ngữ nghĩa): <https://arxiv.org/abs/2004.04906>

Re-ranking (Sắp xếp lại kết quả): <https://arxiv.org/abs/2307.03172>

Self-RAG (LLM tự đánh giá kết quả của chính nó):
<https://arxiv.org/abs/2310.11511>

TỔNG QUAN VỀ SỰ TIẾN HÓA CỦA HỆ THỐNG TRUY VẤN VÀ TÌM KIẾM THÔNG TIN: TỪ MÔ HÌNH THỪA ĐẾN MÔ HÌNH NGÔN NGỮ LỚN

Tóm tắt Điều hành

Tài liệu này tổng hợp các tiến bộ kỹ thuật trong lĩnh vực truy vấn văn bản (Text Retrieval) và trả lời câu hỏi miền mở (Open-domain Question Answering - QA), dựa trên các nghiên cứu về mô hình Dense Passage Retriever (DPR), hệ thống nhúng văn bản E5 và việc tinh chỉnh các mô hình ngôn ngữ lớn (LLM) như LLaMA. **Các điểm rút ra then chốt:**

- **Sự chuyển dịch từ Sparse sang Dense:** Các mô hình truy vấn dày (Dense Retrieval) sử dụng biểu diễn vector liên tục đang dần thay thế các mô hình không gian vector thưa truyền thống (như TF-IDF và BM25) nhờ khả năng bắt được quan hệ ngữ nghĩa thay vì chỉ khớp từ khóa đơn thuần.
- **Hiệu quả của Học tương phản (Contrastive Learning):** Việc sử dụng cơ chế "in-batch negatives" (phần tử âm trong cùng lô) và dữ liệu huấn luyện quy mô lớn (như CCPairs với 270 triệu cặp văn bản) là yếu tố quyết định để tạo ra các bản nhúng văn bản chất lượng cao.
- **Sức mạnh của LLM trong Truy vấn:** Tinh chỉnh các mô hình như LLaMA-2 (RepLLaMA và RankLLaMA) mang lại hiệu quả vượt trội so với các mô hình nhỏ hơn, đồng thời giải quyết được vấn đề xử lý ngữ cảnh dài mà không cần phân đoạn văn bản.
- **Khả năng Zero-shot:** Các mô hình hiện đại như E5 và RepLLaMA cho thấy khả năng thực thi mạnh mẽ trên các tập dữ liệu mới (zero-shot) mà không cần huấn luyện lại, vượt qua các hệ thống BM25 truyền thống trên bảng xếp hạng BEIR.

1. Truy vấn Văn bản Dày (Dense Passage Retrieval - DPR)

Hệ thống DPR đã thiết lập một tiêu chuẩn mới cho việc trả lời câu hỏi miền mở bằng cách thay thế các phương pháp truyền thống dựa trên từ khóa.

Cơ chế hoạt động

- **Cấu trúc Dual-Encoder:** Sử dụng hai mạng BERT độc lập: một để mã hóa câu hỏi ($SE_Q\$$) và một để mã hóa đoạn văn ($SE_P\$$).
- **Đo lường độ tương đồng:** Sử dụng tích vô hướng (dot product) giữa các vector 768 chiều để xác định mức độ liên quan.
- **MIPS (Maximum Inner Product Search):** Cho phép tìm kiếm hiệu quả trong hàng triệu đoạn văn bằng cách sử dụng cấu trúc dữ liệu trong bộ nhớ (như thư viện FAISS).

Những cải tiến quan trọng trong huấn luyện

- **In-batch Negatives:** Tận dụng các đoạn văn đúng của những câu hỏi khác trong cùng một lô huấn luyện để làm phần tử âm, giúp tăng hiệu quả tính toán và cải thiện độ chính xác.
- **Dữ liệu huấn luyện:** Chỉ cần một lượng nhỏ cặp câu hỏi - đoạn văn (khoảng 1.000 cặp) là đủ để DPR vượt qua BM25.

- **Kết quả:** DPR vượt qua hệ thống BM25 của Lucene từ 9% đến 19% về độ chính xác truy vấn Top-20 trên nhiều tập dữ liệu QA miền mở.

2. Mô hình nhúng E5 (Embeddings từ Bidirectional Encoder Representations)

E5 là một họ mô hình nhúng văn bản đa mục tiêu, được huấn luyện thông qua giám sát yếu trên quy mô dữ liệu khổng lồ.

Quy trình tạo dữ liệu CCPairs (Colossal Clean text Pairs)

Để đảm bảo chất lượng nhúng, nghiên cứu đã xây dựng tập dữ liệu CCPairs thông qua các bước:

1. **Thu thập dữ liệu bán cấu trúc:** Khai thác từ Reddit (cặp bài đăng - bình luận), StackExchange (câu hỏi - câu trả lời), Wikipedia, và Common Crawl.
2. **Lọc dựa trên sự nhất quán (Consistency-based filter):** Sử dụng một mô hình được huấn luyện trên dữ liệu nhiễu để xếp hạng, chỉ giữ lại những cặp văn bản có độ tin cậy cao nhất ($Top-2\%$).
3. **Kết quả:** Từ 1,3 tỷ cặp ban đầu, còn lại 270 triệu cặp văn bản sạch để huấn luyện.

Đặc điểm kỹ thuật và Hiệu suất

- **Prefix identifiers:** Sử dụng tiền tố "query:" và "passage:" để phá vỡ tính đối xứng, giúp mô hình hoạt động tốt hơn trong các nhiệm vụ truy vấn không đối xứng.
- **Hiệu quả Zero-shot:** E5 là mô hình đầu tiên vượt qua BM25 trên tiêu chuẩn BEIR mà không sử dụng bất kỳ dữ liệu nhãn nào (unsupervised).
- **So sánh quy mô:** Mô hình E5-base (110M tham số) có khả năng cạnh tranh với các mô hình lớn hơn gấp 40 lần như GTR-xxl.

3. Tinh chỉnh LLM cho Truy vấn Đa giai đoạn (RepLLaMA & RankLLaMA)

Việc sử dụng các mô hình ngôn ngữ lớn (LLM) như LLaMA-2 đã tạo ra một bước đột phá trong hệ thống truy vấn hai giai đoạn: Retriever (Truy vấn) và Reranker (Xếp hạng lại).

Hệ thống RepLLaMA (Retriever)

- **Kiến trúc:** Dựa trên LLaMA-2-7B, sử dụng token kết thúc câu (EOS) để đại diện cho bản nhúng của toàn bộ văn bản.
- **Ưu điểm ngữ cảnh:** Nhờ cửa sổ ngữ cảnh rộng (4096 tokens), mô hình có thể đại diện cho toàn bộ tài liệu một cách chính thể mà không cần các chiến lược phân đoạn (segmenting) hay hợp nhất (pooling) truyền thống.

Hệ thống RankLLaMA (Reranker)

- **Xếp hạng điểm (Pointwise Reranker):** Nhận cặp câu hỏi - tài liệu cùng lúc và đưa ra điểm số liên quan duy nhất.
- **Hiệu quả:** Vượt qua các mô hình xếp hạng trước đó như MORES+ và RankT5 trên tập dữ liệu MS MARCO.

Phân tích kỹ thuật Tinh chỉnh		
Phương pháp	Đặc điểm	Hiệu quả
Full Fine-tuning	Cập nhật toàn bộ tham số	Dễ gây quá khớp (overfitting) trên dữ liệu huấn luyện.
LoRA	Cập nhật các ma trận hạng thấp	Khả năng tổng quát hóa tốt hơn trên các tập dữ liệu độc lập (như TREC DL).

4. So sánh Hiệu suất và Phân tích Định lượng

Dưới đây là bảng tổng hợp hiệu quả của các mô hình trên tập dữ liệu **Natural Questions (NQ)** (Top-20 Accuracy) và **MS MARCO** (MRR@10):

Mô hình	Loại mô hình	NQ (Top-20 Acc)	MS MARCO (MRR@10)
BM25	Sparse (Từ khóa)	59.1%	18.4
DPR	Dense (BERT)	78.4%	-
E5-base	Dense (Weak-sup)	-	38.5
RepLLaMA	LLM-based (7B)	-	41.2

Sự khác biệt định tính giữa BM25 và Dense Retrieval

- **BM25:** Nhạy cảm với các từ khóa hiếm và tên riêng (ví dụ: "Thoros of Myr"). Thất bại khi không có sự trùng lặp từ vựng chính xác.
- **Dense Retrieval (DPR/E5/RepLLaMA):** Nắm bắt tốt các biến thể từ vựng và quan hệ ngữ nghĩa (ví dụ: khớp "bad guy" với "villain", hoặc "body of water" với "Irish Sea" dù không trùng từ khóa).

5. Kết luận và Ý nghĩa thực tiễn

Nghiên cứu khẳng định rằng truy vấn dày không chỉ vượt qua mà còn có tiềm năng thay thế hoàn toàn các thành phần truy vấn thưa truyền thống trong hệ thống QA miền mở.

- **Tốc độ:** Với FAISS, DPR có thể xử lý gần 1.000 câu hỏi mỗi giây, nhanh hơn nhiều lần so với BM25/Lucene trên cùng cấu hình phần cứng.
 - **Độ chính xác:** Độ chính xác truy vấn cao hơn trực tiếp dẫn đến kết quả trả lời câu hỏi cuối cùng (End-to-end QA) chính xác hơn.
 - **Đơn giản hóa hệ thống:** Việc sử dụng LLM giúp loại bỏ các bước tiền xử lý phức tạp như phân đoạn tài liệu, đồng thời mang lại khả năng zero-shot mạnh mẽ, cho phép triển khai nhanh chóng trên các lĩnh vực mới mà không cần dữ liệu nhãn.
- Trích dẫn quan trọng:** *"Chúng tôi chứng minh rằng truy vấn dày có thể vượt qua và có tiềm năng thay thế thành phần truy vấn thưa truyền thống"*

thống trong trả lời câu hỏi miễn mở." (Hybrid Search.pdf) "E5 là mô hình đầu tiên vượt qua BM25 trên tiêu chuẩn BEIR mà không sử dụng bất kỳ dữ liệu nhân nào." (E5.pdf)

3.Nhóm tài liệu về Sinh văn bản có Kiểm chứng (Generation & Critique)

Về Self-RAG (AI tự kiểm tra lại câu trả lời): <https://arxiv.org/pdf/2310.11511>

Về CRAG (Corrective RAG - RAG Sửa lỗi): <https://arxiv.org/pdf/2401.15884>

TỔNG QUAN VỀ CÁC PHƯƠNG PHÁP TỐI ƯU HÓA TRUY XUẤT THÔNG TIN TĂNG CƯỜNG (RAG): CRAG VÀ SELF-RAG

Tóm tắt điều hành

Tài liệu này tổng hợp các phân tích chuyên sâu về hai phương pháp tiên tiến nhằm nâng cao độ tin cậy và hiệu quả của các Mô hình Ngôn ngữ Lớn (LLMs): **Corrective Retrieval Augmented Generation (CRAG)** và **Self-Reflective Retrieval-Augmented Generation (Self-RAG)**. Các mô hình RAG truyền thống thường gặp vấn đề khi phụ thuộc quá mức vào chất lượng của tài liệu được truy xuất. Nếu hệ thống truy xuất cung cấp thông tin sai lệch hoặc không liên quan, mô hình ngôn ngữ dễ dẫn đến tình trạng "ảo giác" (hallucination). Để giải quyết vấn đề này:

- **CRAG** giới thiệu một cơ chế tự sửa lỗi bằng cách đánh giá mức độ tin cậy của tài liệu truy xuất và kích hoạt các hành động tương ứng, bao gồm cả việc tìm kiếm từ khóa trên web để bổ sung tri thức.
- **Self-RAG** sử dụng các "token phản hồi" (reflection tokens) để mô hình tự quyết định khi nào cần truy xuất, đánh giá mức độ liên quan của tài liệu và kiểm chứng tính xác thực của nội dung do chính mình tạo ra. Cả hai phương pháp đều cho thấy sự cải thiện đáng kể về hiệu suất trên nhiều bộ dữ liệu thử nghiệm như PopQA, Biography, PubHealth và Arc-Challenge, đồng thời có khả năng tích hợp linh hoạt vào các kiến trúc mô hình hiện có.

1. Corrective Retrieval Augmented Generation (CRAG)

1.1. Mục tiêu và Cơ chế cốt lõi

CRAG được thiết kế để cải thiện tính bền vững của quá trình tạo văn bản bằng cách thiết lập một hệ thống tự sửa lỗi cho các kết quả truy xuất. Thay vì chấp nhận vô điều kiện các tài liệu được truy xuất, CRAG đánh giá chất lượng của chúng để đưa ra các chiến lược xử lý tri thức khác nhau.

1.2. Các thành phần chính

- **Bộ đánh giá truy xuất nhẹ (Lightweight Retrieval Evaluator):** Được xây dựng dựa trên mô hình T5-large (0.77B tham số), bộ đánh giá này ước tính điểm liên quan giữa câu hỏi đầu vào và tài liệu truy xuất.

- **Cơ chế kích hoạt hành động (Action Trigger):** Dựa trên mức độ tin cậy (confidence degree), hệ thống sẽ kích hoạt một trong ba hành động:
- **Correct (Đúng):** Nếu tài liệu có độ tin cậy cao, hệ thống sẽ tiến hành tinh lọc tri thức.
- **Incorrect (Sai):** Nếu tài liệu không liên quan, chúng sẽ bị loại bỏ và thay thế bằng kết quả tìm kiếm từ web.
- **Ambiguous (Mơ hồ):** Kết hợp cả tri thức nội bộ đã tinh lọc và tri thức từ web để bổ sung cho nhau.
- **Thuật toán Phân rã - Tái cấu trúc (Decompose-then-Recompose):** Chia nhỏ các tài liệu dài thành các "dải tri thức" (knowledge strips) ngắn, lọc bỏ thông tin không thiết yếu và ghép nối các phần liên quan nhất để tối ưu hóa đầu vào cho bộ tạo văn bản.

1.3. Mở rộng tìm kiếm web (Web Search)

Khi tri thức từ kho dữ liệu tĩnh không đủ hoặc không chính xác, CRAG sử dụng Google Search API để tìm kiếm thông tin từ Internet. Các câu hỏi được ChatGPT viết lại thành các từ khóa hiệu quả để mô phỏng hành vi tìm kiếm của con người. Các trang web có độ tin cậy cao như Wikipedia được ưu tiên để đảm bảo chất lượng thông tin.

2. Self-Reflective Retrieval-Augmented Generation (Self-RAG)

2.1. Khái niệm Reflection Tokens (Token phản hồi)

Loại Token	Mục đích	Giá trị đầu ra
Retrieve	Quyết định khi nào cần truy xuất thông tin.	{yes, no, continue}
ISREL	Đánh giá tài liệu có cung cấp thông tin hữu ích không.	{relevant, irrelevant}
ISSUP	Kiểm tra mức độ xác thực của nội dung dựa trên tài liệu.	{fully supported, partially supported, no support}
ISUSE	Đánh giá mức độ hữu ích tổng thể của câu trả lời.	{1, 2, 3, 4, 5}

2.2. Quy trình suy luận của Self-RAG

1. **Đánh giá nhu cầu:** Mô hình dự đoán xem việc truy xuất có giúp ích cho câu trả lời hay không.
2. **Truy xuất song song:** Nếu cần, hệ thống gọi bộ truy xuất để lấy nhiều tài liệu cùng lúc.
3. **Tạo và Đánh giá:** Mô hình tạo ra các đoạn văn bản tương ứng với từng tài liệu, đồng thời tạo các token phản hồi để đánh giá mức độ liên quan và hỗ trợ của tài liệu đó.

4. **Lựa chọn tối ưu:** Sử dụng thuật toán tìm kiếm chùm (beam search) ở cấp độ đoạn văn để chọn ra chuỗi văn bản có điểm số cao nhất dựa trên các token phản hồi.

3. Phân tích Hiệu suất và Thực nghiệm

3.1. Kết quả trên các bộ dữ liệu

Phương pháp	PopQA (Độ chính xác)	Biography (FactScore)	PubHealth (Độ chính xác)	Arc-Challenge (Độ chính xác)
LLaMA2-7B (RAG)	38.2	78.0	30.0	48.0
CRAG (trên SelfRAG-LLaMA2)	59.8	74.1	75.6	68.6
Self-RAG (LLaMA2-7B)	54.9	81.2	72.4	67.3
Self-CRAG (Tích hợp)	61.8	86.2	74.8	67.2

3.2. Khả năng thích ứng và Tính bền vững

- **Tính Plug-and-Play:** CRAG có thể dễ dàng kết hợp với các mô hình RAG khác. Khi tích hợp CRAG vào Self-RAG (tạo thành Self-CRAG), hiệu suất đạt mức cao nhất trên hầu hết các chỉ số.
- **Độ bền trước lỗi truy xuất:** Thử nghiệm cho thấy khi chất lượng truy xuất giảm xuống, hiệu suất của Self-CRAG giảm chậm hơn nhiều so với Self-RAG truyền thống, nhờ vào khả năng tự sửa lỗi và bổ sung thông tin từ web.
- **Chi phí tính toán:** Cơ chế tự sửa lỗi của CRAG chỉ gây ra một lượng nhỏ tài nguyên tính toán bổ sung (từ 26.5 lên 27.2 TFLOPs mỗi token), nhưng mang lại hiệu quả vượt trội so với các phương pháp không có cơ chế sửa lỗi.

4. Kết luận và Ý nghĩa

Việc nghiên cứu và áp dụng CRAG cùng Self-RAG đánh dấu một bước tiến quan trọng trong việc xử lý các kịch bản truy xuất sai sót.

- **CRAG** nổi bật với khả năng sửa lỗi chủ động thông qua tìm kiếm web và tinh lọc tri thức, đặc biệt hữu ích khi kho dữ liệu nội bộ bị hạn chế.
- **Self-RAG** mang lại khả năng tự kiểm soát và đánh giá tình vi cho mô hình ngôn ngữ thông qua hệ thống token phản hồi. Sự kết hợp giữa hai phương pháp này (Self-CRAG) tạo ra một khung làm việc mạnh mẽ, không chỉ giảm thiểu ảo giác mà còn tối ưu hóa việc sử dụng tri thức từ cả nguồn nội bộ và bên ngoài, đảm bảo tính chính xác và thực tế cho các ứng dụng trí tuệ nhân tạo thế hệ mới.**Trích dẫn quan trọng:** *"Việc phụ thuộc quá mức vào tri thức được truy xuất đặt ra những lo ngại nghiêm trọng về hành vi của mô hình trong các tình*

huống truy xuất thất bại hoặc trả về kết quả không chính xác." "Một hệ thống biết những gì nó không biết và biết tìm kiếm tri thức bên ngoài sẽ thông minh hơn một hệ thống bám lấy tri thức hạn chế và không có khả năng sửa lỗi."